

Deep Learning para Business Analytics

Tema A – Del modelo al agente

Anatomía, modos de trabajo y, sobre todo, cuánto cuesta.

Eduardo C. Garrido-Merchán

Profesor Propio Adjunto, Métodos Cuantitativos, ICADE

ecgarrido@comillas.edu



Madrid, 2026



NVIDIA

herramientas del tema

Lo que cubre este tema.

Dos temas, un hilo: cuánto cuesta lo que construís.

TEMA A — El agente y su coste

1. Del modelo al agente
2. El harness y las skills
3. Arquitecturas y workflows
4. Contexto y tipos de dato
5. Tokens, precio y facturas
6. Modelos libres y servidores



TEMA B — Sistemas sobre el agente

1. RAG, de verdad
2. MCP: el agente sale fuera
3. Sistemas multi-agente
4. SFT, LoRA y RLHF
5. Loop engineering
6. El presupuesto completo

El coste atraviesa los doce bloques.

De dónde venimos. Ya sabéis qué es un Transformer y qué es un LLM. Aquí no se añade arquitectura nueva: se añade todo lo que convierte a ese modelo en algo que trabaja.


Al final del tema sabréis. Montar un agente, decidir entre workflow y agente, elegir modelo con criterio y calcular, con números, lo que costará al mes.

El hilo conductor. Cada bloque termina en una línea del presupuesto. El proyecto final se defiende ante inversores, y la primera pregunta de un inversor es el coste por usuario.

IDEA CLAVE. Este tema se evalúa en el Caso II y en el modelo de costes de la memoria final.


Parte 1 / 6

Del modelo al agente



Un modelo es una función; un agente es un bucle alrededor de ella.

Lo único que cambia de verdad: quién decide el siguiente paso.



Los cuatro usan el mismo modelo. Lo que cambia es cuánto harness le han puesto alrededor.

Las cuatro piezas que distinguen al agente del chatbot.



1. Herramientas. El modelo puede pedir que se ejecute algo fuera de él: leer un fichero, lanzar una consulta SQL, llamar a una API.


2. Bucle. Tras cada acción vuelve a mirar el resultado y decide otra vez. Ese «otra vez» es lo que lo hace agente.

3. Criterio de parada. Decide él cuándo ha terminado, o cuándo necesita preguntarnos algo.

4. Permisos. Alguien ha tenido que decidir de antemano qué puede ejecutar sin pedir confirmación.

IDEA CLAVE. Quitadle cualquiera de las cuatro y vuelve a ser un chatbot con buena prensa.

Hay un programa que ejecuta el bucle, y está en vuestra máquina.



Tres puertas al mismo harness



Claude Code. En el terminal, dentro de un repositorio. Es el que usaremos en clase.

```
npm install -g @anthropic-ai/claude-code
```

Claude Cowork. El mismo motor sin terminal, sobre carpetas en vez de repositorios, pensado para trabajo de oficina: documentos, hojas de cálculo, investigación. Es la puerta que usará la mayoría de vuestros compañeros de empresa.

opencode. Libre y agnóstico del proveedor: le enchufáis la API que queráis, o un modelo local.

```
curl -fsSL https://opencode.ai/install | bash
```

Lo que comparten. Los tres hacen lo mismo: montar el contexto, llamar al modelo, ejecutar herramientas, repetir. Cambia la puerta de entrada y quién paga la llamada.

IDEA CLAVE. Cuando alguien os venda «una IA», preguntad cuál de estas tres cosas es.

Abrimos un agente sobre un repositorio de verdad.

DEMO EN DIRECTO · 5 MIN

```
bash — ~/ventas
```

```
$ cd ~/ventas
```

```
$ claude
```

```
> /status
```

```
> ¿qué hay en este directorio?
```

Lanzo. Claude Code sobre una carpeta con un CSV de ventas y cuatro scripts. Nada preparado: lo que haya.

Miráis. Qué modelo contesta, qué herramientas pide antes de responder, y cuántas vueltas da hasta decidir que ha terminado.

Si falla. Si la red falla, lo mismo con `opencode` y el modelo local: más lento, misma anatomía.


IDEA CLAVE. Lo que acabáis de ver es el harness usando el modelo.

Qué producto es cada escalón, y qué no puede hacer.

Escalón	Lo usáis como	Puede	No puede
Modelo	La API en crudo, o Llama 3.3 descargado de Hugging Face.	Transformar el texto que le pasáis.	Recordar nada, ni tocar un fichero.
Chatbot	ChatGPT o Gemini en el navegador.	Sostener una conversación larga.	Abrir vuestro ERP ni ejecutar nada.
Modelo con herramientas	Perplexity, Copilot dentro de Excel.	Buscar, calcular, rellenar una celda.	Encadenar pasos por su cuenta.
Agente	Claude Code, Cowork, opencode.	Decidir cuántos pasos da y ejecutarlos.	Saber qué no debe tocar si no se lo decís.

IDEA CLAVE. La diferencia de precio entre la fila 2 y la fila 4 es de dos órdenes de magnitud. La de capacidad, también.

Una herramienta es un contrato JSON , no magia.



Una llamada a herramienta, en directo y sin cortes.

DEMO EN DIRECTO · 4 MIN

claude — ~/ventas

```
> lee ventas_2025.csv y dime  
cuántas filas tiene
```

- `Read(ventas_2025.csv)`
└ 4.118 filas · 8 columnas


Lanzo. La misma pregunta de la figura anterior, para ver el JSON de ida y vuelta tal cual sale.

Miráis. Que el modelo *pide* la herramienta y se queda esperando. El fichero lo abre el programa.

Si falla. Si no tengo red, enseño el mismo intercambio en el registro de la sesión anterior.

IDEA CLAVE. Entre lo que el modelo pide y lo que se ejecuta hay una frontera. Ahí es donde se ponen las barandillas.

El bucle, sobre una pregunta de negocio real.



Lo que nadie cuenta la primera vez

Cada vuelta del bucle reenvía TODO el contexto anterior.

Vuelta 1:	4.000 tokens
Vuelta 2:	6.500 tokens
Vuelta 3:	9.800 tokens
Vuelta 4:	14.200 tokens

Total:	34.500 tokens
--------	---------------

No pagas la última llamada.
Pagas la suma de todas.

La caché de prompt decide aquí si el proyecto es viable: descuenta el 90 % de todo lo que se repite entre vueltas.

El mismo bucle, tal y como se ve en pantalla.

```
claude — ~/ventas

> ¿por qué cayeron las ventas en marzo?

• Read(ventas_2025.csv)
  ↳ 14 meses · 8 columnas · 41 KB

• Bash(python -c 'df.groupby("mes")...')
  ↳ marzo: 412.300 € (-18,4 % vs febrero)

• Read(calendario_promos.xlsx)
  ↳ la promo de primavera arrancó el 2 de abril

Marzo cayó un 18,4 %. No es estacionalidad:
en 2024 la promo entró el 3 de marzo y este
año se retrasó un mes. El efecto se recupera
en abril (+21 %).

> /cost

4 vueltas · 31.400 in · 2.380 out · 0,13 USD
```

Una vuelta del bucle:
pide herramienta, la lees,
vuelve a decidir.


Decidió él cuántas
herramientas pedir.

La respuesta llega cuando
él decide que ha terminado.

Los cuatro números del
presupuesto, medidos.

Mismo bucle de la figura anterior, esta vez con los tokens contados por el propio programa.

Por qué el coste de un agente sorprende siempre la primera vez.



Cada vuelta reenvía todo lo anterior.

La API no tiene memoria. Cada llamada es independiente. Para que el modelo «recuerde» la vuelta anterior, el harness le reenvía toda la conversación.

Consecuencia. Una sesión de N vueltas no cuesta N llamadas: cuesta la suma de N contextos que crecen.

EJEMPLO A MANO: Cuatro vueltas de 4.000 tokens iniciales

Si cada vuelta añade 2.500 tokens, pagáis $4,000 + 6,500 + 9,000 + 11,500 = 31,000$ tokens de entrada, no 4.000.

IDEA CLAVE. La factura crece de forma cuadrática con la longitud de la sesión si no se gestiona el contexto.

Ocho comandos que vamos a usar durante todo el tema.

Comando	Qué te enseña	Qué concepto del tema mide
/status	Modelo activo, cuenta, directorio.	<i>El harness, de un vistazo.</i>
/context	Cuánto ocupa cada capa de la ventana.	<i>Las cuatro capas del presupuesto.</i>
/compact	Resume el historial y lo sustituye.	<i>Podar frente a compactar.</i>
/usage	Consumo frente al límite del plan.	<i>Qué llevas gastado hoy.</i>
/cost	Tokens y USD de esta sesión.	<i>Los cuatro números de la fórmula.</i>
/model	Cambia de tier sin salir de la sesión.	<i>Palanca 1: bajar de modelo.</i>
/permissions	Qué se ejecuta solo y qué pregunta.	<i>Las barandillas.</i>
/skills	Qué manuales hay y cuáles están cargados.	<i>Carga progresiva.</i>

En `opencode` los equivalentes son `opencode stats` · `opencode models` · `/compact`

Medimos la sesión que acabamos de abrir.

DEMO EN DIRECTO · 6 MIN

claude — ~/ventas

> `/context`

system 2,1k · skills 0,9k

historial 18,4k · libre 178k

> `/cost`

> `/compact`

> `/context`

Lanzo. `/context` antes de compactar, `/compact`, y `/context` otra vez sobre la misma sesión.

Miráis. Cuánto ocupa cada capa, cuál es la única que crece sola, y cuánto historial se pierde al compactar.

Si falla. Si la sesión va corta de historial, pego un PDF largo para inflarla y repito.

IDEA CLAVE. Esta es la medición que tendréis que repetir en el Caso II; de aquí salen las cifras del presupuesto.

Qué está pasando ya en las empresas de vuestro sector.

Expansión · Tecnología

Expansión

La banca española mide ya el gasto en IA por consulta, no por licencia

Los equipos de datos de las grandes entidades han dejado de presupuestar la IA como software y han empezado a hacerlo como infraestructura: coste por token, por usuario y por mes.

Cinco Días · Empresas

CincoDías

El coste por token baja, pero la factura sube: el efecto del agente

Cada agente reenvía su contexto en cada vuelta del bucle. Los equipos que no miden tokens descubren el problema cuando llega la factura del segundo mes.

Lo que un inversor te va a preguntar en el pitch

¿Cuánto te cuesta atender a UN usuario durante un mes?

¿Qué pasa con ese número si creces 10×?

¿Cuál es tu margen si el precio del modelo no baja?

Concepto → aplicación: dónde encaja un agente en una empresa.

Función	Caso concreto	Entradas	KPI
Finanzas	Conciliar extractos bancarios con el ERP.	Extractos + asientos.	% conciliado solo.
Compras	Comparar ofertas de proveedor y resumir diferencias.	PDFs de oferta.	Horas/expediente.
Atención	Responder borradores de tickets con el histórico.	Ticket + base de conocimiento.	% resueltos sin humano.
Riesgos	Revisar contratos y marcar cláusulas atípicas.	Contratos en PDF.	Cláusulas detectadas.
Datos	Explorar un dataset y proponer el primer informe.	CSV de negocio.	Tiempo hasta el insight.

IDEA CLAVE. El patrón común: tareas que mezclan texto, datos y una decisión, repetidas muchas veces al mes.

Parte 2 / 6

El harness y las skills

other

十月三十日(星期五)

中文 寫作: 啟事
(原稿紙)

英文 小測驗及
作業 6 W x 1

綜人 ① Eng Passage p.1

數

英 Quiz Corr + Sign

中史 WS B1-B3
Wed 4/1

其他

值日生
14

Date: 10/30/2019

Period	Subject	Teaching content	Assignments given	Whole class learning (1-5)	Period
1	中文	作文及閱讀: 工作紙	不太集中	1 2 3 4 5	1
2	中文	閱讀: 工作紙	寫作: 故事(原稿紙)	1 2 3 4 5	2
3	英文	練習 (2)	小測驗及作業	1 2 3 4 5	3
4	英文	閱讀及寫作	Eng Passage p.1	1 2 3 4 5	4
5	英文	練習		1 2 3 4 5	5
6	英文	練習	Ex 1 (1-10)	1 2 3 4 5	6
7	英文	Corr. Workbook Set (2)	作文及閱讀	1 2 3 4 5	7
8	英文	A hand writing to go home		1 2 3 4 5	8
9	英文		MS 91-B2, and	1 2 3 4 5	9

Special reports:


Period	Name(s) of student(s)	Details	Period
5	李金波	作文及閱讀	1
	徐金波	寫作	

Others (please give details):

Signature of Student: 李金波


Class teacher's signature:

El harness: todo lo que rodea al modelo .



Cambiar de modelo mueve la calidad un poco. Cambiar el harness lo mueve todo.

Las seis piezas del harness, una por una.



*Cambiar de modelo mueve la calidad un poco.
Cambiar el harness lo mueve todo.*

System prompt. Quién es el agente, qué convenciones sigue, qué tiene prohibido. Es la pieza con mejor relación coste/efecto de todas.

Bucle. Cuántas vueltas como máximo, qué hacer si una herramienta falla, cuándo parar.

Herramientas. El catálogo de acciones. Cada una con su esquema y su descripción.


Permisos. Qué se ejecuta sin preguntar y qué exige confirmación humana. Aquí vive el riesgo operativo.

Contexto. Qué se le mete en cada turno y qué se poda. El capítulo más caro de la factura.

Memoria. Qué sobrevive al cierre de la sesión: un fichero, una base de datos, nada.

IDEA CLAVE. Dos equipos con el mismo modelo y resultados opuestos: la diferencia está casi siempre en el harness.

El fichero de instrucciones: cinco bloques que valen más que cualquier prompt ingenioso.



*Cambiar de modelo mueve la calidad un poco.
Cambiar el harness lo mueve todo.*

- 1. Rol.** «Eres el asistente de análisis del equipo de riesgos de una aseguradora española.»
- 2. Convenciones.** «Las cifras en euros con separador de miles. Los informes en castellano, registro neutro.»
- 3. Restricciones.** «No escribas en produccion/. No instales dependencias sin preguntar.»
- 4. Contexto del proyecto.** «Los datos están en data/polizas.parquet; el diccionario de campos, en docs/.»
- 5. Política de IA.** «Declara en cada entregable qué parte se generó con IA y conserva los prompts.»

IDEA CLAVE. Se versiona con el repositorio. Si vive en la cabeza de una persona, no existe.

Abrimos el harness por dentro y le cambiamos las reglas.

[DEMO EN DIRECTO · 7 MIN](#)

```
claude — ~/ventas
```

```
> /init
```

```
    escribe CLAUDE.md
```

```
> /skills
```

```
> /permissions
```

```
    edito CLAUDE.md y repito
```

```
> ¿qué convenciones sigues?
```


Lanzo. /init para que escriba él su propio fichero de instrucciones, y luego lo edito delante de vosotros.

Miráis. Que la misma pregunta da otra respuesta después de cambiar tres líneas de CLAUDE.md, con el mismo modelo.

Si falla. Si /init tarda, uso el CLAUDE.md que ya tengo escrito y enseño el diff.


IDEA CLAVE. Esto es lo barato de ajustar. Cambiar de modelo cuesta dinero; cambiar el system prompt cuesta cinco minutos.

Skills: manuales que el agente abre solo cuando hacen falta.



El contexto es un presupuesto. Las skills te dejan pagar solo por el manual que estás usando.

Por qué las skills son una decisión económica y no sólo de orden.



El contexto es un presupuesto: pagas solo por el manual que estás usando.

El problema. Una empresa mediana acumula decenas de procedimientos. Metidos todos en el system prompt, se pagan en cada llamada aunque no se usen.

La carga progresiva. El agente ve una línea por skill (nombre y para qué sirve). Cuando la tarea encaja, abre el manual completo.

EJEMPLO A MANO: 18.000 tokens frente a 900

Con 20 skills de 900 tokens, cargarlas todas cuesta 18.000 tokens por llamada. Con carga progresiva se pagan 900 de índice y sólo el manual que toque.

IDEA CLAVE. A 50.000 llamadas al mes y Sonnet 5, esos 17.000 tokens de diferencia son unos 2.550 USD mensuales.

Las barandillas: dónde se pone el humano en el bucle.

1 · Tú declaras la herramienta

lo escribes una vez

```
{
  "name": "consultar_stock",
  "description":
    "Stock por SKU",
  "input_schema": {
    "sku": {"type": "string"}
  }
}
```



2 · El modelo la pide

no ejecuta: pide

```
{
  "type": "tool_use",
  "name": "consultar_stock",
  "input": {
    "sku": "ZR-4410"
  }
}
```



3 · Tu código responde

aquí ejecutas tú

```
{
  "type": "tool_result",
  "content":
    "128 uds en Zaragoza,
    0 en Madrid"
}
```

El modelo pide; tu código ejecuta.

Regla de reversibilidad. Lo que se deshace con un `git revert` puede ir solo. Lo que sale de la empresa (un correo, un pago, un borrado) pide confirmación.

Tres niveles en la práctica. *Permitir siempre* para leer y buscar; *preguntar* para escribir y ejecutar; *denegar* para lo que nunca debe tocar.

Dónde se tocan. `/permissions` lista las reglas vigentes y deja añadirlas sin salir de la sesión. Se versionan en `.claude/settings.json` junto al repositorio.

Auditoría. El agente deja traza de cada herramienta que invocó y con qué argumentos. Cuando algo sale mal, se reproduce.

IDEA CLAVE. El permiso se define por la consecuencia de la acción, no por lo lista que parezca la herramienta.

Parte 3 / 6

Arquitecturas y workflows




Cuatro arquitecturas, de la más predecible a la más abierta.

(a) Cadena fija — un workflow




Tú decides el orden. El modelo solo rellena cada paso.
Coste predecible, resultado auditable.

(b) Router — elige la rama



Un modelo barato enruta; uno caro solo atiende lo que de verdad lo necesita.

(c) Orquestador y trabajadores



Paralelizas el trabajo. Multiplicas el gasto por el número de trabajadores: cada uno recarga su contexto.

(d) Agente autónomo



Máxima capacidad, mínima predictibilidad.
El coste solo se acota poniéndole un límite duro.


Cómo elegir entre las cuatro.

(a) Cadena fija



Tú decides el orden.

(b) Router



Lo barato enruta; lo caro atiende.

(c) Orquestador



Paralelo, y cada uno recarga contexto.

(d) Autónomo



Máxima capacidad, mínima predictibilidad.

Cadena fija. Cuando conocéis los pasos. Coste y latencia predecibles al céntimo. Es la opción correcta mucho más a menudo de lo que parece.

Router. Cuando hay varias ramas conocidas. Un modelo barato clasifica y sólo lo difícil llega al modelo caro: ahorro grande con cambio pequeño.

Orquestador. Cuando la tarea se parte en trozos independientes. Ganáis tiempo de reloj y pagáis el contexto de cada trabajador.

Autónomo. Cuando ni vosotros sabéis los pasos. Máxima capacidad y el único control de coste es un límite duro de tokens.

IDEA CLAVE. Subid un escalón sólo cuando el anterior os haya fallado por una razón concreta.

La mayoría de lo que se vende como «agente» es un workflow.



El criterio de decisión, en una pregunta.

¿Conocéis de antemano los pasos?

Si

WORKFLOW

- Facturas → extraer → validar → ERP
- Ticket → clasificar → plantilla
- Informe mensual de estructura fija
- Traducir 8.000 referencias

Coste predecible · fallos reproducibles · barato

No

AGENTE

- «Averigua por qué se fue este cliente»
- «Migra este módulo a la nueva API»
- «Prepara el análisis competitivo»
- «Encuentra el fallo que tira producción»

Coste variable · fallos difíciles · caro

La pregunta. ¿Podéis escribir hoy la lista de pasos que hay que dar? Si podéis, escribidla: sale más barata, más rápida y más fácil de auditar.

Señales de que necesitáis un agente. El número de pasos depende de lo que se encuentre por el camino; hay que reaccionar a resultados intermedios; la tarea se describe por objetivo y no por procedimiento.

Señal de alarma. Si vuestro «agente» siempre llama a las mismas tres herramientas en el mismo orden, habéis pagado de más por un workflow.

IDEA CLAVE. El coste de un workflow se calcula. El de un agente se acota.

Cuatro modos de usar el mismo agente.

Interactivo

```
claude
```

Conversas, ves cada paso,
apruebas lo que toca.

Para:

Explorar, depurar,
aprender el repo.

Plan

```
claude → shift+tab
```

Te cuenta qué va a hacer
antes de tocar nada.

Para:

Cambios que dan miedo.

No interactivo

```
claude -p "..."
```

Un comando, una respuesta,
sin conversación.

Para:

Scripts, CI, hooks
de git.

Programado

```
cron + claude -p
```

Se ejecuta solo, a su hora,
sin nadie mirando.

Para:

Informes nocturnos,
vigilancia de datos.

Los modos, con la herramienta en la mano.

Interactivo

```
claude
```

Conversas, ves cada paso,
apruebas lo que toca.

Para:

Explorar, depurar,
aprender el repo.

Plan

```
claude → shift+tab
```

Te cuenta qué va a hacer
antes de tocar nada.

Para:

Cambios que dan miedo.

No interactivo

```
claude -p "..."
```

Un comando, una respuesta,
sin conversación.

Para:

Scripts, CI, hooks
de git.

Programado

```
cron + claude -p
```

Se ejecuta solo, a su hora,
sin nadie mirando.

Para:

Informes nocturnos,
vigilancia de datos.

Cloud. `npm install -g @anthropic-ai/claude-code`, después `claude` dentro del repositorio. Requiere cuenta y crédito.

Libre. `curl -fsSL https://opencode.ai/install | bash` y `opencode -model ollama/qwen2.5-coder:7b`. Cero coste por sesión, calidad menor.

Interactivo. Para explorar y para aprender el repositorio. Veis cada paso y aprobáis lo que toca.

Plan. El agente cuenta qué va a hacer antes de tocar nada. Para cambios que dan miedo.

No interactivo. `claude -p 'revisa este diff'` dentro de un script o de un *hook* de git. Sin conversación.

Programado. El mismo comando bajo `cron`. Informes nocturnos, vigilancia de datos, resúmenes de lunes.

IDEA CLAVE. El modo programado es el que convierte un juguete en infraestructura, y también el que dispara la factura sin que nadie mire.

Los cuatro modos, uno detrás de otro, en dos minutos cada uno.

DEMO EN DIRECTO · 8 MIN

```
bash — ~/ventas
```

```
$ claude
```

```
shift+tab → modo plan
```

```
$ claude -p 'resume los  
cambios de hoy' > nota.md
```

```
$ crontab -e
```

```
0 7 * * 1 claude -p ...
```

Lanzo. El mismo agente en interactivo, en plan, en -p dentro de un *pipe* de shell, y la línea de cron que lo programa.

Miráis. Que el modo -p escupe texto plano y encadena con cualquier herramienta de Unix. Ahí es donde esto deja de ser un chat.

Si falla. Si cron no está disponible, enseño el fichero de *hook* de git que hace lo mismo al hacer commit.


IDEA CLAVE. El salto de productividad está en el tercer modo. El salto de factura, en el cuarto.

Parte 4 / 6


El contexto y los datos



El historial se come el presupuesto, y lo pagáis en cada turno.



Las cuatro capas que compiten por la ventana.



Restricción. Las cuatro capas comparten un único presupuesto de tokens:

$$\underbrace{t_{\text{sys}}}_{\text{fijo}} + \underbrace{t_{\text{skills}}}_{\text{bajo demanda}} + \underbrace{t_{\text{rag}}}_{\text{por consulta}} + \underbrace{t_{\text{hist}}}_{\text{crece}} \leq B$$

Cuál crece. Sólo la última. Las otras tres las controláis vosotros; el historial crece solo mientras el agente trabaja.

Las dos salidas. *Podar* (borrar resultados de herramientas antiguos) o *compactar* (resumir lo anterior). Las dos pierden información; elegid cuál os duele menos.

Cómo se mide. `/context` desglosa las cuatro capas de la sesión abierta, y `/compact` ejecuta la segunda salida.

IDEA CLAVE. Gestionar el contexto es la primera decisión de diseño y la primera partida del presupuesto.

Qué le podéis dar de comer, y lo que ocupa cada cosa.

Texto plano	Un folio A4 denso	~ 700 tokens
PDF	Memoria anual de 80 páginas	~ 60.000 tokens
Imagen	Una captura de pantalla	hasta ~ 4.800 tokens
CSV / Excel	20.000 filas de ventas	no cabe: va por herramienta
Audio	Reunión de una hora	se transcribe primero
Base de datos	El ERP entero	nunca entra: se consulta

Fondo dorado: entra directo en el contexto.

Fondo blanco: el agente lo toca con una herramienta, no se lo traga entero.

La pregunta de diseño es «¿cuánto me cuesta que quepa, en cada uno de los turnos de la sesión?».

La regla para decidir qué entra en el contexto y qué no.

Texto plano Un folio A4 denso	- 700 tokens
PDF Memoria anual de 80 páginas	- 60.000 tokens
Imagen Una captura de pantalla	hasta - 4.800 tokens
CSV / Excel 20.000 filas de ventas	no cabe: va por herramienta
Audio Reunión de una hora	se transcribe primero
Base de datos El ERP entero	nunca entra: se consulta

Fondo dorado: entra directo en el contexto.

Fondo blanco: se toca con una herramienta.

Entra en el contexto lo que el modelo necesita *leer entero* para razonar: un contrato, un informe, una captura de pantalla.

Se toca con una herramienta lo que el modelo necesita *consultar*: una tabla de 20.000 filas, el ERP, un índice de documentos.

EJEMPLO A MANO: El error de principiante

Pegar un CSV de 50.000 filas en el prompt. Son unos 2 millones de tokens: no cabe, y si cupiera costaría 6 USD por pregunta con Sonnet 5.

IDEA CLAVE. Si el dato se puede filtrar antes de llegar al modelo, filtradlo antes: cada token que no mandáis es un token que no pagáis.


Parte 5 / 6

Tokens, precio y factura



Qué es exactamente un token, y por qué os lo cobran dos veces.

Precios de lista a 2026-10-02



Entre el modelo más barato y el más caro hay un factor 10. Elegir modelo es, antes que nada, una decisión de presupuesto.

Qué es. Un trozo de texto de entre uno y varios caracteres. En castellano, unas 0,75 palabras por token de media.

Dos contadores. Los tokens de **entrada** (todo lo que le mandáis) y los de **salida** (lo que genera). Se facturan a precios distintos.

Por qué la salida es más cara. Generar exige una pasada del modelo por token. Leer la entrada se paraleliza; escribir la salida es secuencial.


EJEMPLO A MANO: De texto a factura

Un informe de 3 folios son unos 2.000 tokens de salida. Con Opus 5, a 25 USD el millón, son 0,05 USD por informe.

IDEA CLAVE. Todo presupuesto de IA empieza por estimar estos dos números para una consulta típica.

Generar cuesta cinco veces más que leer.


Precios de lista a 2026-10-02



Entre el modelo más barato y el más caro hay un factor 10. Elegir modelo es, antes que nada, una decisión de presupuesto.

La fórmula del coste, término a término.

Precios de lista a 2026-10-02



Entre el modelo más barato y el más caro hay un factor 10. Elegir modelo es, antes que nada, una decisión de presupuesto.

$$C = p_{\text{in}} t_{\text{in}} + p_{\text{out}} t_{\text{out}}$$

$$C_{\text{mes}} = C \cdot N$$

p_{in} precio por token de entrada (USD/MTok $\div 10^6$)

p_{out} precio por token de salida


$t_{\text{in}}, t_{\text{out}}$ tokens de una consulta típica

N consultas al mes

Los cuatro números. Son los únicos que necesitáis para el presupuesto base. Los tres primeros los sabéis; el cuarto es vuestra previsión de negocio.


IDEA CLAVE. Si no sabéis estimar N , no tenéis un problema de IA: tenéis un problema de modelo de negocio.

Tres decisiones, la misma funcionalidad, el 84 % menos de factura.



50.000 consultas/mes de 4.000 tokens de entrada y 400 de salida. Precios a 2026-10-02.

Las tres palancas, explicadas.



50.000 consultas/mes de 4.000 tokens de entrada y 400 de salida. Precios a 2026-10-02.

1. Bajar de tier. Entre el modelo más caro y el más barato hay un factor 10. Casi ninguna tarea de clasificación necesita el tier alto.

2. Caché de prompt. Lo que se repite entre llamadas (system prompt, instrucciones, documentos fijos) se factura al 10 %. Escribirlo en caché cuesta un 25 % más una sola vez.

3. Batch. Si la respuesta no tiene que llegar ya, la API de lotes descuenta el 50 %. Entrega en menos de una hora casi siempre, 24 como máximo.

IDEA CLAVE. Las tres son compatibles entre sí y ninguna cambia lo que el usuario ve.

Bajamos de tier en caliente y medimos lo que cambia.

DEMO EN DIRECTO · 6 MIN

claude — ~/ventas

> /cost

Opus 5 · 0,34 USD

> /model sonnet

> (repito la misma pregunta)

> /cost

Sonnet 5 · 0,07 USD


Lanzo. La misma pregunta de negocio con el tier alto y con el medio, midiendo con /cost las dos veces.

Miráis. El factor de precio entre los dos, y si la respuesta ha empeorado lo suficiente para justificarlo. Casi nunca lo hace.

Si falla. Si solo tengo un modelo disponible, comparo contra las cifras de la calculadora de la práctica.

IDEA CLAVE. Esta comparación de dos minutos es la que deberíais hacer antes de fijar el modelo de cualquier proyecto.

Cómo se rompe la caché sin darse cuenta.



La regla. La caché casa por *prefijo exacto*. Un solo byte distinto al principio invalida todo lo que viene detrás.


Los tres asesinos silenciosos. Meter la fecha y hora en el system prompt; generar un identificador aleatorio por petición; serializar un diccionario sin ordenar las claves.

Cómo se comprueba. La respuesta trae un contador de tokens leídos de caché. Si sale cero llamada tras llamada con el mismo prefijo, hay un asesino suelto.


IDEA CLAVE. Lo estable va delante, lo que cambia va detrás. Ese es todo el diseño.

El presupuesto de IA: expectativa y realidad.

Lo que pusiste en el Excel



Lo que llegó




Parte 6 / 6

Modelos libres y servidores propios



Qué significa «modelo libre» y cómo se baja uno.



El modelo cuantizado ocupa 42 GB y no se mueve. La caché KV crece con el contexto y con la concurrencia, y es la que te obliga a comprar más tarjetas.

Libre, con matices. Los pesos se descargan y se ejecutan donde queráis. La licencia suele permitir uso comercial con condiciones: leedla antes de construir encima.

Dónde están. Hugging Face es el repositorio de referencia. Familias habituales: Llama (Meta), Qwen (Alibaba), Mistral, DeepSeek, Gemma (Google).

Cómo se prueba en cinco minutos.

```
curl -fsSL https://ollama.com/install.sh | sh
ollama pull qwen2.5:7b
ollama run qwen2.5:7b
```

Cuantización. Reducir la precisión de los pesos de 16 bits a 4. El modelo ocupa un tercio y pierde poca calidad. Q4_K_M es el punto dulce habitual.

IDEA CLAVE. Probarlo en vuestro portátil es gratis. Servirlo a 500 usuarios no lo es, y ahí empieza el cálculo.

La misma pregunta, pagando y sin pagar.

API de pago

```
claude — Sonnet 5 por API

> resume este contrato y marca las
  cláusulas atípicas

● Read(contrato.pdf)  ↳ 34 págs
● Grep("penalización")  ↳ 6 hits

Tres cláusulas se salen del estándar:
la 7.2 (penalización al 12 %), la 9.1
(renovación tácita) y la 14 (fuero).

> /cost  ↳ 0,21 USD · 11 s
```

Modelo libre en tu portátil

```
opencode — qwen2.5-coder:7b local

> resume este contrato y marca las
  cláusulas atípicas

● read(contrato.pdf)  ↳ 34 págs

El contrato regula un suministro.
Incluye cláusulas de penalización y
de renovación. Conviene revisarlas.

(no citó ninguna cláusula concreta)

$ opencode stats  ↳ 0,00 USD · 94 s
```

Cero euros y ocho veces más lento, pero la diferencia que importa es que el segundo no citó ni una cláusula.

Un agente entero sin tarjeta de crédito.

[DEMO EN DIRECTO · 7 MIN](#)

```
bash — ~/ventas
```

```
$ ollama run qwen2.5-coder:7b
```

```
$ opencode
```

```
modelo: ollama/qwen2.5-coder
```

```
> (la pregunta de la demo 1)
```

```
$ opencode stats
```

Lanzo. La pregunta de la primera demo, esta vez contra un modelo de 7B que corre en este portátil, sin red.


Miráis. Que el bucle es idéntico y la factura es cero. Y que a la tercera vuelta se nota de dónde viene la diferencia de precio.

Si falla. Si el portátil se queda sin RAM, bajo a qwen2.5:3b y lo digo en voz alta: eso también es dimensionar.

IDEA CLAVE. Probarlo es gratis. Servirlo a quinientos usuarios es la cuenta de las dos slides siguientes.

Llama 3.3 70B en INT4: los pesos son lo de menos.


Llama 3.3 70B en INT4, 8 peticiones simultáneas



El modelo cuantizado ocupa 42 GB y no se mueve. La caché KV crece con el contexto y con la concurrencia, y es la que te obliga a comprar más tarjetas.

Dimensionar un servidor: la fórmula y la trampa.

Llama 3.3 70B en INT4, 8 peticiones simultáneas



El modelo cuantizado ocupa 42 GB y no se mueve. La caché KV crece con el contexto y con la concurrencia, y es la que te obliga a comprar más tarjetas.

$$\text{VRAM} \approx \underbrace{P \cdot b}_{\text{pesos}} \cdot (1 + \rho) + \underbrace{k \cdot L \cdot c}_{\text{caché KV}}$$

P parámetros (en miles de millones)

b bytes por parámetro: 2 en FP16, 0,6 en INT4

ρ overhead del runtime, $\approx 0,15$

k MB de caché por cada 1.000 tokens (≈ 320)


L contexto servido, en miles de tokens

c peticiones simultáneas

La trampa. Casi todo el mundo calcula sólo el primer término. El segundo crece con el contexto y con la concurrencia, y es el que os obliga a comprar la tercera tarjeta.


IDEA CLAVE. Dimensionad con el contexto y la concurrencia reales, no con los del día de la demo.

El volumen decide si compensa la API o el servidor propio.



Sonnet 5 con 60 % de caché frente a Llama 3.3 70B en INT4. Incluye un cuarto de jornada de MLOps. Precios a 2026-10-02.

Cómo se lee el punto de equilibrio.



Sonnet 5 con 60 % de caché frente a Llama 3.3 70B en INT4. Incluye un cuarto de jornada de MLOps. Precios a 2026-10-02.


Dos curvas distintas. La API es coste *variable* puro: una recta que sale del origen. El servidor es coste *fijo*: una horizontal. Siempre se cortan.

El umbral. $N^* = C_{\text{servidor}} / c_{\text{consulta}}$. En este caso, unas 234.000 consultas al mes.

Lo que inclina la balanza. Apagar el servidor fuera de horario baja la horizontal un 65 %. Activar la caché baja la pendiente de la recta. Las dos mueven el cruce.

IDEA CLAVE. El servidor propio se justifica por volumen sostenido, por residencia del dato o por pesos ajustados; casi nunca por precio a volúmenes de arranque.

Lo que el gráfico no dice: las cuatro partidas que se olvidan.



Sonnet 5 con 60 % de caché frente a Llama 3.3 70B en INT4. Incluye un cuarto de jornada de MLOps. Precios a 2026-10-02.

1. Personal. Un servidor en producción necesita alguien que lo vigile. Un cuarto de jornada de MLOps son unos 1.240 USD al mes, y ya está dentro de la horizontal del gráfico.

2. Redundancia. Una sola tarjeta significa una sola avería hasta la caída del servicio. El doble de tarjetas, el doble de horizontal.

3. Actualización. Los modelos libres mejoran cada pocos meses. Migrar, reevaluar y volver a desplegar es trabajo recurrente.

4. Ocupación. Un servidor cuesta lo mismo al 5 % que al 95 % de uso. La API cuesta cero cuando nadie pregunta.

IDEA CLAVE. Comparad coste total de propiedad contra coste total de propiedad, no precio por token contra precio por hora.

Cuándo elegir cada vía, en una tabla.

Criterio	API de pago	Modelo libre en servidor
Volumen bajo o irregular	Gana: pagáis sólo lo que usáis.	Pagáis la GPU aunque nadie pregunte.
Volumen alto y sostenido	El coste crece sin techo.	Gana a partir del umbral.
Datos que no pueden salir	Requiere acuerdo y revisión legal.	Gana: el dato no sale de casa.
Máxima calidad	Gana: tier alto disponible ya.	Los libres van por detrás.
Equipo pequeño	Gana: cero operación.	Necesitáis MLOps.
Modelo ajustado a lo vuestro	Limitado a lo que ofrezca el proveedor.	Gana: control total de los pesos.

IDEA CLAVE. Lo habitual en una startup: API para arrancar y medir; servidor cuando el volumen y el equipo lo justifiquen.

Lo que os lleváis de este tema.

Dos temas, un hilo: cuánto cuesta lo que construís.

TEMA A — El agente y su coste

1. Del modelo al agente
2. El harness y las skills
3. Arquitecturas y workflows
4. Contexto y tipos de dato
5. Tokens, precio y facturas
6. Modelos libres y servidores



TEMA B — Sistemas sobre el agente

1. RAG, de verdad
2. MCP: el agente sale fuera
3. Sistemas multi-agente
4. SFT, LoRA y RLHF
5. Loop engineering
6. El presupuesto completo

El coste atraviesa los doce bloques.

Concepto 1. Un agente es un modelo dentro de un bucle con herramientas y permisos. El harness es el programa que lo ejecuta (Claude Code, Cowork, opencode) y determina la calidad más que el modelo.

Concepto 2. Workflow cuando conocéis los pasos; agente cuando no. Subir de arquitectura cuesta dinero y predictibilidad.


Concepto 3. El contexto es un presupuesto compartido, y el historial de la sesión es lo único que crece solo.

Concepto 4. Tier, caché y batch son tres palancas independientes que juntas recortan la factura un 84 % sin tocar la funcionalidad.

Concepto 5. El servidor propio se decide por volumen, residencia del dato o pesos propios; se calcula con el punto de equilibrio.

Para la práctica. Montar un agente sobre un repositorio real y medir, con `/context` y `/cost` primero y con la calculadora

Pausa para debatir: ¿dejaríais que un agente mandase un correo a un cliente?



La pregunta. Vuestro agente redacta respuestas a reclamaciones. Funciona bien el 97 % de las veces. ¿Lo dejáis enviar sin revisión humana?

Posición A. Sí, con un modelo de riesgo: enviar solo por debajo de cierto importe y auditar una muestra.

Posición B. No. Un correo a un cliente es irreversible, y el 3 % restante es el que acaba en prensa.

Reglas. Cinco minutos, dos turnos por bando, móviles boca abajo. Yo modero y no participo.

Hasta el Tema B.

RAG, MCP, multi-agente y adaptación.

Eduardo C. Garrido-Merchán

ecgarrido@comillas.edu

