

Deep Learning para Business Analytics

Tema A — Del modelo al agente

Anatomía, modos de trabajo y, sobre todo, cuánto cuesta.

Eduardo C. Garrido-Merchán

Profesor Propio Adjunto, Métodos Cuantitativos, ICADE

ecgarrido@comillas.edu




Madrid, 2026



herramientas del tema

Lo que cubre este tema.

Dos temas, un hilo: cuánto cuesta lo que construyes.



El coste atraviesa los doce bloques: cada decisión técnica tiene una línea en el presupuesto.

De dónde venimos. Ya sabéis qué es un Transformer y qué es un LLM. Aquí no se añade arquitectura nueva: se añade todo lo que convierte a ese modelo en algo que trabaja.


Al final del tema sabréis. Montar un agente, decidir entre workflow y agente, elegir modelo con criterio y calcular, con números, lo que costará al mes.

El hilo conductor. Cada bloque termina en una línea del presupuesto. El proyecto final se defiende ante inversores, y la primera pregunta de un inversor es el coste por usuario.

IDEA CLAVE. Este tema se evalúa en el Caso II y en el modelo de costes de la memoria final.


Parte 1 / 6

Del modelo al agente




Un modelo es una función; un agente es un bucle alrededor de ella.

Lo único que cambia de verdad: quién decide el siguiente paso.



El agente usa el mismo modelo de la primera columna. Lo que se le añade es el bucle y los permisos.

Las cuatro piezas que distinguen al agente del chatbot.



El agente usa el mismo modelo de la primera columna. Lo que se le añade es el bucle y los permisos.

- 1. Herramientas.** El modelo puede pedir que se ejecute algo fuera de él: leer un fichero, lanzar una consulta SQL, llamar a una API.
- 2. Bucle.** Tras cada acción vuelve a mirar el resultado y decide otra vez. Ese «otra vez» es lo que lo hace agente.
- 3. Criterio de parada.** Decide él cuándo ha terminado, o cuándo necesita preguntarnos algo.
- 4. Permisos.** Alguien ha tenido que decidir de antemano qué puede ejecutar sin pedir confirmación.

IDEA CLAVE. Quitadle cualquiera de las cuatro y vuelve a ser un chatbot con buena prensa.

Una herramienta es un contrato JSON , no magia.

Una herramienta es un contrato JSON, no magia.

1 · Tú declaras la herramienta

```
{
  "name": "consultar_stock",
  "description": "Stock por SKU",
  "input_schema": {
    "sku": {"type": "string"}
  }
}
```

2 · El modelo la pide

```
{
  "type": "tool_use",
  "name": "consultar_stock",
  "input": {"sku": "ZR-4410"}
}
```


3 · Tu código responde

```
{
  "type": "tool_result",
  "content": "ZR-4410: 128 uds\n      en Zaragoza, 0 en Madrid"
}
```

El modelo solo pide; ejecuta tu código. Esa frontera es donde se ponen las barandillas.

El bucle, sobre una pregunta de negocio real.

El bucle, sobre una tarea real de negocio.



Lo que nadie cuenta la primera vez

Cada vuelta del bucle reenvía TODO el contexto anterior.

Vuelta 1:	4.000 tokens
Vuelta 2:	6.500 tokens
Vuelta 3:	9.800 tokens
Vuelta 4:	14.200 tokens


Total:	34.500 tokens
--------	---------------

No pagas la última llamada.
Pagas la suma de todas.

La caché de prompt decide aquí si el proyecto es viable: descuenta el 90 % de todo lo que se repite entre vueltas.

Por qué el coste de un agente sorprende siempre la primera vez.

El bucle, sobre una tarea real de negocio.



La caché de prompt decide aquí si el proyecto es viable: descuenta el 90 % de todo lo que se repite entre vueltas.

La API no tiene memoria. Cada llamada es independiente. Para que el modelo «recuerde» la vuelta anterior, el harness le reenvía toda la conversación.

Consecuencia. Una sesión de N vueltas no cuesta N llamadas: cuesta la suma de N contextos que crecen.

EJEMPLO A MANO: Cuatro vueltas de 4.000 tokens iniciales

Si cada vuelta añade 2.500 tokens, pagáis $4,000 + 6,500 + 9,000 + 11,500 = 31,000$ tokens de entrada, no 4.000.

IDEA CLAVE. La factura crece de forma cuadrática con la longitud de la sesión si no se gestiona el contexto.

Qué está pasando ya en las empresas de vuestro sector.

Expansión · Tecnología

Expansión

La banca española mide ya el gasto en IA por consulta, no por licencia

Los equipos de datos de las grandes entidades han dejado de presupuestar la IA como software y han empezado a hacerlo como infraestructura: coste por token, por usuario y por mes.

Cinco Días · Empresas

CincoDías

El coste por token baja, pero la factura sube: el efecto del agente

Cada agente reenvía su contexto en cada vuelta del bucle. Los equipos que no miden tokens descubren el problema cuando llega la factura del segundo mes.

Lo que un inversor te va a preguntar en el pitch

¿Cuánto te cuesta atender a UN usuario durante un mes?

¿Qué pasa con ese número si creces 10×?

¿Cuál es tu margen si el precio del modelo no baja?

Concepto → aplicación: dónde encaja un agente en una empresa.

Función	Caso concreto	Entradas	KPI
Finanzas	Conciliar extractos bancarios con el ERP.	Extractos + asientos.	% conciliado solo.
Compras	Comparar ofertas de proveedor y resumir diferencias.	PDFs de oferta.	Horas/expediente.
Atención	Responder borradores de tickets con el histórico.	Ticket + base de conocimiento.	% resueltos sin humano.
Riesgos	Revisar contratos y marcar cláusulas atípicas.	Contratos en PDF.	Cláusulas detectadas.
Datos	Explorar un dataset y proponer el primer informe.	CSV de negocio.	Tiempo hasta el insight.

IDEA CLAVE. El patrón común: tareas que mezclan texto, datos y una decisión, repetidas muchas veces al mes.


Parte 2 / 6

El harness y las skills

Date: 10/30/2019				
Period	Subject	Teaching content	Assessment(s) given	Whole class learning (1-5)
1	中文	写作: 故事 (原创)	不太会写	1 2 3 4 5
2	中文	写作: 故事 (原创)	写作: 故事 (原创)	1 2 3 4 5
3	英文	阅读: (1)	阅读: (1)	1 2 3 4 5
4	英文	阅读: (1)	Reading: (1)	1 2 3 4 5
5	英文	阅读: (1)	Reading: (1)	1 2 3 4 5
6	英文	阅读: (1)	Reading: (1)	1 2 3 4 5
7	英文	Reading: (1)	Reading: (1)	1 2 3 4 5
8	英文	Reading: (1)	Reading: (1)	1 2 3 4 5
9	英文	Reading: (1)	Reading: (1)	1 2 3 4 5
Special reports:				
Period	Number of students	Details	Period	Details
1	1	不太会写	1	不太会写
2	1	不太会写	2	不太会写
3	1	不太会写	3	不太会写
4	1	不太会写	4	不太会写
5	1	不太会写	5	不太会写
6	1	不太会写	6	不太会写
7	1	不太会写	7	不太会写
8	1	不太会写	8	不太会写
9	1	不太会写	9	不太会写
Others (please give details):				
Signature of Student: 10/30/2019				
Class teacher's signature:				

El harness: todo lo que rodea al modelo .


El harness: todo lo que rodea al modelo.



Cambiar de modelo mueve la calidad un poco. Cambiar el harness lo mueve todo.

Las seis piezas del harness, una por una.

El harness: todo lo que rodea al modelo.



Cambiar de modelo mueve la calidad un poco. Cambiar el harness lo mueve todo.

System prompt. Quién es el agente, qué convenciones sigue, qué tiene prohibido. Es la pieza con mejor relación coste/efecto de todas.

Bucle. Cuántas vueltas como máximo, qué hacer si una herramienta falla, cuándo parar.

Herramientas. El catálogo de acciones. Cada una con su esquema y su descripción.

Permisos. Qué se ejecuta sin preguntar y qué exige confirmación humana. Aquí vive el riesgo operativo.


Contexto. Qué se le mete en cada turno y qué se poda. El capítulo más caro de la factura.

Memoria. Qué sobrevive al cierre de la sesión: un fichero, una base de datos, nada.

IDEA CLAVE. Dos equipos con el mismo modelo y resultados opuestos: la diferencia está casi siempre en el harness.

El fichero de instrucciones: cinco bloques que valen más que cualquier prompt ingenioso.

El harness: todo lo que rodea al modelo.




Cambiar de modelo mueve la calidad un poco. Cambiar el harness lo mueve todo.

- 1. Rol.** «Eres el asistente de análisis del equipo de riesgos de una aseguradora española.»
- 2. Convenciones.** «Las cifras en euros con separador de miles. Los informes en castellano, registro neutro.»
- 3. Restricciones.** «No escribas en produccion/. No instales dependencias sin preguntar.»
- 4. Contexto del proyecto.** «Los datos están en data/polizas.parquet; el diccionario de campos, en docs/.»
- 5. Política de IA.** «Declara en cada entregable qué parte se generó con IA y conserva los prompts.»

IDEA CLAVE. Se versiona con el repositorio. Si vive en la cabeza de una persona, no existe.

Skills: manuales que el agente abre solo cuando hacen falta.


Skills: manuales que el agente abre solo cuando hacen falta.



El contexto es un presupuesto. Las skills te dejan pagar solo por el manual que estás usando.

Por qué las skills son una decisión económica y no sólo de orden.

Skills: manuales que el agente abre solo cuando hacen falta.



El contexto es un presupuesto. Las skills te dejan pagar solo por el manual que estás usando.

El problema. Una empresa mediana acumula decenas de procedimientos. Metidos todos en el system prompt, se pagan en cada llamada aunque no se usen.

La carga progresiva. El agente ve una línea por skill (nombre y para qué sirve). Cuando la tarea encaja, abre el manual completo.


EJEMPLO A MANO: 18.000 tokens frente a 900

Con 20 skills de 900 tokens, cargarlas todas cuesta 18.000 tokens por llamada. Con carga progresiva se pagan 900 de índice y sólo el manual que toque.

IDEA CLAVE. A 50.000 llamadas al mes y Sonnet 5, esos 17.000 tokens de diferencia son unos 2.550 USD mensuales.

Las barandillas: dónde se pone el humano en el bucle.

Una herramienta es un contrato JSON, no magia.



Regla de reversibilidad. Lo que se deshace con un `git revert` puede ir solo. Lo que sale de la empresa (un correo, un pago, un borrado) pide confirmación.

Tres niveles en la práctica. *Permitir siempre* para leer y buscar; *preguntar* para escribir y ejecutar; *denegar* para lo que nunca debe tocar.

Auditoría. El agente deja traza de cada herramienta que invocó y con qué argumentos. Cuando algo sale mal, se reproduce.

IDEA CLAVE. El permiso se define por la consecuencia de la acción, no por lo lista que parezca la herramienta.

Parte 3 / 6

Arquitecturas y workflows



Cuatro arquitecturas, de la más predecible a la más abierta.


Cuatro arquitecturas, de la más predecible a la más abierta.

(a) Cadena fija — un workflow




Tú decides el orden. El modelo solo rellena cada paso.
Coste predecible, resultado auditable.

(b) Router — elige la rama



Un modelo barato enruta; uno caro solo atiende
lo que de verdad lo necesita.

(c) Orquestador y trabajadores



Paralelizas el trabajo. Multiplicas el gasto por el
número de trabajadores: cada uno recarga su contexto.

(d) Agente autónomo



Máxima capacidad, mínima predictibilidad.
El coste solo se acota poniéndole un límite duro.

Cómo elegir entre las cuatro.


Cuatro arquitecturas, de la más predecible a la más abierta.

(a) Cadena fija — un workflow



Tú decides el orden. El modelo solo rellena cada paso.
Coste predecible, resultado auditable.

(b) Router — elige la rama



Un modelo barato filtra; uno caro solo atiende
lo que de verdad lo necesita.

(c) Orquestador y trabajadores



Paralelizas el trabajo. Multiplicas el gasto por el
número de trabajadores: cada uno recarga su contexto.

(d) Agente autónomo



Máxima capacidad, mínima predictibilidad.
El coste solo se acota poniéndole un límite duro.

Cadena fija. Cuando conocéis los pasos. Coste y latencia predecibles al céntimo. Es la opción correcta mucho más a menudo de lo que parece.

Router. Cuando hay varias ramas conocidas. Un modelo barato clasifica y sólo lo difícil llega al modelo caro: ahorro grande con cambio pequeño.

Orquestador. Cuando la tarea se parte en trozos independientes. Ganáis tiempo de reloj y pagáis el contexto de cada trabajador.

Autónomo. Cuando ni vosotros sabéis los pasos. Máxima capacidad y el único control de coste es un límite duro de tokens.

IDEA CLAVE. Subid un escalón sólo cuando el anterior os haya fallado por una razón concreta.

La mayoría de lo que se vende como «agente» es un workflow.

La mayoría de lo que se vende como «agente» es un workflow.



El criterio de decisión, en una pregunta.

La mayoría de lo que se vende como «agente» es un workflow.



La pregunta. ¿Podéis escribir hoy la lista de pasos que hay que dar? Si podéis, escribidla: sale más barata, más rápida y más fácil de auditar.

Señales de que necesitáis un agente. El número de pasos depende de lo que se encuentre por el camino; hay que reaccionar a resultados intermedios; la tarea se describe por objetivo y no por procedimiento.

Señal de alarma. Si vuestro «agente» siempre llama a las mismas tres herramientas en el mismo orden, habéis pagado de más por un workflow.

IDEA CLAVE. El coste de un workflow se calcula. El de un agente se acota.

Cuatro modos de usar el mismo agente.

Cuatro modos de usar el mismo agente.

Interactivo

```
claude
```

Conversas, ves cada paso,
apruebas lo que toca.

Para:

Explorar, depurar,
aprender el repo.

Plan

```
claude → /plan
```

Te cuenta qué va a hacer
antes de tocar nada.

Para:

Cambios que dan miedo.

No interactivo

```
claude -p "..."
```

Un comando, una respuesta,
sin conversación.

Para:

Scripts, CI, hooks
de git.

Programado

```
cron + claude -p
```

Se ejecuta solo, a su hora,
sin nadie mirando.

Para:

Informes nocturnos,
vigilancia de datos.

Los modos, con la herramienta en la mano.

Cuatro modos de usar el mismo agente.



Cloud. `npm install -g @anthropic-ai/claude-code`, después `claude` dentro del repositorio. Requiere cuenta y crédito.

Libre. `curl -fsSL https://opencode.ai/install | bash` y `opencode -model ollama/qwen2.5-coder:7b`. Cero coste por sesión, calidad menor.

Interactivo. Para explorar y para aprender el repositorio. Veis cada paso y aprobáis lo que toca.

Plan. El agente cuenta qué va a hacer antes de tocar nada. Para cambios que dan miedo.

No interactivo. `claude -p 'revisa este diff'` dentro de un script o de un *hook* de git. Sin conversación.

Programado. El mismo comando bajo `cron`. Informes nocturnos, vigilancia de datos, resúmenes de lunes.


IDEA CLAVE. El modo programado es el que convierte un juguete en infraestructura, y también el que dispara la factura sin que nadie mire.

Parte 4 / 6

El contexto y los datos




El historial se come el presupuesto, y lo pagáis en cada turno.



Las cuatro capas que compiten por la ventana.

El historial se come el presupuesto, y lo pagas en cada turno.



Restricción. Las cuatro capas comparten un único presupuesto de tokens:

$$\underbrace{t_{\text{sys}}}_{\text{fijo}} + \underbrace{t_{\text{skills}}}_{\text{bajo demanda}} + \underbrace{t_{\text{rag}}}_{\text{por consulta}} + \underbrace{t_{\text{hist}}}_{\text{crece}} \leq B$$

Cuál crece. Sólo la última. Las otras tres las controláis vosotros; el historial crece solo mientras el agente trabaja.

Las dos salidas. *Podar* (borrar resultados de herramientas antiguos) o *compactar* (resumir lo anterior). Las dos pierden información; elegid cuál os duele menos.

IDEA CLAVE. Gestionar el contexto es la primera decisión de diseño y la primera partida del presupuesto.

Qué le podéis dar de comer, y lo que ocupa cada cosa.

Qué le puedes dar de comer, y lo que ocupa cada cosa.

Texto plano	Un folio A4 denso	~ 700 tokens
PDF	Memoria anual de 80 páginas	~ 60.000 tokens
Imagen	Una captura de pantalla	hasta ~ 4.800 tokens
CSV / Excel	20.000 filas de ventas	no cabe: va por herramienta
Audio	Reunión de una hora	se transcribe primero
Base de datos	El ERP entero	nunca entra: se consulta

Fondo dorado: entra directo en el contexto.

Fondo blanco: el agente lo toca con una herramienta, no se lo traga entero.

La pregunta de diseño es «¿cuánto me cuesta que quepa, en cada uno de los turnos de la sesión?».

La regla para decidir qué entra en el contexto y qué no.

Qué le puedes dar de comer, y lo que ocupa cada cosa.

Texto plano	Un folio A4 denso	- 700 tokens
PDF	Memoria anual de 80 páginas	- 60.000 tokens
Imagen	Una captura de pantalla	hasta - 4.800 tokens
CSV / Excel	20.000 filas de ventas	no cabe: va por herramienta
Audio	Reunión de una hora	se transcribe primero
Base de datos	El ERP entero	nunca entra: se consulta

Fondo dorado: entra directo en el contexto.

Fondo blanco: el agente lo toca con una herramienta, no se lo traga entero.

La pregunta de diseño es «¿cuánto me cuesta que quepa, en cada uno de los turnos de la sesión?».

Entra en el contexto lo que el modelo necesita *leer entero* para razonar: un contrato, un informe, una captura de pantalla.

Se toca con una herramienta lo que el modelo necesita *consultar*: una tabla de 20.000 filas, el ERP, un índice de documentos.

EJEMPLO A MANO: El error de principiante

Pegar un CSV de 50.000 filas en el prompt. Son unos 2 millones de tokens: no cabe, y si cupiera costaría 6 USD por pregunta con Sonnet 5.


IDEA CLAVE. Si el dato se puede filtrar antes de llegar al modelo, filtradlo antes: cada token que no mandáis es un token que no pagáis.

Parte 5 / 6

Tokens, precio y factura



Qué es exactamente un token, y por qué os lo cobran dos veces.



Entre el modelo más barato y el más caro hay un factor 10. Elegir modelo es, antes que nada, una decisión de presupuesto.

Qué es. Un trozo de texto de entre uno y varios caracteres. En castellano, unas 0,75 palabras por token de media.

Dos contadores. Los tokens de **entrada** (todo lo que le mandáis) y los de **salida** (lo que genera). Se facturan a precios distintos.


Por qué la salida es más cara. Generar exige una pasada del modelo por token. Leer la entrada se paraleliza; escribir la salida es secuencial.

EJEMPLO A MANO: De texto a factura

Un informe de 3 folios son unos 2.000 tokens de salida. Con Opus 5, a 25 USD el millón, son 0,05 USD por informe.


IDEA CLAVE. Todo presupuesto de IA empieza por estimar estos dos números para una consulta típica.

Generar cuesta cinco veces más que leer.



Entre el modelo más barato y el más caro hay un factor 10. Elegir modelo es, antes que nada, una decisión de presupuesto.

La fórmula del coste, término a término.



Entre el modelo más barato y el más caro hay un factor 10. Elegir modelo es, antes que nada, una decisión de presupuesto.

$$C = p_{\text{in}} t_{\text{in}} + p_{\text{out}} t_{\text{out}}$$

$$C_{\text{mes}} = C \cdot N$$

p_{in} precio por token de entrada (USD/MTok $\div 10^6$)

p_{out} precio por token de salida

$t_{\text{in}}, t_{\text{out}}$ tokens de una consulta típica

N consultas al mes

Los cuatro números. Son los únicos que necesitáis para el presupuesto base. Los tres primeros los sabéis; el cuarto es vuestra previsión de negocio.


IDEA CLAVE. Si no sabéis estimar N , no tenéis un problema de IA: tenéis un problema de modelo de negocio.

Tres decisiones, la misma funcionalidad, el 84 % menos de factura.



50.000 consultas/mes de 4.000 tokens de entrada y 400 de salida. Precios a 2026-10-02.

Las tres palancas, explicadas.




1. Bajar de tier. Entre el modelo más caro y el más barato hay un factor 10. Casi ninguna tarea de clasificación necesita el tier alto.

2. Caché de prompt. Lo que se repite entre llamadas (system prompt, instrucciones, documentos fijos) se factura al 10 %. Escribirlo en caché cuesta un 25 % más una sola vez.

3. Batch. Si la respuesta no tiene que llegar ya, la API de lotes descuenta el 50 %. Entrega en menos de una hora casi siempre, 24 como máximo.

IDEA CLAVE. Las tres son compatibles entre sí y ninguna cambia lo que el usuario ve.

Cómo se rompe la caché sin darse cuenta.



La regla. La caché casa por *prefijo exacto*. Un solo byte distinto al principio invalida todo lo que viene detrás.

Los tres asesinos silenciosos. Meter la fecha y hora en el system prompt; generar un identificador aleatorio por petición; serializar un diccionario sin ordenar las claves.


Cómo se comprueba. La respuesta trae un contador de tokens leídos de caché. Si sale cero llamada tras llamada con el mismo prefijo, hay un asesino suelto.

IDEA CLAVE. Lo estable va delante, lo que cambia va detrás. Ese es todo el diseño.


El presupuesto de IA: expectativa y realidad.

El presupuesto de IA: expectativa y realidad.

Lo que pusiste en el Excel



Lo que llegó




Parte 6 / 6

Modelos libres y servidores propios



Qué significa «modelo libre» y cómo se baja uno.



El modelo cuantizado ocupa 42 GB y no se mueve. La caché KV crece con el contexto y con la concurrencia, y es la que te obliga a comprar más tarjetas.

Libre, con matices. Los pesos se descargan y se ejecutan donde queráis. La licencia suele permitir uso comercial con condiciones: leedla antes de construir encima.

Dónde están. Hugging Face es el repositorio de referencia. Familias habituales: Llama (Meta), Qwen (Alibaba), Mistral, DeepSeek, Gemma (Google).


Cómo se prueba en cinco minutos.

```
curl -fsSL https://ollama.com/install.sh | sh
ollama pull qwen2.5:7b
ollama run qwen2.5:7b
```

Cuantización. Reducir la precisión de los pesos de 16 bits a 4. El modelo ocupa un tercio y pierde poca calidad. Q4_K_M es el punto dulce habitual.

IDEA CLAVE. Probarlo en vuestro portátil es gratis. Servirlo a 500 usuarios no lo es, y ahí empieza el cálculo.


Llama 3.3 70B en INT4: los pesos son lo de menos.



El modelo cuantizado ocupa 42 GB y no se mueve. La caché KV crece con el contexto y con la concurrencia, y es la que te obliga a comprar más tarjetas.

Dimensionar un servidor: la fórmula y la trampa.

Llama 3.3 70B en INT4 con 8 peticiones simultáneas: los pesos son lo de menos.



El modelo cuantizado ocupa 42 GB y no se mueve. La caché KV crece con el contexto y con la concurrencia, y es la que te obliga a comprar más tarjetas.

$$\text{VRAM} \approx \underbrace{P \cdot b \cdot (1 + \rho)}_{\text{pesos}} + \underbrace{k \cdot L \cdot c}_{\text{caché KV}}$$

P parámetros (en miles de millones)

b bytes por parámetro: 2 en FP16, 0,6 en INT4

ρ overhead del runtime, $\approx 0,15$

k MB de caché por cada 1.000 tokens (≈ 320)


L contexto servido, en miles de tokens

c peticiones simultáneas

La trampa. Casi todo el mundo calcula sólo el primer término. El segundo crece con el contexto y con la concurrencia, y es el que os obliga a comprar la tercera tarjeta.


IDEA CLAVE. Dimensionad con el contexto y la concurrencia reales, no con los del día de la demo.

El volumen decide si compensa la API o el servidor propio.



Sonnet 5 con 60 % de caché frente a Llama 3.3 70B en INT4. Incluye un cuarto de jornada de MLOps. Precios a 2026-10-02.

Cómo se lee el punto de equilibrio.



Sonnet 5 con 60 % de caché frente a Llama 3.3 70B en INT4. Incluye un cuarto de jornada de MLOps. Precios a 2026-10-02.


Dos curvas distintas. La API es coste *variable* puro: una recta que sale del origen. El servidor es coste *fijo*: una horizontal. Siempre se cortan.

El umbral. $N^* = C_{\text{servidor}} / c_{\text{consulta}}$. En este caso, unas 234.000 consultas al mes.

Lo que inclina la balanza. Apagar el servidor fuera de horario baja la horizontal un 65 %. Activar la caché baja la pendiente de la recta. Las dos mueven el cruce.

IDEA CLAVE. El servidor propio se justifica por volumen sostenido, por residencia del dato o por pesos ajustados; casi nunca por precio a volúmenes de arranque.

Lo que el gráfico no dice: las cuatro partidas que se olvidan.



1. Personal. Un servidor en producción necesita alguien que lo vigile. Un cuarto de jornada de MLOps son unos 1.240 USD al mes, y ya está dentro de la horizontal del gráfico.

2. Redundancia. Una sola tarjeta significa una sola avería hasta la caída del servicio. El doble de tarjetas, el doble de horizontal.

3. Actualización. Los modelos libres mejoran cada pocos meses. Migrar, reevaluar y volver a desplegar es trabajo recurrente.

4. Ocupación. Un servidor cuesta lo mismo al 5 % que al 95 % de uso. La API cuesta cero cuando nadie pregunta.

IDEA CLAVE. Comparad coste total de propiedad contra coste total de propiedad, no precio por token contra precio por hora.


Cuándo elegir cada vía, en una tabla.

Criterio	API de pago	Modelo libre en servidor
Volumen bajo o irregular	Gana: pagáis sólo lo que usáis.	Pagáis la GPU aunque nadie pregunte.
Volumen alto y sostenido	El coste crece sin techo.	Gana a partir del umbral.
Datos que no pueden salir	Requiere acuerdo y revisión legal.	Gana: el dato no sale de casa.
Máxima calidad	Gana: tier alto disponible ya.	Los libres van por detrás.
Equipo pequeño	Gana: cero operación.	Necesitáis MLOps.
Modelo ajustado a lo vuestro	Limitado a lo que ofrezca el proveedor.	Gana: control total de los pesos.

IDEA CLAVE. Lo habitual en una startup: API para arrancar y medir; servidor cuando el volumen y el equipo lo justifiquen.

Lo que os lleváis de este tema.

Dos temas, un hilo: cuánto cuesta lo que construyes.



El coste atraviesa los doce bloques: cada decisión técnica tiene una línea en el presupuesto.

Concepto 1. Un agente es un modelo dentro de un bucle con herramientas y permisos. El harness determina su calidad más que el modelo.

Concepto 2. Workflow cuando conocéis los pasos; agente cuando no. Subir de arquitectura cuesta dinero y predictibilidad.


Concepto 3. El contexto es un presupuesto compartido, y el historial de la sesión es lo único que crece solo.

Concepto 4. Tier, caché y batch son tres palancas independientes que juntas recortan la factura un 84 % sin tocar la funcionalidad.

Concepto 5. El servidor propio se decide por volumen, residencia del dato o pesos propios; se calcula con el punto de equilibrio.

Para la práctica. Montar un agente sobre un repositorio real y medir, con la calculadora, lo que costaría a escala.

Pausa para debatir: ¿dejaríais que un agente mandase un correo a un cliente?



La pregunta. Vuestro agente redacta respuestas a reclamaciones. Funciona bien el 97 % de las veces. ¿Lo dejáis enviar sin revisión humana?

Posición A. Sí, con un modelo de riesgo: enviar solo por debajo de cierto importe y auditar una muestra.

Posición B. No. Un correo a un cliente es irreversible, y el 3 % restante es el que acaba en prensa.

Reglas. Cinco minutos, dos turnos por bando, móviles boca abajo. Yo modero y no participo.

Hasta el Tema B.

RAG, MCP, multi-agente y adaptación.

Eduardo C. Garrido-Merchán

ecgarrido@comillas.edu

