

Día 03 · Tema 1 — Ejercicios: regularización y *learning rate schedules*

1. Dropout con escalado invertido

Consideremos un vector de activaciones $\mathbf{a} = (3,0, -1,0, 2,5, 0,8)$ en una capa intermedia de una red neuronal durante entrenamiento. Se aplica *inverted dropout* con probabilidad de desactivación $p = 0,3$. La máscara binaria muestreada es $\mathbf{m} = (1, 0, 1, 1)$, donde $m_i \sim \text{Bernoulli}(1 - p)$.

La fórmula del *inverted dropout* es

$$\tilde{a}_i = \frac{1}{1-p} m_i a_i.$$

- Calcula el factor de escalado $\frac{1}{1-p}$.
- Aplica la fórmula para obtener el vector de salida $\tilde{\mathbf{a}}$. Indica el valor numérico de cada componente (cuatro decimales).
- Explica por qué el factor $\frac{1}{1-p}$ garantiza que $\mathbb{E}[\tilde{a}_i] = a_i$.

2. Batch Normalization: cálculo paso a paso

Sea un minibatch de cuatro activaciones (una por ejemplo) que llegan a una capa de *Batch Normalization*: $\mathbf{a} = (2,0, 4,0, 6,0, 8,0)$. Los parámetros aprendibles son $\gamma = 1,5$ y $\beta = 0,5$. Se usa $\varepsilon = 10^{-5}$.

- Calcula la media μ_B y la varianza σ_B^2 del minibatch.
- Normaliza cada elemento: $\hat{a}_i = \frac{a_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}$.
- Aplica la transformación afín: $y_i = \gamma \hat{a}_i + \beta$.
- Si hiciéramos $\gamma = \sqrt{\sigma_B^2 + \varepsilon}$ y $\beta = \mu_B$, ¿qué obtendríamos como y_i ?

3. Weight decay: pérdida total y gradiente de regularización

Una red tiene solo tres pesos $\boldsymbol{\theta} = (0,5, -1,2, 0,8)$ y la pérdida de datos actual es $L_{\text{data}} = 2,3$. Se aplica *weight decay* con $\lambda = 0,01$, es decir,

$$L_{\text{total}} = L_{\text{data}} + \lambda \|\boldsymbol{\theta}\|^2.$$

- Calcula $\|\boldsymbol{\theta}\|^2$ y después L_{total} .
- Calcula el gradiente del término de regularización respecto a cada peso: $\frac{\partial(\lambda \|\boldsymbol{\theta}\|^2)}{\partial \theta_i}$.
- Supongamos que el gradiente de L_{data} respecto a θ_1 es $-0,15$. ¿Cuál es el gradiente total $\frac{\partial L_{\text{total}}}{\partial \theta_1}$? Interpreta el signo y la magnitud del término de regularización.

4. Cosine annealing

Usamos *cosine annealing* con $\eta_{\text{máx}} = 0,1$, $\eta_{\text{mín}} = 0,001$ y periodo total $T = 100$ iteraciones:

$$\eta_t = \eta_{\text{mín}} + \frac{1}{2}(\eta_{\text{máx}} - \eta_{\text{mín}}) \left(1 + \cos\left(\frac{\pi t}{T}\right)\right).$$

- Calcula η_t en $t = 0, 25, 50, 75, 100$. Usa que $\cos 0 = 1$, $\cos(\pi/4) \approx 0,7071$, $\cos(\pi/2) = 0$, $\cos(3\pi/4) \approx -0,7071$, $\cos \pi = -1$.
- ¿En qué punto del ciclo la tasa de aprendizaje alcanza exactamente la media $(\eta_{\text{máx}} + \eta_{\text{mín}})/2$? Justifica analíticamente.

5. Step decay

El *step decay schedule* reduce la tasa de aprendizaje multiplicándola por un factor γ cada T épocas:

$$\eta_t = \eta_0 \gamma^{\lfloor t/T \rfloor}.$$

Con $\eta_0 = 0,1$, $\gamma = 0,1$ y $T = 10$:

- Calcula η_t en las épocas $t = 0, 10, 20, 30, 40$.
- ¿A partir de qué época la tasa de aprendizaje es inferior a 10^{-4} ?
- Compara este *schedule* con *cosine annealing*: ¿cuál produce transiciones más suaves? ¿Cuál es más fácil de ajustar en la práctica?

6. Warmup lineal + cosine decay

Un *schedule* habitual en transformers combina una fase de *warmup* lineal con un *cosine decay*:

$$\eta_t = \begin{cases} \eta_{\max} \frac{t}{T_w}, & t < T_w, \\ \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos\left(\frac{\pi(t - T_w)}{T - T_w}\right)\right), & t \geq T_w, \end{cases}$$

con $T_w = 1000$, $T = 10\,000$, $\eta_{\max} = 10^{-3}$ y $\eta_{\min} = 10^{-6}$.

- Calcula η_t en $t = 500, 1000, 5500, 10\,000$.
- Verifica que el *schedule* es continuo en $t = T_w$.
- ¿Por qué se usa *warmup* al inicio del entrenamiento de transformers?

7. Early stopping con paciencia

Durante el entrenamiento se registran las siguientes pérdidas de validación a lo largo de diez épocas:

Época	1	2	3	4	5	6	7	8	9	10
L_{val}	1,50	1,35	1,28	1,30	1,25	1,27	1,29	1,31	1,26	1,28

Se aplica *early stopping* con paciencia $P = 3$: el entrenamiento se detiene si la pérdida de validación no mejora el mejor valor registrado durante P épocas consecutivas.

- Simula el mecanismo época a época: indica en cada una si hay mejora, el valor del contador de paciencia y el mejor L_{val} registrado hasta ese momento.
- ¿En qué época se detiene el entrenamiento? ¿Cuál es el modelo que se conserva?
- Si la paciencia fuera $P = 5$, ¿se detendría el entrenamiento dentro de estas 10 épocas?

8. Gradient clipping por norma

Durante una iteración de entrenamiento, el gradiente calculado es $\mathbf{g} = (3,0, -4,0)$. Se aplica *gradient clipping by norm* con umbral $c = 2,5$: si $\|\mathbf{g}\| > c$, se reescala el gradiente como

$$\mathbf{g}_{\text{clip}} = \mathbf{g} \frac{c}{\|\mathbf{g}\|}.$$

- Calcula $\|\mathbf{g}\|$ y determina si es necesario recortar.
- Calcula $\mathbf{g}_{\text{clip}}$.
- Verifica que $\|\mathbf{g}_{\text{clip}}\| = c$.
- ¿Se conserva la dirección del gradiente original? Justifica.