

Día 04 · Tema 2 — Ejercicios: convolución, pooling y transfer learning

1. Recuento de parámetros: MLP frente a convolución

Considera una imagen de entrada de dimensiones $32 \times 32 \times 3$ (alto $\times$ ancho $\times$ canales RGB). Queremos obtener 16 mapas de características de salida.

- (a) Si utilizamos una capa *fully connected* (MLP) que conecta cada píxel aplanado con cada una de las 16 neuronas de salida, ¿cuántos parámetros tiene la capa (pesos + sesgos)?
- (b) Si utilizamos una capa convolucional con 16 filtros de tamaño 3×3 , ¿cuántos parámetros tiene? Recuerda: $\text{params} = k^2 \cdot C_{\text{in}} \cdot C_{\text{out}} + C_{\text{out}}$.
- (c) ¿Cuántas veces más parámetros tiene la capa MLP respecto a la convolucional? Comenta por qué esta diferencia es relevante para imágenes de mayor resolución.

2. Convolución a mano (1 canal)

Sea la entrada $\mathbf{X} \in \mathbb{R}^{4 \times 4}$ (un solo canal) y el kernel $\mathbf{K} \in \mathbb{R}^{3 \times 3}$:

$$\mathbf{X} = \begin{pmatrix} 1 & 0 & 2 & 1 \\ 3 & 1 & 0 & 2 \\ 2 & 0 & 1 & 3 \\ 1 & 2 & 3 & 0 \end{pmatrix}, \quad \mathbf{K} = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix}.$$

Sin padding ($p = 0$) y con stride $s = 1$:

- (a) ¿Cuáles son las dimensiones del mapa de salida?
- (b) Calcula cada elemento $Y_{i,j} = \sum_u \sum_v X_{i+u, j+v} K_{u,v}$ explícitamente.

3. Dimensiones de salida: conv + pooling

Una red recibe una imagen de $224 \times 224 \times 3$ y aplica las siguientes operaciones en secuencia:

- (a) Convolución con kernel 7×7 , stride $s = 2$ y padding $p = 3$. Calcula las dimensiones espaciales de salida usando

$$H' = \left\lfloor \frac{H + 2p - k}{s} \right\rfloor + 1.$$

- (b) Max-pooling 2×2 con stride 2. ¿Cuáles son las dimensiones finales?
- (c) ¿Reconoces estas operaciones como parte de alguna arquitectura famosa?

4. Convolución multicanal

Ahora la entrada tiene 2 canales y dimensión espacial 3×3 . Un único filtro de salida tiene kernel $2 \times 2 \times 2$ y sesgo $b = 0,5$. Los datos son:

Canal 0 de la entrada:

$$\mathbf{X}^{(0)} = \begin{pmatrix} 1 & 0 & 2 \\ 3 & 1 & 0 \\ 2 & 0 & 1 \end{pmatrix}, \quad \text{Canal 1: } \mathbf{X}^{(1)} = \begin{pmatrix} 0 & 1 & 1 \\ 2 & 0 & 3 \\ 1 & 1 & 0 \end{pmatrix}.$$

Kernel (canal 0) y kernel (canal 1):

$$\mathbf{K}^{(0)} = \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix}, \quad \mathbf{K}^{(1)} = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix}.$$

Calcula el mapa de salida $\mathbf{Y} \in \mathbb{R}^{2 \times 2}$ usando $Y_{i,j} = \sum_c \sum_u \sum_v X_{i+u, j+v}^{(c)} K_{u,v}^{(c)} + b$.

5. Max-pooling a mano

Dado el mapa de características $\mathbf{M} \in \mathbb{R}^{4 \times 4}$:

$$\mathbf{M} = \begin{pmatrix} 1 & 3 & 2 & 4 \\ 5 & 6 & 7 & 8 \\ 3 & 2 & 1 & 0 \\ 9 & 4 & 6 & 5 \end{pmatrix}.$$

- (a) Aplica max-pooling 2×2 con stride 2 y escribe la salida 2×2 .
- (b) ¿Cuántos parámetros entrenables introduce esta capa de pooling?
- (c) Repite el apartado (a) usando average-pooling en lugar de max-pooling.

6. Recuento de parámetros de una arquitectura completa

Considera la siguiente red para clasificar imágenes $32 \times 32 \times 3$ en 10 clases:

Capa	Configuración	Tras capa	Tras pooling
Conv1	$3 \rightarrow 16, k = 3, p = 1, s = 1$	$? \times ? \times 16$	MaxPool 2×2
Conv2	$16 \rightarrow 32, k = 3, p = 1, s = 1$	$? \times ? \times 32$	MaxPool 2×2
FC	$32 \cdot 8 \cdot 8 \rightarrow 10$	—	—

- Completa las dimensiones espaciales tras cada convolución y tras cada max-pool.
- Calcula el número de parámetros de Conv1, Conv2 y FC por separado.
- Calcula el total de parámetros de la red. ¿Qué capa domina el recuento?

7. Bloque residual (ResNet)

En un bloque residual la salida es $y = F(\mathbf{x}; W) + \mathbf{x}$, donde F es la transformación aprendida.

Sea $\mathbf{x} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$ y $F(\mathbf{x}; W) = W\mathbf{x}$ con $W = \begin{pmatrix} 0,5 & -0,3 \\ 0,1 & 0,8 \end{pmatrix}$.

- Calcula $F(\mathbf{x})$.
- Calcula $y = F(\mathbf{x}) + \mathbf{x}$.
- ¿Qué aprende la rama F si la inicializamos cerca de cero? ¿Qué ventaja tiene esto para el entrenamiento de redes profundas?

8. Coste asimétrico: transfer learning en detección de fraude

Un modelo de transfer learning (fine-tuning de las últimas capas de una red preentrenada) se aplica a detección de fraude bancario. Las probabilidades predichas y las etiquetas reales para 4 transacciones son:

Transacción	$\hat{y}$ (prob. fraude)	y (etiqueta real)
1	0,8	1 (fraude)
2	0,7	0 (legítima)
3	0,4	1 (fraude)
4	0,9	1 (fraude)

El banco asigna $c_{FP} = 10$ € (coste de investigar una transacción legítima) y $c_{FN} = 50$ € (coste de no detectar un fraude).

- Usando un umbral de clasificación $\tau = 0,5$, clasifica cada transacción, identifica FP y FN y calcula el coste total.
- Repite con $\tau = 0,75$. ¿Cambia el coste? ¿Qué umbral es preferible dados los costes asimétricos?
- ¿Por qué tiene sentido usar *transfer learning* en este problema en lugar de entrenar una red desde cero? Relaciona tu respuesta con el tamaño típico de los datasets de fraude.