

Día 07 · Tema 2 — Ejercicios: del cuello de botella RNN a la atención

Códigos de examen. Cada ejercicio lleva un distintivo que indica su papel en la evaluación. **VERDE** tipo obligatorio: cae seguro en el examen; dominando todos los verdes se puede alcanzar hasta un 7. **AMARILLO** obligatorio para nota: con verdes y amarillos se cubre hasta un 8. **ROJO** opcional avanzado: necesario para aspirar al 9. **NEGRO** reto: marca la diferencia entre el 9 y el 10.

1. Atención dot-product escalada, paso a paso **VERDE**

Consideremos una única *query* $\mathbf{q} = (2, 1)$, tres *keys* $\mathbf{k}_1 = (1, 0)$, $\mathbf{k}_2 = (0, 1)$, $\mathbf{k}_3 = (1, 1)$ y tres *values* $\mathbf{v}_1 = (10, 0)$, $\mathbf{v}_2 = (0, 20)$, $\mathbf{v}_3 = (5, 5)$, con $d_k = 2$.

- Calcula los *scores* brutos $s_j = \mathbf{q} \cdot \mathbf{k}_j$ para $j = 1, 2, 3$.
- Escala cada *score* dividiéndolo por $\sqrt{d_k} = \sqrt{2} \approx 1,4142$.
- Aplica softmax a los *scores* escalados para obtener los pesos de atención $\alpha_1, \alpha_2, \alpha_3$. Recuerda que

$$\text{softmax}(a, b, c) = \frac{(e^a, e^b, e^c)}{e^a + e^b + e^c}.$$

Valores de referencia: $e^{0,707} \approx 2,028$; $e^{1,414} \approx 4,113$; $e^{2,121} \approx 8,342$.

- Calcula la salida de atención $\text{Att} = \sum_{j=1}^3 \alpha_j \mathbf{v}_j$.

2. Atención con máscara causal **AMARILLO**

Con los mismos datos del ejercicio anterior, supón ahora que la posición 3 queda *enmascarada* (por ejemplo, porque en un modelo autorregresivo aún no se ha generado). Antes de aplicar softmax, se asigna $s_3 \rightarrow -\infty$ (lo que fuerza $e^{s_3} = 0$).

- Recalcula los pesos de atención $\alpha'_1, \alpha'_2, \alpha'_3$.
- Recalcula la salida Att' .
- Compara cualitativamente Att' con la salida sin máscara del ejercicio 1. ¿Hacia qué *value* se desplaza la salida y por qué?

3. Matriz de atención completa **ROJO**

Ahora trabajamos con *dos* queries empaquetadas en la matriz $Q \in \mathbb{R}^{2 \times 2}$, tres *keys* en $K \in \mathbb{R}^{3 \times 2}$ y tres *values* en $V \in \mathbb{R}^{3 \times 2}$:

$$Q = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}, \quad K = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}, \quad V = \begin{pmatrix} 10 & 0 \\ 0 & 20 \\ 5 & 5 \end{pmatrix}.$$

- Calcula el producto QK^T y la matriz escalada $S = QK^T / \sqrt{d_k}$.
- Aplica softmax *por filas* a S para obtener la matriz de pesos $A \in \mathbb{R}^{2 \times 3}$.
Valores de referencia adicionales: $e^0 = 1$; $e^{0,707} \approx 2,028$.
- Calcula la salida $Z = AV \in \mathbb{R}^{2 \times 2}$.
- Comprueba que la primera fila de Z coincide con la respuesta del ejercicio 1.

4. Coste cuadrático de la atención **VERDE**

Un modelo Transformer procesa secuencias de T tokens con $d_k = 64$.

- ¿Cuántas entradas tiene la matriz QK^T cuando $T = 4096$? ¿Cuántos bytes ocupa en FP32 (4 bytes por entrada)? Expresa el resultado en megabytes.
- Repite el cálculo para $T = 512$.
- ¿Cuál es el factor de reducción al pasar de $T = 4096$ a $T = 512$? Relaciona este factor con la complejidad $O(T^2)$ de la atención.

5. Atención aditiva frente a dot-product **ROJO**

La *atención aditiva* (Bahdanau) calcula el *score* como

$$s(\mathbf{q}, \mathbf{k}_j) = \mathbf{v}^T \tanh(W_1 \mathbf{q} + W_2 \mathbf{k}_j),$$

con parámetros aprendibles $W_1, W_2 \in \mathbb{R}^{3 \times 2}$ y $\mathbf{v} \in \mathbb{R}^3$. Usa los mismos $\mathbf{q}, \mathbf{k}_1, \mathbf{k}_2, \mathbf{k}_3$ del ejercicio 1 y los pesos

$$W_1 = W_2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0,5 & 0,5 \end{pmatrix}, \quad \mathbf{v} = (1, 1, -1).$$

- (a) Calcula $s(\mathbf{q}, \mathbf{k}_j)$ para $j = 1, 2, 3$.
Valores de referencia: $\tanh(1) \approx 0,762$; $\tanh(1,5) \approx 0,905$; $\tanh(2) \approx 0,964$; $\tanh(2,5) \approx 0,987$; $\tanh(3) \approx 0,995$.
- (b) Compara los tres *scores* aditivos con los *scores* dot-product brutos ($s_j = \mathbf{q} \cdot \mathbf{k}_j$) del ejercicio 1. ¿Los dos mecanismos inducen el mismo ranking entre keys?
- (c) ¿Cuál de los dos mecanismos es más eficiente computacionalmente y por qué?

6. ¿Por qué dividimos por $\sqrt{d_k}$? NEGRO

Supón que cada componente de $\mathbf{q}$ y de $\mathbf{k}$ se muestrea de forma independiente según $\mathcal{N}(0, 1)$. El *score* bruto es $s = \mathbf{q} \cdot \mathbf{k} = \sum_{i=1}^{d_k} q_i k_i$.

- (a) Calcula $\mathbb{E}[s]$ y $\text{Var}(s)$ en función de d_k .
Pista: cada producto $q_i k_i$ tiene media 0 y varianza 1 (por ser producto de dos normales estándar independientes) y los sumandos son independientes entre sí.
- (b) Particulariza para $d_k = 64$. ¿Cuál es la desviación típica de los *scores*?
- (c) Cuando la desviación típica es grande, las entradas de softmax difieren mucho entre sí y los pesos se concentran en un solo token (softmax “saturado”). Ilustra este efecto calculando $\text{softmax}(8, 0, -8)$. Valores de referencia: $e^8 \approx 2981$; $e^{-8} \approx 0,00034$.
- (d) Ahora divide por $\sqrt{d_k} = 8$ y calcula $\text{softmax}(1, 0, -1)$. Valores de referencia: $e^1 \approx 2,718$; $e^{-1} \approx 0,368$.
- (e) Explica, a la luz de los apartados anteriores, por qué el factor $1/\sqrt{d_k}$ es necesario para que los gradientes de softmax no se desvanezcan durante el entrenamiento.