

Día 08 · Tema 3 — Ejercicios: embeddings y distancia coseno

Qué es esta hoja. El ejercicio del día de la sesión: uno por sesión, y es el único obligatorio. Es el que entra en el examen con el cálculo incluido, y repite el mismo cálculo del ejemplo resuelto en clase con otros números. Basta con hacer ese para seguir el curso con solvencia.

Dónde está lo demás. Los ejercicios de ampliación de esta sesión van en una hoja aparte, *Ampliación*. Son opcionales, no se piden calculados en el examen y de ellos sólo puede preguntarse la idea, a nivel conceptual.

EL EJERCICIO DEL DÍA *obligatorio · entra en el examen*

1. Distancia coseno entre embeddings

El buscador interno de una aseguradora representa cada texto con tres números: cuánto habla de precio, cuánto habla de cobertura y cuánto habla de siniestros. La consulta de un cliente y tres fichas del catálogo son

$$\mathbf{q} = (2, 3, 6), \quad \mathbf{d}_1 = (0, 0, 7), \quad \mathbf{d}_2 = (7, 0, 0), \quad \mathbf{d}_3 = (3, 6, 2).$$

- (a) Calcula la longitud (norma) de los cuatro vectores.
- (b) Calcula el producto escalar de la consulta con cada una de las tres fichas.
- (c) Calcula la similitud coseno $\cos(\mathbf{q}, \mathbf{d}_j) = \frac{\mathbf{q} \cdot \mathbf{d}_j}{\|\mathbf{q}\| \|\mathbf{d}_j\|}$ para $j = 1, 2, 3$.
- (d) Ordena las tres fichas de más a menos relevante. ¿Cuál devuelve el buscador en primer lugar?
- (e) Si multiplicásemos $\mathbf{d}_1$ por 10, ¿cambiaría su similitud coseno con la consulta? Razona la respuesta en una línea.