

## Día 08 · Tema 3 — Ejercicios: embeddings y distancia coseno

### 1. Similitud coseno paso a paso

Dados los vectores  $\mathbf{u} = (1, 2, 3)$  y  $\mathbf{v} = (4, 5, 6)$ :

- Calcula el producto escalar  $\mathbf{u} \cdot \mathbf{v}$ .
- Calcula las normas  $\|\mathbf{u}\|$  y  $\|\mathbf{v}\|$ .
- Calcula la similitud coseno  $\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$ .
- Interpreta el resultado: ¿están estos vectores muy alineados o poco?

### 2. Coseno frente a distancia euclídea

Considera tres vectores en  $\mathbb{R}^3$ :  $\mathbf{a} = (1, 0, 0)$ ,  $\mathbf{b} = (2, 0, 0)$ ,  $\mathbf{c} = (0, 1, 0)$ .

- Calcula  $\cos(\mathbf{a}, \mathbf{b})$  y  $\|\mathbf{a} - \mathbf{b}\|$ .
- Calcula  $\cos(\mathbf{a}, \mathbf{c})$  y  $\|\mathbf{a} - \mathbf{c}\|$ .
- ¿Qué métrica captura la *dirección* y cuál la *magnitud*? ¿En cuál de los dos pares la similitud coseno da un resultado más extremo que la distancia euclídea?

### 3. Aritmética de Word2Vec

Se dan los siguientes embeddings de palabras en  $\mathbb{R}^3$ :

$$\varphi(\text{España}) = (0,8, 0,3, 0,6), \quad \varphi(\text{Madrid}) = (0,9, 0,5, 0,7), \quad \varphi(\text{Francia}) = (0,7, 0,2, 0,8).$$

- Usando la analogía  $\varphi(\text{París}) \approx \varphi(\text{Madrid}) - \varphi(\text{España}) + \varphi(\text{Francia})$ , calcula el vector predicho para París.
- Se proponen tres candidatos:  $\mathbf{c}_1 = (0,8, 0,4, 0,9)$ ,  $\mathbf{c}_2 = (0,5, 0,1, 0,3)$ ,  $\mathbf{c}_3 = (0,9, 0,9, 0,9)$ . Calcula la similitud coseno entre el vector predicho y cada candidato. ¿Cuál es el más cercano?

### 4. Pérdida de negative sampling

En el modelo skip-gram con negative sampling, la función de pérdida para una palabra objetivo  $w_t$  con un contexto positivo  $w_c$  y una muestra negativa  $w_n$  es:

$$\mathcal{L} = \log \sigma(\varphi(w_c) \cdot \varphi(w_t)) + \log \sigma(-\varphi(w_n) \cdot \varphi(w_t)),$$

donde  $\sigma(x) = 1/(1 + e^{-x})$  es la función sigmoide.

Datos:  $\varphi(w_t) = (1, 0)$ ,  $\varphi(w_c) = (0,5, 0,5)$ ,  $\varphi(w_n) = (-0,3, 0,8)$ .

Valores aproximados de la sigmoide:  $\sigma(0,5) \approx 0,622$ ,  $\sigma(-0,5) \approx 0,378$ ,  $\sigma(0,3) \approx 0,574$ ,  $\sigma(-0,3) \approx 0,426$ .

- Calcula los productos escalares  $\varphi(w_c) \cdot \varphi(w_t)$  y  $\varphi(w_n) \cdot \varphi(w_t)$ .
- Evalúa  $\mathcal{L}$  usando los valores aproximados anteriores.
- Interpreta el signo y la magnitud: ¿la pérdida indica un buen o mal estado del modelo?

### 5. Ranking en búsqueda semántica

Un sistema de búsqueda semántica codifica una consulta como  $\mathbf{q} = (1, 0, 1)$  y tiene cuatro documentos indexados:

$$\mathbf{d}_1 = (1, 1, 0), \quad \mathbf{d}_2 = (0, 0, 1), \quad \mathbf{d}_3 = (1, 0, 1), \quad \mathbf{d}_4 = (0,5, 0,5, 0,5).$$

- Calcula  $\cos(\mathbf{q}, \mathbf{d}_j)$  para  $j = 1, 2, 3, 4$ .
- Ordena los documentos de mayor a menor similitud.
- Si el sistema devuelve el *top-2*, ¿qué documentos se recuperan?
- ¿Habría cambiado el ranking si se usara distancia euclídea en lugar de similitud coseno? Justifica brevemente.

## 6. Compromiso dimensionalidad–almacenamiento

Un corpus tiene un vocabulario de  $|V| = 50\,000$  palabras. La matriz de embeddings tiene tamaño  $|V| \times d$ , donde cada parámetro se almacena en FP32 (4 bytes).

- (a) Calcula el número de parámetros y el almacenamiento en MB para  $d = 100$ ,  $d = 300$  y  $d = 768$ .
- (b) Completar la tabla siguiente:

|                       | $d = 100$ | $d = 300$ | $d = 768$ |
|-----------------------|-----------|-----------|-----------|
| Parámetros (millones) |           |           |           |
| Almacenamiento (MB)   |           |           |           |

- (c) ¿Qué factores, más allá del almacenamiento, afectan a la elección de  $d$  en la práctica?

## 7. Mean pooling y similitud de frases

Se tiene una frase de tres tokens con los siguientes embeddings:

$$\mathbf{e}_1 = (1, 2, 0), \quad \mathbf{e}_2 = (0, 1, 3), \quad \mathbf{e}_3 = (2, 0, 1).$$

- (a) Calcula el embedding de la frase por *mean pooling*:  $\bar{\mathbf{e}} = \frac{1}{3}(\mathbf{e}_1 + \mathbf{e}_2 + \mathbf{e}_3)$ .
- (b) Dado otro embedding de frase  $\mathbf{s} = (1, 1, 1)$ , calcula  $\cos(\bar{\mathbf{e}}, \mathbf{s})$ .
- (c) ¿Qué información se pierde con mean pooling respecto a un modelo que genera embeddings contextuales (p. ej. BERT)?