

# Día 11 · Tema 4 — Ejercicios: LLMs, sampling y coste

**Códigos de examen.** Cada ejercicio lleva un distintivo que indica su papel en la evaluación. **VERDE** tipo obligatorio: cae seguro en el examen; dominando todos los verdes se puede alcanzar hasta un 7. **AMARILLO** obligatorio para nota: con verdes y amarillos se cubre hasta un 8. **ROJO** opcional avanzado: necesario para aspirar al 9. **NEGRO** reto: marca la diferencia entre el 9 y el 10.

## 1. Temperature scaling **VERDE**

Un modelo de lenguaje genera, para la posición  $t + 1$ , los logits  $\ell = (2,0; 1,0; 0,5; -1,0)$  correspondientes a cuatro tokens  $\{A, B, C, D\}$ .

La distribución con temperatura  $\tau$  es

$$p_{\tau}(x_i) = \frac{\exp(\ell_i/\tau)}{\sum_j \exp(\ell_j/\tau)}.$$

- Calcula la distribución para  $\tau = 1,0$  (softmax estándar). Muestra los valores de  $\exp(\ell_i)$  y la suma  $Z$ .
- Calcula la distribución para  $\tau = 0,5$ . ¿Qué sucede con la probabilidad del token más probable?
- Calcula la distribución para  $\tau = 2,0$ . ¿Qué sucede ahora?
- Describe con una frase el efecto de  $\tau < 1$  y de  $\tau > 1$  sobre la distribución.

*Pista.* Valores útiles:  $e^2 \approx 7,389$ ,  $e^1 \approx 2,718$ ,  $e^{0,5} \approx 1,649$ ,  $e^{-1} \approx 0,368$ ,  $e^4 \approx 54,60$ ,  $e^{-2} \approx 0,135$ ,  $e^{0,25} \approx 1,284$ ,  $e^{-0,5} \approx 0,607$ .

## 2. Top- $k$ sampling **VERDE**

Partiendo de la distribución obtenida en el Ejercicio 1 con  $\tau = 1,0$ :

- Aplica top- $k$  con  $k = 2$ . ¿Qué tokens sobreviven al truncamiento?
- Calcula las probabilidades renormalizadas de los tokens supervivientes.
- ¿Qué porcentaje de la masa de probabilidad original se ha descartado?

## 3. Top- $p$ (nucleus) sampling **AMARILLO**

Aplica ahora el muestreo top- $p$  con  $p = 0,9$  a la distribución obtenida con  $\tau = 0,7$  y los mismos logits del Ejercicio 1.

- Calcula primero la distribución con  $\tau = 0,7$ . Usa  $\ell_i/0,7$ : los logits escalados son aproximadamente  $(2,857; 1,429; 0,714; -1,429)$ .  
*Pista.*  $e^{2,857} \approx 17,41$ ,  $e^{1,429} \approx 4,173$ ,  $e^{0,714} \approx 2,043$ ,  $e^{-1,429} \approx 0,240$ .
- Ordena los tokens de mayor a menor probabilidad y acumula hasta alcanzar o superar 0,9. ¿Qué tokens forman el nucleus?
- Calcula las probabilidades renormalizadas del nucleus.

## 4. Cálculo de coste de API **VERDE**

Un chatbot de atención al cliente recibe 500 consultas al día. Cada consulta tiene:

| Componente                | Tokens       |
|---------------------------|--------------|
| System prompt             | 800          |
| Historial de conversación | 1 200        |
| Mensaje del usuario       | 100          |
| <b>Total input</b>        | <b>2 100</b> |
| Respuesta media (output)  | 300          |

El modelo utilizado es Claude Sonnet con precios  $p_{\text{in}} = 3 \text{ \$/M tokens}$  y  $p_{\text{out}} = 15 \text{ \$/M tokens}$ . La fórmula de coste es:

$$C = \frac{N_{\text{in}}}{10^6} p_{\text{in}} + \frac{N_{\text{out}}}{10^6} p_{\text{out}}.$$

- Calcula el coste por consulta.
- Calcula el coste diario (500 consultas).
- Calcula el coste mensual (30 días).

## 5. Ahorro con prompt caching **AMARILLO**

El mismo chatbot del Ejercicio 4 implementa *prompt caching*: el system prompt de 800 tokens se almacena en caché y se factura a un precio reducido de  $0,30 \times p_{\text{in}} = 0,90 \text{ \$/M tokens}$ , en lugar del precio completo de  $3 \text{ \$/M}$ .

- Calcula el nuevo coste de entrada por consulta, separando la parte cacheada (800 tokens a 0,90 \$/M) y la parte no cacheada (1 300 tokens a 3 \$/M).
- Calcula el coste total por consulta (entrada + salida).
- Calcula el ahorro mensual respecto al escenario sin caché del Ejercicio 4.
- ¿Qué porcentaje de reducción supone sobre el coste mensual original?

#### 6. Presupuesto de contexto (context budget) ROJO

Un sistema RAG (*Retrieval-Augmented Generation*) opera con un presupuesto de contexto de  $B = 4\,096$  tokens, distribuido así:

| Componente                | Tokens       |
|---------------------------|--------------|
| System prompt             | 500          |
| Historial de conversación | 1 200        |
| Consulta del usuario      | 150          |
| Reserva para la respuesta | 600          |
| <b>Total fijo</b>         | <b>2 450</b> |

El presupuesto restante se destina a fragmentos recuperados de la base de conocimiento, cada uno de 400 tokens.

- ¿Cuántos tokens quedan disponibles para fragmentos?
- ¿Cuántos fragmentos completos caben?
- El equipo de producto necesita incluir 6 fragmentos. ¿Cuántos tokens adicionales se requieren? Propón al menos dos estrategias concretas para liberar ese espacio.

#### 7. Comparación de modelos ROJO

Usando las mismas cifras del chatbot (500 consultas/día, 2 100 tokens de entrada, 300 tokens de salida, 30 días/mes), calcula el coste mensual para cada uno de los siguientes modelos:

| Modelo         | $p_{in}$ (\$/M) | $p_{out}$ (\$/M) |
|----------------|-----------------|------------------|
| Claude Sonnet  | 3,00            | 15,00            |
| GPT-5          | 2,50            | 10,00            |
| Mistral Large  | 2,00            | 6,00             |
| Gemini 1.5 Pro | 1,25            | 5,00             |

- Construye una tabla con el coste mensual de entrada, de salida y total para cada modelo.
- ¿Cuánto se ahorra al mes eligiendo el modelo más barato frente al más caro?
- Comenta brevemente qué factores, además del precio, debería considerar la empresa al elegir modelo.

#### 8. Economía de tokens a escala ROJO

Una empresa procesa 10 000 documentos legales al mes. Cada documento tiene 5 000 tokens de entrada y requiere un resumen de 200 tokens.

- Calcula el total de tokens de entrada y de salida al mes.
- Calcula el coste mensual con Claude Sonnet (3 \$/M entrada, 15 \$/M salida).
- Calcula el coste mensual con Gemini 1.5 Pro (1,25 \$/M entrada, 5 \$/M salida).
- Un empleado humano cobra 3 000 \$/mes y resume 50 documentos al día (22 días laborables, es decir 1 100 documentos/mes). ¿Cuántos empleados se necesitan para los 10 000 documentos? ¿Cuál es el coste humano mensual?
- Calcula el coste por documento en cada caso (IA con Sonnet, IA con Gemini, humano) y el factor de ahorro de la IA frente al humano.