

Día 11 · Tema 4 — Ejercicios: LLMs, sampling y coste

1. Temperature scaling

Un modelo de lenguaje genera, para la posición $t + 1$, los logits $\ell = (2,0; 1,0; 0,5; -1,0)$ correspondientes a cuatro tokens $\{A, B, C, D\}$.

La distribución con temperatura τ es

$$p_{\tau}(x_i) = \frac{\exp(\ell_i/\tau)}{\sum_j \exp(\ell_j/\tau)}.$$

- (a) Calcula la distribución para $\tau = 1,0$ (softmax estándar). Muestra los valores de $\exp(\ell_i)$ y la suma Z .
- (b) Calcula la distribución para $\tau = 0,5$. ¿Qué sucede con la probabilidad del token más probable?
- (c) Calcula la distribución para $\tau = 2,0$. ¿Qué sucede ahora?
- (d) Describe con una frase el efecto de $\tau < 1$ y de $\tau > 1$ sobre la distribución.

Pista. Valores útiles: $e^2 \approx 7,389$, $e^1 \approx 2,718$, $e^{0,5} \approx 1,649$, $e^{-1} \approx 0,368$, $e^4 \approx 54,60$, $e^{-2} \approx 0,135$, $e^{0,25} \approx 1,284$, $e^{-0,5} \approx 0,607$.

2. Top-k sampling

Partiendo de la distribución obtenida en el Ejercicio 1 con $\tau = 1,0$:

- (a) Aplica top- k con $k = 2$. ¿Qué tokens sobreviven al truncamiento?
- (b) Calcula las probabilidades renormalizadas de los tokens supervivientes.
- (c) ¿Qué porcentaje de la masa de probabilidad original se ha descartado?

3. Top-p (nucleus) sampling

Aplica ahora el muestreo top- p con $p = 0,9$ a la distribución obtenida con $\tau = 0,7$ y los mismos logits del Ejercicio 1.

- (a) Calcula primero la distribución con $\tau = 0,7$. Usa $\ell_i/0,7$: los logits escalados son aproximadamente $(2,857; 1,429; 0,714; -1,429)$.
Pista. $e^{2,857} \approx 17,41$, $e^{1,429} \approx 4,173$, $e^{0,714} \approx 2,043$, $e^{-1,429} \approx 0,240$.
- (b) Ordena los tokens de mayor a menor probabilidad y acumula hasta alcanzar o superar 0,9. ¿Qué tokens forman el nucleus?
- (c) Calcula las probabilidades renormalizadas del nucleus.

4. Cálculo de coste de API

Un chatbot de atención al cliente recibe 500 consultas al día. Cada consulta tiene:

Componente	Tokens
System prompt	800
Historial de conversación	1 200
Mensaje del usuario	100
Total input	2 100
Respuesta media (output)	300

El modelo utilizado es Claude Sonnet con precios $p_{\text{in}} = 3 \text{ \$/M tokens}$ y $p_{\text{out}} = 15 \text{ \$/M tokens}$. La fórmula de coste es:

$$C = \frac{N_{\text{in}}}{10^6} p_{\text{in}} + \frac{N_{\text{out}}}{10^6} p_{\text{out}}.$$

- (a) Calcula el coste por consulta.
- (b) Calcula el coste diario (500 consultas).
- (c) Calcula el coste mensual (30 días).

5. Ahorro con prompt caching

El mismo chatbot del Ejercicio 4 implementa *prompt caching*: el system prompt de 800 tokens se almacena en caché y se factura a un precio reducido de $0,30 \times p_{\text{in}} = 0,90 \text{ \$/M tokens}$, en lugar del precio completo de $3 \text{ \$/M}$.

- (a) Calcula el nuevo coste de entrada por consulta, separando la parte cacheada (800 tokens a $0,90 \text{ \$/M}$) y la parte no cacheada (1 300 tokens a $3 \text{ \$/M}$).
- (b) Calcula el coste total por consulta (entrada + salida).
- (c) Calcula el ahorro mensual respecto al escenario sin caché del Ejercicio 4.
- (d) ¿Qué porcentaje de reducción supone sobre el coste mensual original?

6. Presupuesto de contexto (context budget)

Un sistema RAG (*Retrieval-Augmented Generation*) opera con un presupuesto de contexto de $B = 4\,096$ tokens, distribuido así:

Componente	Tokens
System prompt	500
Historial de conversación	1 200
Consulta del usuario	150
Reserva para la respuesta	600
Total fijo	2 450

El presupuesto restante se destina a fragmentos recuperados de la base de conocimiento, cada uno de 400 tokens.

- (a) ¿Cuántos tokens quedan disponibles para fragmentos?
- (b) ¿Cuántos fragmentos completos caben?
- (c) El equipo de producto necesita incluir 6 fragmentos. ¿Cuántos tokens adicionales se requieren? Propón al menos dos estrategias concretas para liberar ese espacio.

7. Comparación de modelos

Usando las mismas cifras del chatbot (500 consultas/día, 2 100 tokens de entrada, 300 tokens de salida, 30 días/mes), calcula el coste mensual para cada uno de los siguientes modelos:

Modelo	p_{in} (\$/M)	p_{out} (\$/M)
Claude Sonnet	3,00	15,00
GPT-5	2,50	10,00
Mistral Large	2,00	6,00
Gemini 1.5 Pro	1,25	5,00

- (a) Construye una tabla con el coste mensual de entrada, de salida y total para cada modelo.
- (b) ¿Cuánto se ahorra al mes eligiendo el modelo más barato frente al más caro?
- (c) Comenta brevemente qué factores, además del precio, debería considerar la empresa al elegir modelo.

8. Economía de tokens a escala

Una empresa procesa 10 000 documentos legales al mes. Cada documento tiene 5 000 tokens de entrada y requiere un resumen de 200 tokens.

- (a) Calcula el total de tokens de entrada y de salida al mes.
- (b) Calcula el coste mensual con Claude Sonnet (3 \$/M entrada, 15 \$/M salida).
- (c) Calcula el coste mensual con Gemini 1.5 Pro (1,25 \$/M entrada, 5 \$/M salida).
- (d) Un empleado humano cobra 3 000 \$/mes y resume 50 documentos al día (22 días laborables, es decir 1 100 documentos/mes). ¿Cuántos empleados se necesitan para los 10 000 documentos? ¿Cuál es el coste humano mensual?
- (e) Calcula el coste por documento en cada caso (IA con Sonnet, IA con Gemini, humano) y el factor de ahorro de la IA frente al humano.