

Día 15 · Tema 6 — Ejercicios: RAG y búsqueda semántica

1. Chunking de un documento

Un documento tiene un total de 2400 tokens. Se aplica chunking con un tamaño de chunk C y un solapamiento O . El número de chunks se calcula como

$$n = \left\lceil \frac{T - O}{C - O} \right\rceil,$$

donde T es el número total de tokens.

- (a) $C = 400$, $O = 0$ (sin solapamiento). ¿Cuántos chunks se generan?
- (b) $C = 400$, $O = 100$. ¿Cuántos chunks se generan? ¿Cuántos tokens cubre el último chunk si no está completamente lleno?
- (c) $C = 600$, $O = 50$. ¿Cuántos chunks se generan?
- (d) Comenta cualitativamente: ¿qué efecto tiene aumentar el solapamiento sobre el número de chunks y sobre la probabilidad de que una idea quede partida entre dos chunks consecutivos?

2. Recuperación por similitud coseno

Un sistema RAG indexa cinco chunks con embeddings en $\mathbb{R}^4$. El embedding de la consulta del usuario es $\mathbf{q} = (1, 0, 1, 0)$ y los embeddings de los chunks son:

$$\mathbf{d}_1 = (1, 1, 0, 0), \quad \mathbf{d}_2 = (0, 0, 1, 1), \quad \mathbf{d}_3 = (1, 0, 1, 1), \quad \mathbf{d}_4 = (0, 1, 0, 1), \quad \mathbf{d}_5 = (1, 0, 0, 0).$$

- (a) Calcula $\cos(\mathbf{q}, \mathbf{d}_j)$ para cada $j = 1, \dots, 5$. Recuerda:

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}.$$

- (b) Ordena los chunks de mayor a menor similitud.
- (c) Si el sistema recupera los top-3, ¿qué chunks se devuelven?

3. Recuperación híbrida: coseno + BM25

Para los mismos cinco chunks del ejercicio anterior, un motor de búsqueda léxica (BM25) asigna las siguientes puntuaciones (ya normalizadas en $[0, 1]$):

$$\text{BM25}(d_1) = 0,8, \quad \text{BM25}(d_2) = 0,3, \quad \text{BM25}(d_3) = 0,5, \quad \text{BM25}(d_4) = 0,9, \quad \text{BM25}(d_5) = 0,2.$$

El sistema híbrido combina ambas señales con

$$s_j = \alpha \cos(\mathbf{q}, \mathbf{d}_j) + (1 - \alpha) \text{BM25}(d_j), \quad \alpha = 0,7.$$

Dado que las similitudes coseno del ejercicio anterior ya están en $[0, 1]$, úsalas directamente (redondea a dos decimales si lo necesitas).

- (a) Calcula s_j para cada chunk.
- (b) Ordena los chunks de mayor a menor puntuación híbrida.
- (c) Compara este ranking con el del ejercicio 2. ¿Qué chunk sube más posiciones gracias a BM25 y cuál baja? ¿Por qué tiene sentido combinar ambas señales?

4. Recall@k y MRR

Los chunks relevantes para la consulta anterior son $\{d_2, d_3\}$ (ground truth proporcionada por un anotador humano). Utiliza el ranking por similitud coseno del ejercicio 2.

- (a) Calcula Recall@1, Recall@3 y Recall@5. Recuerda:

$$\text{Recall}@k = \frac{|\{\text{relevantes}\} \cap \{\text{top-}k \text{ recuperados}\}|}{|\{\text{relevantes}\}|}.$$

- (b) Calcula el MRR (*Mean Reciprocal Rank*). Para una sola consulta, $\text{MRR} = 1/r$, donde r es la posición del primer chunk relevante en el ranking.
- (c) Si en lugar de usar el ranking coseno usamos el ranking híbrido del ejercicio 3, ¿cambian Recall@3 y MRR? Calcula ambas métricas con el nuevo ranking.

5. Coste de un sistema RAG por consulta

Un sistema RAG recupera $k = 5$ chunks de 400 tokens cada uno. El prompt del sistema tiene 300 tokens y la consulta del usuario 50 tokens. La respuesta media del LLM es de 400 tokens. Se usa Claude Sonnet con precios de \$3 por millón de tokens de entrada y \$15 por millón de tokens de salida.

- (a) Calcula el total de tokens de entrada por consulta.
- (b) Calcula el coste por consulta (entrada + salida).
- (c) Si el sistema recibe 1 000 consultas al día, ¿cuál es el coste diario? ¿Y el mensual (30 días)?
- (d) Si se reduce a $k = 3$ (tras un reranking que descarta 2 chunks), ¿cuánto se ahorra al mes?

6. Dimensionado de una base de datos vectorial

Un corpus contiene 100 000 documentos con una media de 2 000 tokens cada uno. Se aplica chunking con $C = 400$ y $O = 100$. Los embeddings tienen dimensión $D = 1024$.

- (a) Calcula el número total de chunks.
- (b) Calcula el almacenamiento necesario para los embeddings en FP32 (4 bytes por float). Expresa el resultado en GB.
- (c) Repite el cálculo con cuantización a int8 (1 byte por float).
- (d) Calcula el tamaño del texto original (1 token $\approx$ 4 bytes) y compara con el almacenamiento de embeddings. ¿Los embeddings ocupan más o menos que el texto?

7. Análisis coste-beneficio del reranking

Sin reranking, un sistema RAG tiene Recall@5 = 0,70, lo que se traduce en un 30 % de respuestas erróneas. Cada respuesta errónea genera una escalación al equipo humano con un coste de \$5. Con un cross-encoder que reordena los top-50 candidatos para seleccionar los top-5, el Recall@5 sube a 0,88 y las respuestas erróneas bajan al 12 %. El cross-encoder tiene un coste computacional adicional de \$0,001 por consulta. El sistema recibe 10 000 consultas al mes.

- (a) Calcula el coste mensual extra por el cross-encoder.
- (b) Calcula el coste mensual de escalaciones *sin* reranking y *con* reranking.
- (c) Calcula el ahorro neto mensual (ahorro en escalaciones menos coste del cross-encoder).
- (d) ¿A partir de cuántas consultas mensuales el reranking deja de ser rentable? (Pista: plantea la ecuación de punto de equilibrio.)