

Día 16 · Tema 6 — Ejercicios: LoRA, RLHF y DPO

Códigos de examen. Cada ejercicio lleva un distintivo que indica su papel en la evaluación. **VERDE** tipo obligatorio: cae seguro en el examen; dominando todos los verdes se puede alcanzar hasta un 7. **AMARILLO** obligatorio para nota: con verdes y amarillos se cubre hasta un 8. **ROJO** opcional avanzado: necesario para aspirar al 9. **NEGRO** reto: marca la diferencia entre el 9 y el 10.

Cómo trabajar la hoja. Cada día hay un único **ejercicio del día** (sin derivadas y representativo): es el imprescindible y basta con hacer ese para seguir el curso. El resto son **ampliaciones ilustrativas**, opcionales pero igualmente representativas, para quien quiera profundizar.

AMPLIACIÓN ILUSTRATIVA opcional · representativo

1. Recuento de parámetros LoRA en un Transformer **VERDE**

Un Transformer tiene dimensión oculta $d = 4096$. En cada capa de atención hay cuatro matrices de proyección W^Q, W^K, W^V, W^O , cada una de tamaño 4096×4096 . Se aplica LoRA con rango $r = 8$ a las cuatro matrices.

Recuerda que LoRA reemplaza el ajuste completo de $W \in \mathbb{R}^{m \times n}$ por

$$W' = W + \frac{\alpha}{r} B A, \quad A \in \mathbb{R}^{r \times n}, \quad B \in \mathbb{R}^{m \times r}.$$

Solo se entrenan A y B ; la matriz original W permanece congelada.

- ¿Cuántos parámetros tiene la capa de atención original (las cuatro matrices, sin contar sesgos)?
- ¿Cuántos parámetros entrenables introduce LoRA en esa misma capa?
- Calcula la razón de compresión (parámetros originales / parámetros LoRA).
- Si el modelo tiene 32 capas y se aplica LoRA a todas, ¿cuántos parámetros LoRA hay en total? ¿Qué porcentaje representan del total original?

EL EJERCICIO DEL DÍA obligatorio · sin derivadas · representativo

2. Forward pass de LoRA (ejemplo numérico) **VERDE**

Sean la matriz original $W \in \mathbb{R}^{2 \times 2}$, los adaptadores LoRA $A \in \mathbb{R}^{1 \times 2}$ y $B \in \mathbb{R}^{2 \times 1}$ (rango $r = 1$), el factor de escala $\alpha = 1$, y el vector de entrada $\mathbf{x}$:

$$W = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad A = (0,1 \quad 0,2), \quad B = \begin{pmatrix} 0,5 \\ 0,3 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

- Calcula $W\mathbf{x}$.
- Calcula el producto $B A \mathbf{x}$ paso a paso.
- Calcula la salida completa $W'\mathbf{x} = W\mathbf{x} + \frac{\alpha}{r} B A \mathbf{x}$.
- Comenta: ¿cuántos parámetros entrenables tiene este adaptador frente a la matriz W completa? ¿Cuál es la naturaleza (rango) de la corrección $\Delta W = B A$?

AMPLIACIÓN ILUSTRATIVA opcional · representativo

3. Ahorro de memoria con LoRA **AMARILLO**

Un LLM de 7 B (7 mil millones) de parámetros en FP16 ocupa 14 GB en memoria.

Supón que las matrices de atención representan aproximadamente $\frac{1}{3}$ de los parámetros totales. Se aplica LoRA con rango $r = 16$ únicamente a esas matrices. Cada matriz original es cuadrada de dimensión $d = 4096$, y LoRA añade $r(d + d) = 2rd$ parámetros por cada una, con una razón de compresión $\frac{d^2}{2rd} = \frac{d}{2r}$.

- ¿Cuántos parámetros de atención tiene el modelo original?
- ¿Cuántos parámetros LoRA se introducen? (Divide los parámetros de atención por la razón de compresión $\frac{d}{2r}$.)
- ¿Cuánta memoria ocupan los adaptadores LoRA en FP16 (2 bytes por parámetro)?
- ¿Qué porcentaje de la memoria del modelo base representan?

AMPLIACIÓN ILUSTRATIVA opcional · representativo

4. Memoria con QLoRA **ROJO**

Partiendo del mismo LLM de 7 B:

- Si se cuantiza el modelo base a 4 bits (0,5 bytes por parámetro), ¿cuántos GB ocupa?
- Añade los adaptadores LoRA del ejercicio anterior (en FP16). ¿Cuál es la memoria total de QLoRA?

- (c) El fine-tuning completo en FP16 necesita almacenar parámetros (14 GB) más estados del optimizador (momentos de Adam $\approx 2 \times$ los parámetros) ≈ 42 GB. ¿Cuántas veces más memoria necesita el fine-tuning completo respecto a QLoRA?

AMPLIACIÓN ILUSTRATIVA *opcional · representativo*

5. Pérdida del modelo de recompensa (Bradley-Terry) **ROJO**

En RLHF, el modelo de recompensa se entrena con la pérdida de Bradley-Terry:

$$\mathcal{L}_{\text{RM}} = -\mathbb{E} \left[\log \sigma(r(x, y_w) - r(x, y_l)) \right],$$

donde y_w es la respuesta preferida, y_l la rechazada, y $\sigma(z) = \frac{1}{1+e^{-z}}$.

- (a) **Caso 1 (preferencia clara):** $r(x, y_w) = 2,5$ y $r(x, y_l) = 1,0$. Calcula la diferencia, aplica σ (usa $\sigma(1,5) \approx 0,818$) y obtén la pérdida.
- (b) **Caso 2 (preferencia ambigua):** $r(x, y_w) = 1,2$ y $r(x, y_l) = 1,0$. Calcula la diferencia, aplica σ (usa $\sigma(0,2) \approx 0,550$) y obtén la pérdida.
- (c) Compara ambas pérdidas. ¿Cuándo le resulta más difícil al modelo aprender las preferencias? ¿Qué implicación tiene para la calidad de las anotaciones humanas?

AMPLIACIÓN ILUSTRATIVA *opcional · representativo*

6. Pérdida DPO **NEGRO**

DPO evita entrenar un modelo de recompensa explícito. Su pérdida es:

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E} \left[\log \sigma \left(\beta \left[\log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{SFT}}(y_w | x)} - \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{SFT}}(y_l | x)} \right] \right) \right].$$

Datos: $\log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{SFT}}(y_w | x)} = 0,5$ y $\log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{SFT}}(y_l | x)} = 0,3$.

- (a) Con $\beta = 0,1$: calcula el argumento de σ , aplica σ (usa $\sigma(0,02) \approx 0,505$) y obtén la pérdida.
- (b) Con $\beta = 1,0$: repite el cálculo (usa $\sigma(0,2) \approx 0,550$).
- (c) Compara las dos pérdidas. ¿Qué controla β ? ¿Qué ocurre si se elige un β demasiado pequeño o demasiado grande?

AMPLIACIÓN ILUSTRATIVA *opcional · representativo*

7. Árbol de decisión cuantitativo: adaptación de un LLM **ROJO**

Una empresa procesa 1 000 facturas al mes mediante un LLM que extrae campos clave (importe, fecha, proveedor). Cada extracción errónea requiere corrección manual con un coste de 20 €. Dispone de 200 facturas etiquetadas.

Se consideran cuatro estrategias de adaptación con las siguientes estimaciones:

Estrategia	Coste inicial	Precisión estimada
(a) Prompt engineering	0 €	70 %
(b) Few-shot (5 ejemplos)	0 €	80 %
(c) LoRA (200 ejemplos)	50 €	92 %
(d) RLHF completo	15 000 €	95 %

- (a) Para cada estrategia, calcula el número de errores mensuales y el coste mensual de corrección.
- (b) Calcula el ahorro mensual de LoRA frente a prompt engineering.
- (c) ¿En cuánto tiempo se amortiza el coste inicial de LoRA?
- (d) ¿En cuánto tiempo se amortiza RLHF frente a prompt engineering? ¿Y frente a LoRA?
- (e) ¿Qué estrategia recomendarías a esta empresa y por qué?