

# Día 02 · Tema 1 — Ampliación: neurona, MLP y backpropagation

**Qué es esta hoja.** Los ejercicios de ampliación de la sesión. Son opcionales y están para enseñar de qué es capaz el método, no para exigir: **no se piden calculados en el examen**. De ellos sólo puede preguntarse la idea, a nivel conceptual.

**Dónde está lo obligatorio.** En la hoja *Ejercicios* de esta misma sesión, que contiene el ejercicio del día: uno por sesión, obligatorio, y el que entra en el examen con el cálculo incluido.

## AMPLIACIÓN *opcional · no se pide calculado en el examen*

### 1. Pase forward por una neurona

Un operador de telecomunicaciones quiere predecir la fuga de clientes. Se dispone de una única neurona con tres entradas:  $x_1 = 24$  (meses de antigüedad),  $x_2 = 80$  (gasto mensual en euros) y  $x_3 = 5$  (llamadas a soporte). Los pesos y el sesgo son

$$\mathbf{w} = (-0,04, 0,02, 0,55), \quad b = -0,50.$$

- Calcula la pre-activación  $z = \mathbf{w}^\top \mathbf{x} + b$ .
- Calcula la salida si la activación es ReLU:  $\text{ReLU}(z) = \max(0, z)$ .
- Calcula la salida si la activación es sigmoide:  $\sigma(z) = \frac{1}{1 + e^{-z}}$ .
- Interpreta el resultado de la sigmoide como probabilidad de fuga. ¿Clasificarías a este cliente como *churn* con un umbral de 0,5?

## AMPLIACIÓN *opcional · no se pide calculado en el examen*

### 2. Pase forward por un MLP de dos capas

Considera un MLP con 2 entradas, 2 neuronas ocultas (activación ReLU) y 1 neurona de salida (activación sigmoide). La entrada es  $\mathbf{x} = (1,0, 2,0)^\top$ . Los parámetros son:

$$W^{(1)} = \begin{pmatrix} 0,3 & -0,5 \\ 0,8 & 0,1 \end{pmatrix}, \quad \mathbf{b}^{(1)} = \begin{pmatrix} -0,1 \\ 0,2 \end{pmatrix}, \quad \mathbf{w}^{(2)} = \begin{pmatrix} 0,6 \\ -0,4 \end{pmatrix}, \quad b^{(2)} = 0,1.$$

- Calcula las pre-activaciones de la capa oculta  $\mathbf{z}^{(1)}$ .
- Aplica ReLU para obtener  $\mathbf{h} = \text{ReLU}(\mathbf{z}^{(1)})$ .
- Calcula la pre-activación de la capa de salida  $z^{(2)}$ .
- Aplica sigmoide para obtener  $\hat{y}$ .
- Si la etiqueta real es  $y = 0$ , ¿es esta una buena predicción?

## AMPLIACIÓN *opcional · no se pide calculado en el examen*

### 3. Entropía cruzada binaria

La entropía cruzada binaria para una observación es

$$\mathcal{L}(\hat{y}, y) = -[y \ln \hat{y} + (1 - y) \ln(1 - \hat{y})].$$

- Calcula  $\mathcal{L}$  para una observación con  $y = 1$ ,  $\hat{y} = 0,82$ .
- Calcula  $\mathcal{L}$  para una observación con  $y = 0$ ,  $\hat{y} = 0,35$ .
- Calcula la pérdida media del mini-batch formado por estas dos observaciones.
- Si en vez de  $\hat{y} = 0,82$  el modelo hubiera predicho  $\hat{y} = 0,99$  para la primera observación, ¿cómo cambia la pérdida? Comenta.

## AMPLIACIÓN *opcional · no se pide calculado en el examen*

### 4. Un paso de SGD

En un instante del entrenamiento, los pesos de una neurona son

$$\mathbf{w} = (1,50, -0,80, 0,30), \quad b = 0,20.$$

Los gradientes calculados para el mini-batch actual son

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = (0,12, -0,35, 0,08), \quad \frac{\partial \mathcal{L}}{\partial b} = 0,15.$$

La tasa de aprendizaje es  $\eta = 0,01$ .

- Escribe la regla de actualización de SGD.
- Calcula los nuevos valores de  $\mathbf{w}$  y  $b$ .
- ¿En qué dirección se mueve cada peso? ¿Tiene sentido?

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

### 5. Backpropagation completo en una red 2-2-1

Considera la red del siguiente diagrama: 2 entradas, 2 neuronas ocultas (ReLU) y 1 neurona de salida (sigmoide) con pérdida de entropía cruzada binaria. La entrada es  $\mathbf{x} = (1, -1)^\top$  y la etiqueta  $y = 1$ . Los parámetros son:

$$\mathbf{W}^{(1)} = \begin{pmatrix} 0,5 & -0,3 \\ 0,2 & 0,4 \end{pmatrix}, \quad \mathbf{b}^{(1)} = \begin{pmatrix} 0,1 \\ -0,1 \end{pmatrix}, \quad \mathbf{w}^{(2)} = \begin{pmatrix} 0,7 \\ -0,5 \end{pmatrix}, \quad b^{(2)} = 0,2.$$

- Realiza el pase forward completo: calcula  $\mathbf{z}^{(1)}$ ,  $\mathbf{h}$ ,  $\mathbf{z}^{(2)}$  y  $\hat{y}$ .
- Calcula la pérdida  $\mathcal{L}$ .
- Calcula la señal de error de salida  $\delta^{(2)} = \hat{y} - y$ .
- Calcula los gradientes de la capa de salida:  $\partial \mathcal{L} / \partial \mathbf{w}_j^{(2)}$  y  $\partial \mathcal{L} / \partial b^{(2)}$ .
- Retropropaga el error a la capa oculta: calcula  $\delta_j^{(1)} = \delta^{(2)} \mathbf{w}_j^{(2)} \text{ReLU}'(z_j^{(1)})$  para  $j = 1, 2$ .
- Calcula todos los gradientes de la capa oculta:  $\partial \mathcal{L} / \partial \mathbf{W}_{jk}^{(1)}$  y  $\partial \mathcal{L} / \partial \mathbf{b}_j^{(1)}$ .
- Comenta qué ocurre con los gradientes de la segunda neurona oculta y por qué.

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

### 6. Un paso de Adam

Se optimiza un parámetro escalar  $\theta$  con Adam. Los hiperparámetros son  $\alpha = 0,01$ ,  $\beta_1 = 0,9$ ,  $\beta_2 = 0,999$ ,  $\varepsilon = 10^{-8}$ . El estado inicial es  $\theta_0 = 2,0$ ,  $m_0 = 0$ ,  $v_0 = 0$ .

- En  $t = 1$  el gradiente es  $g_1 = 0,5$ . Calcula  $m_1$ ,  $v_1$ , sus versiones corregidas  $\hat{m}_1$  y  $\hat{v}_1$ , y el nuevo parámetro  $\theta_1$ .
- En  $t = 2$  el gradiente es  $g_2 = -0,3$ . Repite el cálculo para obtener  $\theta_2$ .
- Observa que en  $t = 1$ , partiendo de  $m_0 = v_0 = 0$ , el tamaño efectivo de paso es  $\alpha$  independientemente de la magnitud del gradiente. Demuéstralo.
- Compara  $\theta_1$  y  $\theta_2$  con los que obtendría SGD simple con la misma tasa  $\alpha$ . ¿Qué efecto tiene el cambio de signo del gradiente en Adam frente a SGD?

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

### 7. Precision, recall y F1 a partir de una matriz de confusión

Un modelo de detección de fraude bancario se evalúa sobre 100 transacciones y produce la siguiente matriz de confusión:

|               | Predicho fraude | Predicho legítimo |
|---------------|-----------------|-------------------|
| Real fraude   | 42              | 8                 |
| Real legítimo | 12              | 38                |

- Identifica TP, FP, FN y TN.
- Calcula precision, recall y F1.
- Calcula la accuracy. ¿Es un buen resumen del rendimiento en este problema? ¿Por qué?
- Si el coste de un falso negativo (fraude no detectado) fuera 10 veces mayor que el de un falso positivo (transacción legítima bloqueada), ¿qué métrica priorizarías?

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

### 8. Selección del umbral que maximiza F1

Un modelo de riesgo crediticio produce las siguientes puntuaciones para 8 clientes, ordenados de mayor a menor probabilidad de impago:

| Ciente    | A    | B    | C    | D    | E    | F    | G    | H    |
|-----------|------|------|------|------|------|------|------|------|
| $\hat{y}$ | 0,91 | 0,73 | 0,62 | 0,55 | 0,44 | 0,38 | 0,31 | 0,15 |
| $y$       | 1    | 1    | 0    | 1    | 0    | 0    | 1    | 0    |

- Para cada umbral  $\tau \in \{0,3, 0,4, 0,5, 0,6, 0,7\}$ , clasifica como positivo si  $\hat{y} \geq \tau$  y calcula precision, recall y F1.

- b) ¿Qué umbral maximiza F1?
- c) ¿Qué umbral maximiza precision? ¿Y recall?
- d) Describe cualitativamente cómo cambiaría la curva ROC al mover el umbral de 0,3 a 0,7.