

## Día 03 · Tema 1 — Ampliación: regularización y *learning rate schedules*

**Qué es esta hoja.** Los ejercicios de ampliación de la sesión. Son opcionales y están para enseñar de qué es capaz el método, no para exigir: **no se piden calculados en el examen**. De ellos sólo puede preguntarse la idea, a nivel conceptual.

**Dónde está lo obligatorio.** En la hoja *Ejercicios* de esta misma sesión, que contiene el ejercicio del día: uno por sesión, obligatorio, y el que entra en el examen con el cálculo incluido.

**AMPLIACIÓN** opcional · no se pide calculado en el examen

### 1. Dropout con escalado invertido

Consideremos un vector de activaciones  $\mathbf{a} = (3,0, -1,0, 2,5, 0,8)$  en una capa intermedia de una red neuronal durante entrenamiento. Se aplica *inverted dropout* con probabilidad de desactivación  $p = 0,3$ . La máscara binaria muestreada es  $\mathbf{m} = (1, 0, 1, 1)$ , donde  $m_i \sim \text{Bernoulli}(1 - p)$ .

La fórmula del *inverted dropout* es

$$\tilde{a}_i = \frac{1}{1 - p} m_i a_i.$$

- Calcula el factor de escalado  $\frac{1}{1 - p}$ .
- Aplica la fórmula para obtener el vector de salida  $\tilde{\mathbf{a}}$ . Indica el valor numérico de cada componente (cuatro decimales).
- Explica por qué el factor  $\frac{1}{1 - p}$  garantiza que  $\mathbb{E}[\tilde{a}_i] = a_i$ .

**AMPLIACIÓN** opcional · no se pide calculado en el examen

### 2. Weight decay: pérdida total y gradiente de regularización

Una red tiene solo tres pesos  $\boldsymbol{\theta} = (0,5, -1,2, 0,8)$  y la pérdida de datos actual es  $L_{\text{data}} = 2,3$ . Se aplica *weight decay* con  $\lambda = 0,01$ , es decir,

$$L_{\text{total}} = L_{\text{data}} + \lambda \|\boldsymbol{\theta}\|^2.$$

- Calcula  $\|\boldsymbol{\theta}\|^2$  y después  $L_{\text{total}}$ .
- Calcula el gradiente del término de regularización respecto a cada peso:  $\frac{\partial(\lambda \|\boldsymbol{\theta}\|^2)}{\partial \theta_i}$ .
- Supongamos que el gradiente de  $L_{\text{data}}$  respecto a  $\theta_1$  es  $-0,15$ . ¿Cuál es el gradiente total  $\frac{\partial L_{\text{total}}}{\partial \theta_1}$ ? Interpreta el signo y la magnitud del término de regularización.

**AMPLIACIÓN** opcional · no se pide calculado en el examen

### 3. Cosine annealing

Usamos *cosine annealing* con  $\eta_{\text{máx}} = 0,1$ ,  $\eta_{\text{mín}} = 0,001$  y periodo total  $T = 100$  iteraciones:

$$\eta_t = \eta_{\text{mín}} + \frac{1}{2}(\eta_{\text{máx}} - \eta_{\text{mín}}) \left(1 + \cos\left(\frac{\pi t}{T}\right)\right).$$

- Calcula  $\eta_t$  en  $t = 0, 25, 50, 75, 100$ . Usa que  $\cos 0 = 1$ ,  $\cos(\pi/4) \approx 0,7071$ ,  $\cos(\pi/2) = 0$ ,  $\cos(3\pi/4) \approx -0,7071$ ,  $\cos \pi = -1$ .
- ¿En qué punto del ciclo la tasa de aprendizaje alcanza exactamente la media  $(\eta_{\text{máx}} + \eta_{\text{mín}})/2$ ? Justifica analíticamente.

**AMPLIACIÓN** opcional · no se pide calculado en el examen

### 4. Step decay

El *step decay schedule* reduce la tasa de aprendizaje multiplicándola por un factor  $\gamma$  cada  $T$  épocas:

$$\eta_t = \eta_0 \gamma^{\lfloor t/T \rfloor}.$$

Con  $\eta_0 = 0,1$ ,  $\gamma = 0,1$  y  $T = 10$ :

- Calcula  $\eta_t$  en las épocas  $t = 0, 10, 20, 30, 40$ .
- ¿A partir de qué época la tasa de aprendizaje es inferior a  $10^{-4}$ ?
- Compara este *schedule* con *cosine annealing*: ¿cuál produce transiciones más suaves? ¿Cuál es más fácil de ajustar en la práctica?

**AMPLIACIÓN** opcional · no se pide calculado en el examen

## 5. Warmup lineal + cosine decay

Un *schedule* habitual en transformers combina una fase de *warmup* lineal con un *cosine decay*:

$$\eta_t = \begin{cases} \eta_{\text{máx}} \frac{t}{T_w}, & t < T_w, \\ \eta_{\text{mín}} + \frac{1}{2}(\eta_{\text{máx}} - \eta_{\text{mín}}) \left(1 + \cos\left(\frac{\pi(t - T_w)}{T - T_w}\right)\right), & t \geq T_w, \end{cases}$$

con  $T_w = 1000$ ,  $T = 10\,000$ ,  $\eta_{\text{máx}} = 10^{-3}$  y  $\eta_{\text{mín}} = 10^{-6}$ .

- Calcula  $\eta_t$  en  $t = 500, 1000, 5500, 10\,000$ .
- Verifica que el *schedule* es continuo en  $t = T_w$ .
- ¿Por qué se usa *warmup* al inicio del entrenamiento de transformers?

**AMPLIACIÓN** opcional · no se pide calculado en el examen

## 6. Early stopping con paciencia

Durante el entrenamiento se registran las siguientes pérdidas de validación a lo largo de diez épocas:

| Época            | 1    | 2    | 3    | 4    | 5    | 6    | 7    | 8    | 9    | 10   |
|------------------|------|------|------|------|------|------|------|------|------|------|
| $L_{\text{val}}$ | 1,50 | 1,35 | 1,28 | 1,30 | 1,25 | 1,27 | 1,29 | 1,31 | 1,26 | 1,28 |

Se aplica *early stopping* con paciencia  $P = 3$ : el entrenamiento se detiene si la pérdida de validación no mejora el mejor valor registrado durante  $P$  épocas consecutivas.

- Simula el mecanismo época a época: indica en cada una si hay mejora, el valor del contador de paciencia y el mejor  $L_{\text{val}}$  registrado hasta ese momento.
- ¿En qué época se detiene el entrenamiento? ¿Cuál es el modelo que se conserva?
- Si la paciencia fuera  $P = 5$ , ¿se detendría el entrenamiento dentro de estas 10 épocas?

**AMPLIACIÓN** opcional · no se pide calculado en el examen

## 7. Gradient clipping por norma

Durante una iteración de entrenamiento, el gradiente calculado es  $\mathbf{g} = (3,0, -4,0)$ . Se aplica *gradient clipping by norm* con umbral  $c = 2,5$ : si  $\|\mathbf{g}\| > c$ , se reescala el gradiente como

$$\mathbf{g}_{\text{clip}} = \mathbf{g} \frac{c}{\|\mathbf{g}\|}.$$

- Calcula  $\|\mathbf{g}\|$  y determina si es necesario recortar.
- Calcula  $\mathbf{g}_{\text{clip}}$ .
- Verifica que  $\|\mathbf{g}_{\text{clip}}\| = c$ .
- ¿Se conserva la dirección del gradiente original? Justifica.