

## Día 07 · Tema 2 — Ampliación: del cuello de botella RNN a la atención

**Qué es esta hoja.** Los ejercicios de ampliación de la sesión. Son opcionales y están para enseñar de qué es capaz el método, no para exigir: **no se piden calculados en el examen**. De ellos sólo puede preguntarse la idea, a nivel conceptual.

**Dónde está lo obligatorio.** En la hoja *Ejercicios* de esta misma sesión. De este tema el examen no pide ningún cálculo, así que el obligatorio del día es conceptual y el cálculo completo de la atención vive aquí, en esta hoja.

### AMPLIACIÓN opcional · no se pide calculado en el examen

#### 1. Atención dot-product escalada, paso a paso

Consideremos una única *query*  $\mathbf{q} = (2, 1)$ , tres *keys*  $\mathbf{k}_1 = (1, 0)$ ,  $\mathbf{k}_2 = (0, 1)$ ,  $\mathbf{k}_3 = (1, 1)$  y tres *values*  $\mathbf{v}_1 = (10, 0)$ ,  $\mathbf{v}_2 = (0, 20)$ ,  $\mathbf{v}_3 = (5, 5)$ , con  $d_k = 2$ .

- Calcula los *scores* brutos  $s_j = \mathbf{q} \cdot \mathbf{k}_j$  para  $j = 1, 2, 3$ .
- Escala cada *score* dividiéndolo por  $\sqrt{d_k} = \sqrt{2} \approx 1,4142$ .
- Aplica softmax a los *scores* escalados para obtener los pesos de atención  $\alpha_1, \alpha_2, \alpha_3$ . Recuerda que

$$\text{softmax}(a, b, c) = \frac{(e^a, e^b, e^c)}{e^a + e^b + e^c}.$$

Valores de referencia:  $e^{0,707} \approx 2,028$ ;  $e^{1,414} \approx 4,113$ ;  $e^{2,121} \approx 8,342$ .

- Calcula la salida de atención  $\text{Att} = \sum_{j=1}^3 \alpha_j \mathbf{v}_j$ .

### AMPLIACIÓN opcional · no se pide calculado en el examen

#### 2. Atención con máscara causal

Con los mismos datos del ejercicio anterior, supón ahora que la posición 3 queda *enmascarada* (por ejemplo, porque en un modelo autorregresivo aún no se ha generado). Antes de aplicar softmax, se asigna  $s_3 \rightarrow -\infty$  (lo que fuerza  $e^{s_3} = 0$ ).

- Recalcula los pesos de atención  $\alpha'_1, \alpha'_2, \alpha'_3$ .
- Recalcula la salida  $\text{Att}'$ .
- Compara cualitativamente  $\text{Att}'$  con la salida sin máscara del ejercicio 1. ¿Hacia qué *value* se desplaza la salida y por qué?

### AMPLIACIÓN opcional · no se pide calculado en el examen

#### 3. Matriz de atención completa

Ahora trabajamos con *dos* queries empaquetadas en la matriz  $Q \in \mathbb{R}^{2 \times 2}$ , tres *keys* en  $K \in \mathbb{R}^{3 \times 2}$  y tres *values* en  $V \in \mathbb{R}^{3 \times 2}$ :

$$Q = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}, \quad K = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}, \quad V = \begin{pmatrix} 10 & 0 \\ 0 & 20 \\ 5 & 5 \end{pmatrix}.$$

- Calcula el producto  $QK^T$  y la matriz escalada  $S = QK^T / \sqrt{d_k}$ .
- Aplica softmax *por filas* a  $S$  para obtener la matriz de pesos  $A \in \mathbb{R}^{2 \times 3}$ .  
Valores de referencia adicionales:  $e^0 = 1$ ;  $e^{0,707} \approx 2,028$ .
- Calcula la salida  $Z = AV \in \mathbb{R}^{2 \times 2}$ .
- Comprueba que la primera fila de  $Z$  coincide con la respuesta del ejercicio 1.

### AMPLIACIÓN opcional · no se pide calculado en el examen

#### 4. Coste cuadrático de la atención

Un modelo Transformer procesa secuencias de  $T$  tokens con  $d_k = 64$ .

- ¿Cuántas entradas tiene la matriz  $QK^T$  cuando  $T = 4096$ ? ¿Cuántos bytes ocupa en FP32 (4 bytes por entrada)?  
Expresa el resultado en megabytes.
- Repite el cálculo para  $T = 512$ .
- ¿Cuál es el factor de reducción al pasar de  $T = 4096$  a  $T = 512$ ? Relaciona este factor con la complejidad  $O(T^2)$  de la atención.

### AMPLIACIÓN opcional · no se pide calculado en el examen

## 5. Atención aditiva frente a dot-product

La *atención aditiva* (Bahdanau) calcula el *score* como

$$s(\mathbf{q}, \mathbf{k}_j) = \mathbf{v}^\top \tanh(W_1 \mathbf{q} + W_2 \mathbf{k}_j),$$

con parámetros aprendibles  $W_1, W_2 \in \mathbb{R}^{3 \times 2}$  y  $\mathbf{v} \in \mathbb{R}^3$ . Usa los mismos  $\mathbf{q}, \mathbf{k}_1, \mathbf{k}_2, \mathbf{k}_3$  del ejercicio 1 y los pesos

$$W_1 = W_2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0,5 & 0,5 \end{pmatrix}, \quad \mathbf{v} = (1, 1, -1).$$

- (a) Calcula  $s(\mathbf{q}, \mathbf{k}_j)$  para  $j = 1, 2, 3$ .  
Valores de referencia:  $\tanh(1) \approx 0,762$ ;  $\tanh(1,5) \approx 0,905$ ;  $\tanh(2) \approx 0,964$ ;  $\tanh(2,5) \approx 0,987$ ;  $\tanh(3) \approx 0,995$ .
- (b) Compara los tres *scores* aditivos con los *scores* dot-product brutos ( $s_j = \mathbf{q} \cdot \mathbf{k}_j$ ) del ejercicio 1. ¿Los dos mecanismos inducen el mismo ranking entre keys?
- (c) ¿Cuál de los dos mecanismos es más eficiente computacionalmente y por qué?

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

## 6. ¿Por qué dividimos por $\sqrt{d_k}$ ?

Supón que cada componente de  $\mathbf{q}$  y de  $\mathbf{k}$  se muestrea de forma independiente según  $\mathcal{N}(0, 1)$ . El *score* bruto es  $s = \mathbf{q} \cdot \mathbf{k} = \sum_{i=1}^{d_k} q_i k_i$ .

- (a) Calcula  $\mathbb{E}[s]$  y  $\text{Var}(s)$  en función de  $d_k$ .  
*Pista:* cada producto  $q_i k_i$  tiene media 0 y varianza 1 (por ser producto de dos normales estándar independientes) y los sumandos son independientes entre sí.
- (b) Particulariza para  $d_k = 64$ . ¿Cuál es la desviación típica de los *scores*?
- (c) Cuando la desviación típica es grande, las entradas de softmax difieren mucho entre sí y los pesos se concentran en un solo token (softmax “saturado”). Ilustra este efecto calculando  $\text{softmax}(8, 0, -8)$ . Valores de referencia:  $e^8 \approx 2981$ ;  $e^{-8} \approx 0,00034$ .
- (d) Ahora divide por  $\sqrt{d_k} = 8$  y calcula  $\text{softmax}(1, 0, -1)$ . Valores de referencia:  $e^1 \approx 2,718$ ;  $e^{-1} \approx 0,368$ .
- (e) Explica, a la luz de los apartados anteriores, por qué el factor  $1/\sqrt{d_k}$  es necesario para que los gradientes de softmax no se desvanezcan durante el entrenamiento.