

Día 08 · Tema 3 — Ampliación: embeddings y distancia coseno

Qué es esta hoja. Los ejercicios de ampliación de la sesión. Son opcionales y están para enseñar de qué es capaz el método, no para exigir: **no se piden calculados en el examen**. De ellos sólo puede preguntarse la idea, a nivel conceptual.

Dónde está lo obligatorio. En la hoja *Ejercicios* de esta misma sesión, que contiene el ejercicio del día: uno por sesión, obligatorio, y el que entra en el examen con el cálculo incluido.

AMPLIACIÓN *opcional · no se pide calculado en el examen*

1. Aritmética de Word2Vec

Se dan los siguientes embeddings de palabras en $\mathbb{R}^3$:

$$\varphi(\text{España}) = (0,8, 0,3, 0,6), \quad \varphi(\text{Madrid}) = (0,9, 0,5, 0,7), \quad \varphi(\text{Francia}) = (0,7, 0,2, 0,8).$$

- (a) Usando la analogía $\varphi(\text{París}) \approx \varphi(\text{Madrid}) - \varphi(\text{España}) + \varphi(\text{Francia})$, calcula el vector predicho para París.
- (b) Se proponen tres candidatos: $\mathbf{c}_1 = (0,8, 0,4, 0,9)$, $\mathbf{c}_2 = (0,5, 0,1, 0,3)$, $\mathbf{c}_3 = (0,9, 0,9, 0,9)$. Calcula la similitud coseno entre el vector predicho y cada candidato. ¿Cuál es el más cercano?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

2. Similitud coseno paso a paso

Dados los vectores $\mathbf{u} = (1, 2, 3)$ y $\mathbf{v} = (4, 5, 6)$:

- (a) Calcula el producto escalar $\mathbf{u} \cdot \mathbf{v}$.
- (b) Calcula las normas $\|\mathbf{u}\|$ y $\|\mathbf{v}\|$.
- (c) Calcula la similitud coseno $\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$.
- (d) Interpreta el resultado: ¿están estos vectores muy alineados o poco?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

3. Coseno frente a distancia euclídea

Considera tres vectores en $\mathbb{R}^3$: $\mathbf{a} = (1, 0, 0)$, $\mathbf{b} = (2, 0, 0)$, $\mathbf{c} = (0, 1, 0)$.

- (a) Calcula $\cos(\mathbf{a}, \mathbf{b})$ y $\|\mathbf{a} - \mathbf{b}\|$.
- (b) Calcula $\cos(\mathbf{a}, \mathbf{c})$ y $\|\mathbf{a} - \mathbf{c}\|$.
- (c) ¿Qué métrica captura la *dirección* y cuál la *magnitud*? ¿En cuál de los dos pares la similitud coseno da un resultado más extremo que la distancia euclídea?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

4. Pérdida de negative sampling

En el modelo skip-gram con negative sampling, la función de pérdida para una palabra objetivo w_t con un contexto positivo w_c y una muestra negativa w_n es:

$$\mathcal{L} = \log \sigma(\varphi(w_c) \cdot \varphi(w_t)) + \log \sigma(-\varphi(w_n) \cdot \varphi(w_t)),$$

donde $\sigma(x) = 1/(1 + e^{-x})$ es la función sigmoide.

Datos: $\varphi(w_t) = (1, 0)$, $\varphi(w_c) = (0,5, 0,5)$, $\varphi(w_n) = (-0,3, 0,8)$.

Valores aproximados de la sigmoide: $\sigma(0,5) \approx 0,622$, $\sigma(-0,5) \approx 0,378$, $\sigma(0,3) \approx 0,574$, $\sigma(-0,3) \approx 0,426$.

- (a) Calcula los productos escalares $\varphi(w_c) \cdot \varphi(w_t)$ y $\varphi(w_n) \cdot \varphi(w_t)$.
- (b) Evalúa $\mathcal{L}$ usando los valores aproximados anteriores.
- (c) Interpreta el signo y la magnitud: ¿la pérdida indica un buen o mal estado del modelo?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

5. Ranking en búsqueda semántica

Un sistema de búsqueda semántica codifica una consulta como $\mathbf{q} = (1, 0, 1)$ y tiene cuatro documentos indexados:

$$\mathbf{d}_1 = (1, 1, 0), \quad \mathbf{d}_2 = (0, 0, 1), \quad \mathbf{d}_3 = (1, 0, 1), \quad \mathbf{d}_4 = (0, 5, 0, 5).$$

- (a) Calcula $\cos(\mathbf{q}, \mathbf{d}_j)$ para $j = 1, 2, 3, 4$.
- (b) Ordena los documentos de mayor a menor similitud.
- (c) Si el sistema devuelve el *top-2*, ¿qué documentos se recuperan?
- (d) ¿Habría cambiado el ranking si se usara distancia euclídea en lugar de similitud coseno? Justifica brevemente.

AMPLIACIÓN *opcional · no se pide calculado en el examen*

6. Compromiso dimensionalidad–almacenamiento

Un corpus tiene un vocabulario de $|V| = 50\,000$ palabras. La matriz de embeddings tiene tamaño $|V| \times d$, donde cada parámetro se almacena en FP32 (4 bytes).

- (a) Calcula el número de parámetros y el almacenamiento en MB para $d = 100$, $d = 300$ y $d = 768$.
- (b) Completar la tabla siguiente:

	$d = 100$	$d = 300$	$d = 768$
Parámetros (millones)			
Almacenamiento (MB)			

- (c) ¿Qué factores, más allá del almacenamiento, afectan a la elección de d en la práctica?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

7. Mean pooling y similitud de frases

Se tiene una frase de tres tokens con los siguientes embeddings:

$$\mathbf{e}_1 = (1, 2, 0), \quad \mathbf{e}_2 = (0, 1, 3), \quad \mathbf{e}_3 = (2, 0, 1).$$

- (a) Calcula el embedding de la frase por *mean pooling*: $\bar{\mathbf{e}} = \frac{1}{3}(\mathbf{e}_1 + \mathbf{e}_2 + \mathbf{e}_3)$.
- (b) Dado otro embedding de frase $\mathbf{s} = (1, 1, 1)$, calcula $\cos(\bar{\mathbf{e}}, \mathbf{s})$.
- (c) ¿Qué información se pierde con mean pooling respecto a un modelo que genera embeddings contextuales (p. ej. BERT)?