

Día 09 · Tema 3 — Ampliación: self-attention y Transformer

Qué es esta hoja. Los ejercicios de ampliación de la sesión. Son opcionales y están para enseñar de qué es capaz el método, no para exigir: **no se piden calculados en el examen**. De ellos sólo puede preguntarse la idea, a nivel conceptual.

Dónde está lo obligatorio. En la hoja *Ejercicios* de esta misma sesión, que contiene el ejercicio del día: uno por sesión, obligatorio, y el que entra en el examen con el cálculo incluido.

Estos ejercicios son de cálculo analítico (lápiz y papel). Todos los resultados numéricos deben obtenerse paso a paso; se proporcionan los valores de referencia de las exponenciales necesarias para que el cálculo sea factible sin calculadora científica.

AMPLIACIÓN *opcional · no se pide calculado en el examen*

1. Self-attention desde cero (3 tokens, $d=2$)

Considera una secuencia de $T=3$ tokens con embeddings de dimensión $d=2$, recogidos en la matriz

$$X = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix},$$

donde cada fila es un token. Las matrices de proyección son

$$W^Q = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad W^K = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad W^V = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}.$$

- (a) Calcula las proyecciones $Q = XW^Q$, $K = XW^K$, $V = XW^V$.
- (b) Calcula la matriz de puntuaciones $S = QK^T / \sqrt{d_k}$ con $d_k = 2$.
- (c) Aplica softmax por filas para obtener la matriz de atención A . Utiliza los siguientes valores de referencia:

$$e^0 = 1, \quad \alpha = e^{1/\sqrt{2}} \approx 2,0281, \quad \alpha^2 = e^{\sqrt{2}} \approx 4,1133.$$

- (d) Calcula la salida $Z' = AV$.
- (e) Interpreta los pesos de atención: ¿a qué token presta más atención cada token? ¿Por qué?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

2. Conteo de parámetros: Multi-Head Attention

Considera un modelo con dimensión $d = 512$ y $H = 8$ cabezas de atención. Las proyecciones por cabeza son $W_h^Q, W_h^K, W_h^V \in \mathbb{R}^{d \times d_k}$ y la proyección de salida es $W^O \in \mathbb{R}^{d \times d}$. No consideres sesgos (biases).

- (a) ¿Cuánto vale $d_k = d/H$?
- (b) ¿Cuántos parámetros tiene cada proyección W_h^Q de una cabeza?
- (c) ¿Cuántos parámetros suman las tres proyecciones (W_h^Q, W_h^K, W_h^V) de una cabeza?
- (d) ¿Cuántos parámetros suman las proyecciones de las H cabezas?
- (e) ¿Cuántos parámetros tiene W^O ?
- (f) ¿Cuál es el total de parámetros del bloque MHA? Exprésalo también en función de d .

AMPLIACIÓN *opcional · no se pide calculado en el examen*

3. Conteo de parámetros: bloque Transformer completo (BERT-base)

Considera la arquitectura BERT-base: $d = 768$, $H = 12$ cabezas, MLP con expansión $\times 4$ (es decir, $d_{\text{ff}} = 4d = 3072$), y $N = 12$ bloques. Cada bloque consta de:

$$X' = X + \text{MHA}(\text{LN}(X)), \quad Z = X' + \text{MLP}(\text{LN}(X')),$$

con $\text{MLP} = \text{Linear}(d, 4d) \rightarrow \text{GELU} \rightarrow \text{Linear}(4d, d)$.

- (a) Calcula los parámetros del bloque MHA (sin sesgos): $4d^2$ (tres proyecciones de entrada más W^O).
- (b) Calcula los parámetros del MLP (sin sesgos): $\text{Linear}(d, 4d)$ y $\text{Linear}(4d, d)$.
- (c) Calcula los parámetros de las dos capas LayerNorm. Cada LayerNorm tiene un vector de escala γ y uno de desplazamiento β , ambos de dimensión d .

- (d) Suma para obtener el total por bloque. Exprésalo como $12d^2 + 4d$.
- (e) Multiplica por $N = 12$ bloques. ¿Cuántos millones de parámetros resultan solo en los bloques Transformer (sin contar embeddings)?

AMPLIACIÓN opcional · no se pide calculado en el examen

4. Positional encoding sinusoidal

La codificación posicional del Transformer original se define como

$$P_{t,2i} = \sin(t/10000^{2i/d}), \quad P_{t,2i+1} = \cos(t/10000^{2i/d}).$$

Toma $d = 4$, de modo que las cuatro dimensiones de cada posición son:

$$\underbrace{\sin(t)}_{\text{dim 0}}, \quad \underbrace{\cos(t)}_{\text{dim 1}}, \quad \underbrace{\sin(t/100)}_{\text{dim 2}}, \quad \underbrace{\cos(t/100)}_{\text{dim 3}}.$$

- (a) Completa la tabla de codificación posicional para $t = 0, 1, 2, 3$, usando los valores de referencia:

t	$\sin(t)$	$\cos(t)$	$\sin(t/100)$	$\cos(t/100)$
0	0,0000	1,0000	0,0000	1,0000
1	0,8415	0,5403	0,0100	0,9999
2	0,9093	-0,4161	0,0200	0,9998
3	0,1411	-0,9900	0,0300	0,9996

- (b) Dada la matriz de embeddings

$$X = \begin{pmatrix} 0,5 & 0,3 & -0,1 & 0,2 \\ 0,1 & -0,4 & 0,6 & 0,0 \\ -0,2 & 0,7 & 0,3 & -0,5 \\ 0,8 & 0,1 & -0,3 & 0,4 \end{pmatrix},$$

calcula $X + P$ (la entrada al primer bloque Transformer).

- (c) Observa las columnas 2 y 3 (las dimensiones de baja frecuencia). ¿Qué diferencia hay en su comportamiento respecto de las columnas 0 y 1? ¿Qué implicación tiene esto para posiciones lejanas ($t = 500$ frente a $t = 501$)?

AMPLIACIÓN opcional · no se pide calculado en el examen

5. Coste computacional de la atención

Considera una capa de atención con T tokens, dimensión del modelo $d = 512$, $d_k = 64$ y $H = 8$ cabezas.

- (a) Para una cabeza, calcula el número de operaciones en coma flotante (FLOPs) del producto QK^T , donde $Q, K \in \mathbb{R}^{T \times d_k}$. Usa la aproximación $\text{FLOPs} \approx 2T^2 d_k$. Evalúa para $T = 1024$.
- (b) Calcula la memoria necesaria para almacenar la matriz de atención $A \in \mathbb{R}^{T \times T}$ en FP32 (4 bytes por elemento). ¿Y para las $H = 8$ cabezas simultáneamente? Evalúa para $T = 1024$.
- (c) Repite los cálculos para $T = 8192$. ¿Cuál es el factor de incremento en FLOPs y en memoria respecto de $T = 1024$? Justifica el resultado en función de la complejidad $O(T^2)$.

AMPLIACIÓN opcional · no se pide calculado en el examen

6. Conexiones residuales: preservación de la información

Considera un token con representación $\mathbf{x} = (1, 2)$ a la entrada de un bloque Transformer. Supón que los sub-bloques producen:

$$\text{MHA}(\text{LN}(\mathbf{x})) = (0,3, -0,1), \quad \text{MLP}(\text{LN}(\mathbf{x}')) = (0,5, 0,2).$$

- (a) Calcula $\mathbf{x}' = \mathbf{x} + \text{MHA}(\text{LN}(\mathbf{x}))$.
- (b) Calcula $\mathbf{z} = \mathbf{x}' + \text{MLP}(\text{LN}(\mathbf{x}'))$.
- (c) Expresa $\mathbf{z}$ como la suma de tres términos: la representación original $\mathbf{x}$, la corrección de atención y la corrección del MLP.
- (d) ¿Qué ocurriría si no existieran las conexiones residuales y el bloque simplemente aplicara $\mathbf{z} = \text{MLP}(\text{MHA}(\mathbf{x}))$? Reflexiona sobre la preservación de la información original y el problema del desvanecimiento del gradiente.