

Día 12 · Tema 4 — Ampliación: difusión y modelos multimodales

Qué es esta hoja. Los ejercicios de ampliación de la sesión. Son opcionales y están para enseñar de qué es capaz el método, no para exigir: **no se piden calculados en el examen**. De ellos sólo puede preguntarse la idea, a nivel conceptual.

Dónde está lo obligatorio. En la hoja *Ejercicios* de esta misma sesión, que contiene el ejercicio del día: uno por sesión, obligatorio, y el que entra en el examen con el cálculo incluido.

AMPLIACIÓN *opcional · no se pide calculado en el examen*

1. Muestreo directo desde x_0

Utilizando los valores de $\bar{\alpha}_t$ calculados en el ejercicio anterior, supongamos que hemos extraído una realización concreta $\varepsilon = 0,5$ de $\mathcal{N}(0, 1)$. Usando la fórmula de muestreo directo

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon,$$

- (a) calcula x_1 , x_2 y x_3 numéricamente (cuatro decimales).
- (b) ¿A qué valor convergería x_t si siguiéramos añadiendo pasos ($T \rightarrow \infty$ con $\bar{\alpha}_T \rightarrow 0$)?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

2. Paso reverso: de x_2 a x_1

En el proceso reverso, la red neuronal ε_θ predice el ruido que se añadió, y la media de la distribución reversa se calcula como

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \varepsilon_\theta(x_t, t) \right).$$

Supongamos que estamos en $t = 2$ con $x_2 = 0,6$ y que la red predice $\varepsilon_\theta(x_2, 2) = 0,4$. Usando $\alpha_2 = 0,8$, $\beta_2 = 0,2$ y $\bar{\alpha}_2 = 0,72$:

- (a) Calcula $\frac{\beta_2}{\sqrt{1 - \bar{\alpha}_2}}$.
- (b) Calcula $\mu_\theta(x_2, 2)$. Este es el valor estimado de x_1 .
- (c) Si la predicción de ruido fuese perfecta ($\varepsilon_\theta = \varepsilon$ real), ¿qué significaría geométricamente μ_θ ?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

3. Classifier-free guidance

Dado un modelo de difusión condicionado por texto, la predicción combinada con *classifier-free guidance* es

$$\hat{\varepsilon} = \varepsilon_\theta(x_t, t, \emptyset) + w(\varepsilon_\theta(x_t, t, c) - \varepsilon_\theta(x_t, t, \emptyset)),$$

donde $\emptyset$ indica la predicción incondicional, c es el prompt de texto y w es la escala de guía.

Supón que, para un cierto x_t y paso t , las predicciones bidimensionales son:

$$\varepsilon_\theta(x_t, t, \emptyset) = (0,3, 0,5), \quad \varepsilon_\theta(x_t, t, c) = (0,1, 0,8),$$

donde c es el prompt "cat".

- (a) Calcula la dirección condicional: $\Delta = \varepsilon_\theta(x_t, t, c) - \varepsilon_\theta(x_t, t, \emptyset)$.
- (b) Calcula $\hat{\varepsilon}$ para $w = 1$ (estándar), $w = 3$, $w = 7,5$ (valor por defecto en Stable Diffusion) y $w = 15$.
- (c) Calcula la norma $\|\hat{\varepsilon}\|$ para cada valor de w . ¿Qué observas?
- (d) Discute el compromiso calidad/diversidad: ¿qué ocurre con valores de w muy altos?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

4. Relación señal-ruido (SNR)

La *signal-to-noise ratio* (SNR) en el paso t se define como

$$\text{SNR}(t) = \frac{\bar{\alpha}_t}{1 - \bar{\alpha}_t}.$$

- (a) Usando los $\bar{\alpha}_t$ del ejercicio 1, calcula $\text{SNR}(1)$, $\text{SNR}(2)$ y $\text{SNR}(3)$.
- (b) ¿Para qué valor de $\bar{\alpha}_t$ se cumple $\text{SNR} = 1$ (señal y ruido iguales)? ¿Está cerca de alguno de nuestros pasos t ?
- (c) En los modelos de difusión reales (e.g., DDPM con $T = 1000$), el SNR decae de $\approx 10^3$ a $\approx 10^{-3}$. ¿Qué implica esto sobre los pasos iniciales y finales del proceso forward?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

5. Coste de una campaña publicitaria multimodal

Un equipo de marketing quiere generar contenido para el lanzamiento de un producto utilizando modelos generativos. El plan de producción y los costes unitarios son:

Modalidad	Cantidad	Coste unitario	Detalle
Imágenes de producto	500	\$0,04/imagen	DALL-E 3 / Midjourney
Descripciones de texto	500	ver abajo	Claude Sonnet
Locuciones de voz	100	\$0,04/segundo	ElevenLabs (15 s cada una)
Clips de vídeo	10	\$1,50/clip	Sora (5 s cada uno)

Para las descripciones de texto, cada llamada usa 500 tokens de entrada (\$3/Mtok) y genera 200 tokens de salida (\$15/Mtok).

- (a) Calcula el coste total de cada modalidad por separado.
- (b) Calcula el coste total de toda la campaña.
- (c) ¿Qué modalidad domina el presupuesto? ¿Es sorprendente?
- (d) Si el presupuesto es \$500, ¿cuántas campañas completas se podrían financiar?

AMPLIACIÓN *opcional · no se pide calculado en el examen*

6. Coste de tokenización de imágenes

Un modelo visión-lenguaje (e.g., GPT-4o, Claude) procesa imágenes convirtiéndolas en ~1000 tokens por imagen. El precio de entrada es \$3/Mtok.

- (a) ¿Cuál es el coste por imagen analizada?
- (b) Una empresa de e-commerce quiere analizar su catálogo de 50 000 imágenes de producto para extraer atributos (color, material, estilo). ¿Cuál es el coste total vía API?
- (c) Compara con la alternativa humana: 5 anotadores a \$2 000/mes, cada uno etiqueta 200 imágenes/día (22 días laborables/mes). ¿Cuántos meses tardan en etiquetar las 50 000 imágenes y cuánto cuesta en total?
- (d) Calcula el ratio coste-humano/coste-API. ¿Qué factores cualitativos podrían justificar aún así el etiquetado humano?