

# Día 15 · Tema 6 — Ampliación: RAG y búsqueda semántica

**Qué es esta hoja.** Los ejercicios de ampliación de la sesión. Son opcionales y están para enseñar de qué es capaz el método, no para exigir: **no se piden calculados en el examen**. De ellos sólo puede preguntarse la idea, a nivel conceptual.

**Dónde está lo obligatorio.** En la hoja *Ejercicios* de esta misma sesión, que contiene el ejercicio del día: uno por sesión, obligatorio, y el que entra en el examen con el cálculo incluido.

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

## 1. Chunking de un documento

Un documento tiene un total de 2400 tokens. Se aplica chunking con un tamaño de chunk  $C$  y un solapamiento  $O$ . El número de chunks se calcula como

$$n = \left\lceil \frac{T - O}{C - O} \right\rceil,$$

donde  $T$  es el número total de tokens.

- (a)  $C = 400, O = 0$  (sin solapamiento). ¿Cuántos chunks se generan?
- (b)  $C = 400, O = 100$ . ¿Cuántos chunks se generan? ¿Cuántos tokens cubre el último chunk si no está completamente lleno?
- (c)  $C = 600, O = 50$ . ¿Cuántos chunks se generan?
- (d) Comenta cualitativamente: ¿qué efecto tiene aumentar el solapamiento sobre el número de chunks y sobre la probabilidad de que una idea quede partida entre dos chunks consecutivos?

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

## 2. Recuperación híbrida: coseno + BM25

Para los mismos cinco chunks del ejercicio anterior, un motor de búsqueda léxica (BM25) asigna las siguientes puntuaciones (ya normalizadas en  $[0, 1]$ ):

$$\text{BM25}(d_1) = 0,8, \quad \text{BM25}(d_2) = 0,3, \quad \text{BM25}(d_3) = 0,5, \quad \text{BM25}(d_4) = 0,9, \quad \text{BM25}(d_5) = 0,2.$$

El sistema híbrido combina ambas señales con

$$s_j = \alpha \cos(\mathbf{q}, \mathbf{d}_j) + (1 - \alpha) \text{BM25}(d_j), \quad \alpha = 0,7.$$

Dado que las similitudes coseno del ejercicio anterior ya están en  $[0, 1]$ , úsalas directamente (redondea a dos decimales si lo necesitas).

- (a) Calcula  $s_j$  para cada chunk.
- (b) Ordena los chunks de mayor a menor puntuación híbrida.
- (c) Compara este ranking con el del ejercicio 2. ¿Qué chunk sube más posiciones gracias a BM25 y cuál baja? ¿Por qué tiene sentido combinar ambas señales?

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

## 3. Recall@k y MRR

Los chunks relevantes para la consulta anterior son  $\{d_2, d_3\}$  (ground truth proporcionada por un anotador humano). Utiliza el ranking por similitud coseno del ejercicio 2.

- (a) Calcula Recall@1, Recall@3 y Recall@5. Recuerda:

$$\text{Recall}@k = \frac{|\{\text{relevantes}\} \cap \{\text{top-}k \text{ recuperados}\}|}{|\{\text{relevantes}\}|}.$$

- (b) Calcula el MRR (*Mean Reciprocal Rank*). Para una sola consulta,  $\text{MRR} = 1/r$ , donde  $r$  es la posición del primer chunk relevante en el ranking.
- (c) Si en lugar de usar el ranking coseno usamos el ranking híbrido del ejercicio 3, ¿cambian Recall@3 y MRR? Calcula ambas métricas con el nuevo ranking.

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

#### 4. Coste de un sistema RAG por consulta

Un sistema RAG recupera  $k = 5$  chunks de 400 tokens cada uno. El prompt del sistema tiene 300 tokens y la consulta del usuario 50 tokens. La respuesta media del LLM es de 400 tokens. Se usa Claude Sonnet con precios de \$3 por millón de tokens de entrada y \$15 por millón de tokens de salida.

- (a) Calcula el total de tokens de entrada por consulta.
- (b) Calcula el coste por consulta (entrada + salida).
- (c) Si el sistema recibe 1 000 consultas al día, ¿cuál es el coste diario? ¿Y el mensual (30 días)?
- (d) Si se reduce a  $k = 3$  (tras un reranking que descarta 2 chunks), ¿cuánto se ahorra al mes?

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

#### 5. Dimensionado de una base de datos vectorial

Un corpus contiene 100 000 documentos con una media de 2 000 tokens cada uno. Se aplica chunking con  $C = 400$  y  $O = 100$ . Los embeddings tienen dimensión  $D = 1024$ .

- (a) Calcula el número total de chunks.
- (b) Calcula el almacenamiento necesario para los embeddings en FP32 (4 bytes por float). Expresa el resultado en GB.
- (c) Repite el cálculo con cuantización a int8 (1 byte por float).
- (d) Calcula el tamaño del texto original (1 token  $\approx$  4 bytes) y compara con el almacenamiento de embeddings. ¿Los embeddings ocupan más o menos que el texto?

**AMPLIACIÓN** *opcional · no se pide calculado en el examen*

#### 6. Análisis coste-beneficio del reranking

Sin reranking, un sistema RAG tiene Recall@5 = 0,70, lo que se traduce en un 30 % de respuestas erróneas. Cada respuesta errónea genera una escalación al equipo humano con un coste de \$5. Con un cross-encoder que reordena los top-50 candidatos para seleccionar los top-5, el Recall@5 sube a 0,88 y las respuestas erróneas bajan al 12 %. El cross-encoder tiene un coste computacional adicional de \$0,001 por consulta. El sistema recibe 10 000 consultas al mes.

- (a) Calcula el coste mensual extra por el cross-encoder.
- (b) Calcula el coste mensual de escalaciones *sin* reranking y *con* reranking.
- (c) Calcula el ahorro neto mensual (ahorro en escalaciones menos coste del cross-encoder).
- (d) ¿A partir de cuántas consultas mensuales el reranking deja de ser rentable? (Pista: plantea la ecuación de punto de equilibrio.)