

Kahoots: preguntas y respuestas

Deep Learning para Business Analytics

Primera parte del curso · 92 preguntas · Universidad Pontificia Comillas, ICADE

La respuesta correcta va en **dorado** y marcada con ✓. La numeración de la izquierda es continua a lo largo del documento; debajo, en gris, el día y el número que la pregunta tiene dentro de su kahoot.

1 ¿Cuál es la diferencia más clara entre un chatbot y un agente?

D01 P2

- A. El chatbot habla en lenguaje natural y el agente solo en código.
- B. El agente requiere GPU dedicada y el chatbot funciona en cualquier portátil.
- C. El agente actúa con herramientas externas; el chatbot solo responde texto. ✓**
- D. El chatbot mantiene memoria persistente y el agente trabaja sin memoria.

2 ¿Qué pipeline permite trabajar la asignatura sin pagar API ni suscripción?

D01 P3

- A. Cursor con modelo Claude Sonnet conectado a la API de Anthropic.
- B. VS Code con la extensión oficial conectada al servicio gestionado de OpenAI.
- C. opencode local conectado a Ollama con un modelo abierto descargado. ✓**
- D. Google Colab Pro+ con notebook ejecutando modelos cerrados por API.

3 ¿Cuál de estos casos es típico del Bloque II (IA Agéntica) y no del Bloque I (Deep Learning)?

D01 P5

- A. Forecasting de demanda multiproducto con una red LSTM clásica.
- B. Clasificación de imágenes de retail con una red CNN preentrenada.
- C. Asistente corporativo que consulta documentos internos vía RAG. ✓**
- D. Detección de anomalías en producción con un MLP supervisado.

4 ¿Cuál de estas familias de modelos suele ser la primera opción para un problema de clasificación de imágenes en retail?

D01 P7

- A. Recurrencias modernas tipo RWKV con atención lineal escalable.
- B. State Space Models tipo Mamba con dependencias temporales largas.
- C. Redes convolucionales preentrenadas tipo ResNet o EfficientNet. ✓**
- D. Perceptrones multicapa profundos entrenados sobre píxeles aplanados.

5 ¿Por qué la activación no lineal es lo que da poder a un MLP?

D02 P2

- A. Permite invertir la matriz de pesos sin que aparezcan singularidades numéricas.
- B. Sin ella, una pila de capas se reduce a una única transformación lineal. ✓**
- C. Garantiza que los gradientes nunca se anulan durante el entrenamiento.
- D. Permite usar batch size grande sin perder estabilidad numérica de la red.

6 Si una neurona tiene $w_1 = 0,5$, $w_2 = -0,3$, $b = 0,2$ y entradas $x_1 = 2$, $x_2 = 4$, ¿cuánto vale z antes de la activación?

D02 P3

- A. $z = 0,5(2) + (-0,3)(4) + 0,2 = 0,0$. ✓**
- B. $z = 0,5(2) + (-0,3)(4) + 0,2 = 0,4$.
- C. $z = 0,5(2) + (-0,3)(4) + 0,2 = -0,2$.
- D. $z = 0,5(2) + (-0,3)(4) + 0,2 = 1,2$.

7 En un dataset con 99 % de no-churn, ¿qué métrica es engañosa?

D02 P4

- A. AUC (área bajo la curva ROC) sobre el conjunto de validación reservado.
- B. F1 sobre la clase positiva con umbral elegido por validación cruzada.
- C. Accuracy sobre el test, sin ningún ajuste de la clase desbalanceada. ✓**
- D. Recall sobre la clase positiva con umbral fijo de probabilidad 0,5.

8 ¿Cuál es el síntoma típico del overfitting durante el entrenamiento?

D02 P6

- A. La pérdida de train baja y la de validación también, en paralelo.
- B. La pérdida de train baja pero la de validación empieza a subir. ✓**
- C. La pérdida de train no baja y la de validación oscila violentamente.
- D. La pérdida de train baja y la de validación se mantiene plana.

9 ¿Para qué sirve la validación cruzada k-fold?

D02 P7

- A. Reducir el tiempo total de entrenamiento aprovechando paralelismo en GPU.
- B. Aumentar artificialmente el dataset cuando hay pocos ejemplos disponibles.
- C. Estimar el rendimiento del modelo con menos sensibilidad a la partición. ✓**
- D. Garantizar que el modelo no presenta sesgos por género o edad.

10 Si una regresión logística da el 90 % del valor de negocio, lo razonable es:

D02 P8

- A. Sustituirla por un MLP profundo aunque no se haya medido la mejora.
- B. Sustituirla por un Transformer fine-tuned, por consistencia tecnológica.
- C. Mantenerla y dedicar el esfuerzo a integrarla y mejorar el dato fuente. ✓**
- D. Sustituirla por un modelo de difusión adaptado a datos tabulares.

11 ¿Qué hace dropout durante el entrenamiento?

D03 P1

- A. Desactiva un porcentaje aleatorio de neuronas en cada paso de entrenamiento. ✓**
- B. Reduce el número total de pesos del modelo eliminando los menos útiles.
- C. Aumenta el tamaño del batch para estabilizar el cálculo del gradiente.
- D. Sustituye la activación ReLU por una versión suavizada y diferenciable.

12 ¿Cuál es el efecto principal de BatchNorm?

D03 P2

- A. Reduce los pesos del modelo equivalente a una penalización L1 implícita.
- B. Permite usar learning rates más altos y estabiliza la distribución entre capas. ✓**
- C. Acelera la inferencia eliminando cualquier operación no lineal del modelo.
- D. Cambia la función de pérdida a una versión robusta frente a outliers extremos.

13 ¿Qué efecto tiene weight decay sobre la solución que encuentra el optimizador?

D03 P3

- A. Penaliza pesos grandes y empuja la solución hacia el origen del espacio. ✓**
- B. Acelera el entrenamiento aumentando el tamaño del paso del gradiente.
- C. Reduce el ruido del gradiente promediando muestras consecutivas.
- D. Cambia la métrica de validación reportada al final de cada época.

14 ¿Cuándo se considera correcto aplicar early stopping?

D03 P4

- A. Cuando la pérdida de validación deja de mejorar durante varias épocas seguidas. ✓**
- B. Cuando la pérdida de entrenamiento alcanza un valor mínimo predefinido.
- C. Cuando el tiempo total de entrenamiento supera el presupuesto disponible.
- D. Cuando el learning rate cae por debajo de un umbral fijado de antemano.

15 ¿Para qué sirven W&B, MLflow o TensorBoard?

D03 P6

- A. Acelerar el entrenamiento conectando con GPUs distribuidas en la nube.
- B. Registrar experimentos, comparar configuraciones y reproducir resultados. ✓**
- C. Generar arquitecturas óptimas mediante búsqueda automática y autónoma.
- D. Convertir notebooks en aplicaciones desplegadas sin tocar ninguna línea.

16 Dada $\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{data}} + \lambda \|w\|^2$, ¿qué papel juega λ ?

D03 P7

- A. Controla la magnitud del coste asociado a tener pesos grandes en el modelo. ✓**
- B. Define la varianza inicial usada al inicializar los pesos antes de entrenar.
- C. Marca el umbral por debajo del cual se considera que el modelo ha convergido.
- D. Determina el número máximo de épocas que el optimizador puede ejecutar.

17 ¿Por qué un MLP plano escala mal a imágenes de 224×224 píxeles?

D04 P1

- A. Porque la activación ReLU se satura cuando hay muchos píxeles en la entrada.
- B. Porque el número de pesos crece linealmente con el tamaño de la imagen.
- C. Porque cada píxel requiere un peso distinto y los pesos no se comparten. ✓**
- D. Porque la regla de la cadena no funciona con tensores multidimensionales.

18 Dado un kernel 3×3 sobre una imagen 5×5 con stride 1 y sin padding, ¿qué tamaño tiene el feature map de salida?

D04 P2

- A. 3 × 3, calculado como (5 - 3 + 1) en cada dimensión espacial de la imagen. ✓**
- B. 5 × 5, mismo tamaño que la imagen original al aplicar la convolución estándar.
- C. 6 × 6, porque la salida añade un margen completo alrededor de la imagen.
- D. 4 × 4, equivalente a aplicar pooling de 2×2 después de la convolución 3×3.

19 ¿Qué hace el max-pooling 2×2 sobre un feature map?

D04 P3

- A. Reemplaza cada bloque 2×2 por el valor máximo y reduce la resolución a la mitad. ✓**
- B. Suma cada bloque 2×2 y normaliza para preservar la media del feature map.
- C. Multiplica cada bloque 2×2 por un kernel aprendido durante el entrenamiento.
- D. Aplica una convolución 2×2 con stride 1 y padding para preservar el tamaño.

20 ¿Qué propiedad clave aporta el “pesos compartidos” de la convolución?

D04 P4

- A. Reduce el número de parámetros y permite reusar detectores en toda la imagen. ✓**
- B. Permite acelerar el cálculo del gradiente sin afectar la precisión final.
- C. Hace la red robusta a cambios de iluminación bruscos en la entrada.
- D. Sustituye la necesidad de funciones de activación no lineales entre capas.

21 ¿Cuándo conviene transfer learning frente a entrenar desde cero?

D04 P6

- A. Cuando se dispone de millones de imágenes etiquetadas de propiedad propia.
- B. Cuando el dataset es pequeño o mediano y el dominio es visualmente cercano. ✓**
- C. Cuando se quiere maximizar el número de hiperparámetros del modelo final.
- D. Cuando se necesita una arquitectura completamente novedosa y nunca usada.

22 Si se congela el backbone de una ResNet preentrenada, ¿qué se entrena?

D04 P7

- A. La normalización por lotes (BatchNorm) de todas las capas convolucionales del modelo.
- B. La cabeza de clasificación adaptada al número de clases del nuevo problema. ✓**
- C. Solo la primera capa convolucional, ajustada al canal específico de las imágenes.
- D. Únicamente los hiperparámetros del optimizador, no los pesos del modelo.

23 ¿Cuál de estas aplicaciones encaja peor con una CNN clásica?

D04 P8

- A. Clasificar fotografías de prendas de moda en categorías de catálogo retail.
- B. Detectar defectos visibles en frutas durante el control de calidad en planta.
- C. Predecir series temporales de demanda multiproducto sin información visual. ✓**
- D. Segmentar imágenes satélite para análisis de uso del suelo agrícola.

24 ¿Cuándo gana más el transfer learning frente a entrenar desde cero?

D05 P1

- A. Cuando el dataset es muy grande y el problema es completamente nuevo.
- B. Cuando hay poco dato etiquetado y el dominio es visualmente cercano. ✓**
- C. Cuando se dispone de muchas GPUs y se quiere maximizar el tamaño del modelo.
- D. Cuando se necesita aleatoriedad pura en la inicialización de los pesos.

25 Si el dataset etiquetado tiene 100 ejemplos, ¿qué nivel de transfer es razonable?

D05 P2

- A. Fine-tuning total descongelando el backbone completo desde la primera capa.
- B. Feature extraction: backbone congelado, solo entrenas la cabeza nueva. ✓**
- C. Entrenamiento desde cero con inicialización aleatoria de todos los pesos.
- D. Búsqueda de arquitectura neuronal (NAS) sobre 100 ejemplos del dataset.

26 ¿Qué pasa si usas la tasa de aprendizaje habitual de entrenamiento desde cero (1e-3) para fine-tuning?

D05 P3

- A. El modelo converge antes y con mejor accuracy de la habitual.
- B. La métrica no cambia, porque el backbone está pre-entrenado.
- C. Los pesos pre-entrenados se desplazan demasiado y la red olvida lo aprendido. ✓**
- D. El optimizador AdamW lo corrige automáticamente con el weight decay.

27 ¿Qué representa el estado oculto h_t en una RNN?

D06 P1

- A. Un número real escalar que mide la pérdida en el paso temporal actual.
- B. Un vector que resume toda la información relevante de los pasos anteriores. ✓**
- C. Una copia exacta de la entrada x_t procesada por una activación no lineal.
- D. Un parámetro fijo aprendido en preentrenamiento y compartido en todos los pasos.

28 ¿Por qué falla la RNN básica con dependencias temporales muy largas?

D06 P2

- A. Porque el batch size se vuelve demasiado grande para la memoria del modelo.
- B. Porque los gradientes pueden desaparecer o explotar al propagarse por el tiempo. ✓**
- C. Porque la activación tanh no es diferenciable en los puntos extremos de la curva.
- D. Porque el dataset requiere mucha más memoria para ser cargado en GPU completa.

29 ¿Qué añade LSTM frente a la RNN básica?

D06 P3

- A. Una segunda red neuronal idéntica que duplica la capacidad del modelo original.
- B. Una memoria explícita C_t con puertas de olvido, entrada y salida controladas. ✓**
- C. Una etapa de embeddings aprendidos previa a la primera capa recurrente del modelo.
- D. Una normalización por lotes específica para tensores de tres dimensiones temporales.

30 Dados $W_x = 0,01$, $W_h = 0,5$, $b = -0,2$, $x_1 = 100$, $h_0 = 0$, ¿cuál es h_1 con activación tanh?

D06 P5

- A. $h_1 = \tanh(0,01 \cdot 100 + 0,5 \cdot 0 - 0,2) = \tanh(0,80) \approx 0,66$. ✓**
- B. $h_1 = \tanh(0,01 \cdot 100 - 0,5 \cdot 0 + 0,2) = \tanh(1,20) \approx 0,83$.
- C. $h_1 = \tanh(0,01 \cdot 100 + 0,5 \cdot 1 - 0,2) = \tanh(1,30) \approx 0,86$.
- D. $h_1 = \tanh(0,01 \cdot 100 + 0,5 \cdot 0 + 0,2) = \tanh(1,20) \approx 0,83$.

31 ¿En qué caso de negocio la LSTM tiene ventaja clara sobre un ARIMA clásico?

D06 P6

- A. Cuando la serie es estacionaria, sin tendencia y sin estacionalidad evidente.
- B. Cuando se dispone de covariables externas (promo, precio, calendario) que importan. ✓**
- C. Cuando el horizonte es de un único paso y la varianza del error es muy baja.
- D. Cuando el dataset es muy pequeño y el modelo debe ser interpretable a stakeholders.

32 ¿Cuál es el valor típico de dropout en una LSTM de dos capas?

D06 P7

- A. Entre 0,8 y 1,0 para evitar cualquier riesgo de overfitting durante el entrenamiento.
- B. Exactamente 0,0 porque dropout no se usa nunca en redes recurrentes modernas.
- C. Entre 0,1 y 0,3 aplicado entre capas para reducir overfitting sin perder señal. ✓**
- D. Entre 0,5 y 0,7 aplicado siempre sobre la entrada x_t de cada paso temporal.

33 ¿Cuál es la limitación principal de una RNN clásica para secuencias largas?

D07 P1

- A. No puede entrenarse con minibatches de más de un ejemplo.
- B. El pasado se comprime en un solo vector y se pierde con la distancia. ✓**
- C. La función ReLU no se puede usar dentro de una red recurrente convencional.
- D. No es compatible con dropout ni con BatchNorm como regularizadores.

34 En “el cliente devolvió el pedido porque estaba roto”, “roto” da peso 0,61 a “pedido”. ¿Qué significa?

D07 P2

- A. Que “pedido” y “roto” aparecen juntas el 61 % de las veces en el corpus.
- B. Que el modelo dedica el 61 % de sus parámetros a la palabra “pedido”.
- C. Que “pedido” es la palabra que más explica qué es lo que está roto. ✓**
- D. Que “pedido” está a 0,61 unidades de distancia de “roto” en la frase.

35 En una capa de atención, ¿qué son la query, el key y el value de una palabra?

D07 P3

- A. Lo que la palabra busca, lo que ofrece y lo que aporta si la eligen. ✓**
- B. Tres copias idénticas del embedding que se promedian al final del bloque.
- C. Las tres matrices de pesos que la red aprende durante el entrenamiento.
- D. La entrada, el estado oculto y la salida de la celda recurrente.

36 Los pesos de atención de una palabra suman exactamente 1. ¿De qué operación sale esa propiedad?

D07 P4

- A. De dividir entre $\sqrt{d_k}$, que reescala los scores antes de mezclar.
- B. Del producto QK^T , que ya devuelve valores acotados entre 0 y 1.
- C. De multiplicar por V , que normaliza la mezcla final de los values.
- D. Del softmax, que convierte los encajes en porcentajes que suman uno. ✓**

37 “Banco” entra con el mismo vector en dos frases distintas y sale con vectores distintos. ¿Por qué?

D07 P5

- A. Porque el embedding de “banco” se reentrena con cada frase que llega.
- B. Porque la mezcla de valores cambia: mira a “interés” o mira a “parque”. ✓**
- C. Porque la red añade ruido aleatorio distinto en cada pasada hacia delante.
- D. Porque el diccionario guarda dos entradas para la palabra “banco”.

38 En una capa de atención, ¿qué se aprende en el entrenamiento y qué se recalcula en cada frase?

D07 P6

- A. Se aprenden W_Q , W_K y W_V ; los pesos se recalculan por frase. ✓**
- B. Se aprenden los pesos de atención; las tres matrices son fijas.
- C. Se aprende todo en cada frase; la capa no guarda ningún parámetro.
- D. No se aprende nada: la atención es una fórmula cerrada sin parámetros.

39 ¿Qué coste asintótico tiene la atención escalada en una secuencia de longitud T ?

D07 P7

- A. $O(T)$, lineal: solo recorre cada token una vez.
- B. $O(T \log T)$, como una ordenación por comparaciones.
- C. $O(T^2)$, cuadrático: la matriz QK^T es $T \times T$. ✓**
- D. $O(2^T)$, exponencial: prohibitivo más allá de 50 tokens.

40 ¿En qué caso tiene sentido seguir prefiriendo una RNN/GRU a un Transformer?

D07 P8

- A. Cuando la secuencia es larga y hay dependencias muy remotas.
- B. Cuando se quiere maximizar el paralelismo con muchas GPUs en data center.
- C. Cuando hay millones de ejemplos y miles de tokens por secuencia.
- D. Cuando corre en streaming con latencia de milisegundos. ✓**

41 ¿Qué es un embedding de palabra?

D08 P1

- A. Un vector denso de baja dimensión que codifica el significado del token. ✓**
- B. Una representación binaria que indica si la palabra aparece en el corpus.
- C. Un parámetro del optimizador AdamW específico para procesamiento de texto.
- D. El resultado de pasar la palabra por la función de pérdida BCEWithLogits.

42 ¿De dónde salen los números de un embedding?

D08 P2

- A. De contar cuántas veces aparece cada palabra en todo el corpus.
- B. De un diccionario que un lingüista rellena palabra por palabra.
- C. De la descomposición en valores singulares de la matriz de pesos.
- D. De jugar a adivinar la palabra que falta, millones de veces. ✓**

43 ¿Qué famoso resultado ilustra word2vec con aritmética vectorial?

D08 P3

- A. $\vec{\text{Madrid}} + \vec{\text{España}} \approx \vec{\text{París}}$, la capital vecina.
- B. $\vec{\text{rey}} - \vec{\text{hombre}} + \vec{\text{mujer}} \approx \vec{\text{reina}}$. ✓**
- C. $\vec{\text{coche}} + \vec{\text{rojo}} \approx \vec{\text{semáforo}}$, por el color.
- D. $\vec{\text{lluvia}} \cdot \vec{\text{paraguas}} \approx 1$ en cualquier modelo.

44 ¿Cuál es la distancia recomendada entre embeddings normalizados?

D08 P4

- A. Distancia euclidiana, equivalente al error cuadrático medio entre vectores.
- B. Distancia de Manhattan, sumando los valores absolutos de las diferencias.
- C. Distancia coseno: si están normalizados, es el producto escalar. ✓**
- D. Distancia de Hamming, contando coordenadas donde dos vectores difieren.

45 Con la consulta $q = (2, 3, 6)$, ¿qué ficha se parece más: $d_1 = (0, 0, 7)$ o $d_2 = (7, 0, 0)$?

D08 P5

- A. d_2 , porque su primera coordenada, 7, es la mayor de todas.
- B. Las dos igual, porque ambas tienen la misma longitud, 7.
- C. Ninguna: con dos coordenadas nulas el coseno no está definido.
- D. d_1 , porque comparte la coordenada dominante de la consulta. ✓**

46 Si multiplicamos por 10 todas las coordenadas de una ficha, ¿cambia su similitud coseno?

D08 P6

- A. No: el coseno mide dirección, y escalar no cambia la dirección. ✓**
- B. Sí: queda multiplicada por 10, igual que el producto escalar.
- C. Sí: pasa a valer 1, porque el vector se vuelve mucho más largo.
- D. Depende de si la consulta estaba normalizada a longitud uno.

47 ¿Cuál es el caso de negocio canónico de los embeddings en banca?

D08 P8

- A. Detectar tarjetas de crédito falsificadas con redes convolucionales.
- B. Predecir el tipo de cambio del euro frente al dólar a 30 días vista.
- C. Buscar normativa interna por significado, no por palabra exacta. ✓**
- D. Generar contenido publicitario nuevo para campañas en redes sociales.

48 ¿Qué representa self-attention dentro de un Transformer?

D09 P1

- A. Una atención donde Q, K y V salen todos de la misma secuencia. ✓**
- B. Una atención entre la secuencia de entrada y otra de salida distinta.
- C. Una capa convolucional adaptada a tokens en lugar de píxeles de imagen.
- D. Un mecanismo de regularización que reemplaza al dropout en el bloque.

49 ¿Qué es un Transformer, dicho con lo que ya sabéis del Día 07?

D09 P2

- A. Una RNN a la que se le añade una capa de atención al final.
- B. Una CNN cuyos filtros recorren tokens en lugar de píxeles.
- C. La misma capa de atención apilada N veces, una encima de otra. ✓**
- D. Un modelo nuevo de 2022 sin relación con la atención de 2017.

50 ¿Qué piezas monta un bloque Transformer, una detrás de otra?

D09 P4

- A. Convolución 1D, max-pooling y una capa LSTM con dropout intermedio.
- B. Tres capas convolucionales con BatchNorm y un clasificador lineal.
- C. Una RNN, una capa de embedding y atención sobre la salida final.
- D. Atención multi-head, residual, una capa densa y otra residual. ✓**

51 ¿Qué hace la conexión residual ($x + \text{Att}(x)$) en el Transformer?

D09 P5

- A. Reemplaza la función ReLU dentro de la red feed-forward del bloque.
- B. Reduce el número total de parámetros del modelo Transformer completo.
- C. Permite apilar muchos bloques sin que el gradiente se desvanezca. ✓**
- D. Inicializa los pesos con una gaussiana de media cero y varianza uno.

52 En un modelo de churn, ¿para qué sirve el sesgo b de una neurona?

RM1 P1

- A. Para medir cuánto se equivoca el modelo con cada cliente.
- B. Para subir o bajar el listón a partir del cual la neurona se activa. ✓**
- C. Para decidir cuántas variables del cliente entran en el modelo.
- D. Para corregir que en los datos haya muchas más altas que bajas.

53 En un modelo de churn, ¿qué se consigue poniendo una sigmoide en la neurona de salida?

RM1 P2

- A. Que la salida caiga entre 0 y 1 y se lea como probabilidad de baja. ✓**
- B. Que el modelo deje de necesitar un conjunto de validación.
- C. Que el entrenamiento funcione con cualquier learning rate.
- D. Que las bajas y las altas pesen lo mismo en la pérdida.

54 Durante el entrenamiento, ¿qué hace el optimizador?

RM1 P3

- A. Decide cuántas capas y cuántas neuronas va a tener la red.
- B. Elige qué clientes entran en el siguiente batch de entrenamiento.
- C. Ajusta un poco cada peso en el sentido que hace bajar el error. ✓**
- D. Traduce la salida del modelo a un informe legible por el negocio.

55 ¿En qué se diferencia el conjunto de validación del conjunto de test?

RM1 P5

- A. En nada: son dos nombres para la misma partición de los datos.
- B. Validación sirve para elegir modelo; test, solo para el juicio final. ✓**
- C. Validación se usa para entrenar y test para calcular el error.
- D. El test se mira cada época y la validación solo al terminar.

56 Una neurona recibe $x = (1, 3)$ con pesos $w = (0,5, 0,2)$ y sesgo $b = -0,4$, y aplica ReLU. ¿Qué sale?

RM1 P6

- A. 1,1
- B. 0,7 ✓**
- C. 0,3
- D. 0

57 La pérdida de train se queda alta y la de validación también. ¿Qué le pasa al modelo?

RM1 P7

- A. Se ha quedado corto: le falta capacidad o le falta entrenamiento. ✓**
- B. Está memorizando el conjunto de entrenamiento ejemplo a ejemplo.
- C. El conjunto de validación está contaminado con datos de train.
- D. El learning rate es tan pequeño que la pérdida ya ha convergido.

58 ¿Qué pasa con el dropout cuando el modelo ya está en producción prediciendo?

RM1 P8

- A. Se mantiene igual, apagando neuronas al azar en cada predicción.
- B. Se desactiva: la predicción usa todas las neuronas de la red. ✓**
- C. Se sube la probabilidad p para dar predicciones más prudentes.
- D. Se aplica solo a la capa de salida y no a las capas ocultas.

59 Entrenas con 1.000 clientes y batches de 50. ¿Cuántas veces se actualizan los pesos en una época?

RM1 P9

- A. 1.000 veces, una por cada cliente del conjunto.
- B. 50 veces, una por cada cliente de cada batch.
- C. 1 vez, porque una época es un único paso.
- D. 20 veces, una por cada batch de la época. ✓**

60 BatchNorm recibe el batch (2, 4, 5, 6, 8). ¿Cuánto vale el normalizado del 8, antes de gamma y beta?

RM1 P10

- A. 1,50 ✓**
- B. 3,00
- C. 0,75
- D. 1,34

61 Una capa con 8 kernels de 3x3 mira fotos de estante en blanco y negro. ¿Cuántos pesos tiene, sin sesgos?

RM1 P11

- A. 8 pesos, uno por cada kernel de la capa.
- B. 9 pesos, los del kernel que se comparte.
- C. 72 pesos, nueve por cada uno de los 8 kernels. ✓**
- D. 576 pesos, uno por píxel y por kernel.

62 Un único kernel 3x3 mira una foto de estante en color RGB. ¿Cuántos pesos tiene, sin sesgo?

RM1 P12

- A. 9, uno por casilla, los mismos para los tres canales.
- B. 3, uno por cada canal de color de la imagen.
- C. 27, nueve casillas por cada uno de los tres canales. ✓**
- D. 12, las nueve casillas más los tres canales.

63 Un kernel 3x3 recorre una foto de 6x6 posición a posición. ¿De qué tamaño sale el mapa de activación?

RM1 P13

- A. 6x6, el mismo que la foto de entrada.
- B. 4x4, porque el kernel pierde un borde por cada lado. ✓**
- C. 3x3, el mismo tamaño que tiene el kernel.
- D. 2x2, porque el mapa se reduce a la mitad.

64 Al final de una CNN se aplanan los mapas y entra una capa densa. ¿Para qué sirve esa capa densa?

RM1 P14

- A. Para volver a detectar bordes sobre el vector ya aplanado.
- B. Para recuperar la resolución original de la foto de entrada.
- C. Para quitar ruido de los mapas antes de clasificar.
- D. Para combinar los rasgos detectados y puntuar cada clase. ✓**

65 Pasas el kernel (1 1 1 / 0 0 0 / -1 -1 -1) sobre el parche (1 2 3 / 4 5 6 / 7 8 9). ¿Cuánto sale?

RM1 P15

- A. -18 ✓**
- B. 18
- C. 45
- D. 0

66 ¿Qué parte de una red preentrenada guarda los rasgos que sirven para cualquier foto?

RM1 P16

- A. Las primeras capas, que detectan bordes, colores y texturas. ✓**
- B. La última capa, la que da una puntuación por clase.
- C. Las capas de pooling, que son las únicas sin parámetros.
- D. Ninguna: los rasgos genéricos viven en los datos, no en la red.

67 Al reutilizar una CNN preentrenada se habla de backbone y de cabeza. ¿Qué es el backbone?

RM1 P17

- A. El conjunto de datos con el que se preentrenó el modelo.
- B. La capa final que da una puntuación por cada clase.
- C. El cuerpo convolucional que extrae los rasgos de la imagen. ✓**
- D. El optimizador con el que se hizo el preentrenamiento.

68 ¿Qué comparte una RNN entre todas las semanas de una serie de ventas?

RM1 P18

- A. El estado oculto, que se queda congelado durante toda la serie.
- B. La venta de entrada, que es la misma en todas las semanas.
- C. Los mismos pesos, que se reutilizan semana tras semana. ✓
- D. El error, que es idéntico en todas las semanas de la serie.

69 ¿Qué decide la puerta de olvido de una LSTM?

RM1 P20

- A. Cuándo se detiene el entrenamiento de la red recurrente.
- B. Qué neuronas se apagan al azar en ese paso temporal.
- C. Qué parte de lo que la red tenía memorizado deja de ser útil. ✓
- D. Cuántas semanas hacia atrás llega a mirar la red en total.

70 RNN con $W_x = 0,5$, $W_h = 0,8$ y $b = 0,1$. Con $h_0 = 0,5$ y $x_1 = 1$, ¿cuánto vale $h_1 = \tanh(W_x \cdot x_1 + W_h \cdot h_0 + b)$?

RM1 P22

- A. $\tanh(0,9) = 0,72$
- B. $\tanh(1,0) = 0,76$ ✓
- C. $\tanh(1,1) = 0,80$
- D. $\tanh(0,6) = 0,54$

71 En “el cliente devolvió el pedido porque estaba roto”, ¿qué es el key de cada palabra?

RM1 P23

- A. La pregunta que esa palabra le lanza al resto de la frase.
- B. Lo que esa palabra ofrece para que las demás decidan si mirarla. ✓
- C. El contenido que se mezcla una vez repartidos los pesos.
- D. El número que marca su posición dentro de la frase.

72 ¿Qué hace el softmax con los scores de atención de una palabra?

RM1 P24

- A. Los convierte en un reparto: todos positivos y sumando uno. ✓
- B. Los divide por la raíz de la dimensión para bajar su tamaño.
- C. Se queda solo con la palabra que ha sacado el score más alto.
- D. Proyecta la palabra en sus vectores query, key y value.

73 La palabra “banco” sale con un vector distinto en “banco del parque” y en “banco de inversión”. ¿Por qué?

RM1 P25

- A. Porque el tokenizador la parte en trozos distintos en cada frase.
- B. Porque la tabla de embeddings guarda una entrada por significado.
- C. Porque la atención mezcla cada palabra con el resto de su frase. ✓
- D. Porque el modelo se reentrena cada vez que cambia de contexto.

74 Dos fichas de producto dicen lo mismo pero una es mucho más larga. ¿Qué mide su similitud coseno?

RM1 P26

- A. Cuántas palabras tienen en común las dos fichas del catálogo.
- B. Cuántos caracteres de diferencia hay entre una ficha y la otra.
- C. Si hablan del mismo tema, sin que importe lo larga que sea cada una. ✓
- D.Cuál de las dos fichas generó más ventas durante el mes pasado.

75 ¿De dónde salen los números que forman el embedding de una palabra?

RM1 P27

- A. De un diccionario de sinónimos que anota un lingüista a mano.
- B. Del orden alfabético de la palabra dentro del vocabulario.
- C. De contar en cuántos documentos del corpus aparece la palabra.
- D. De entrenar un modelo a adivinar palabras a partir de su contexto. ✓

76 Dos embeddings valen $u = (3, 0)$ y $v = (3, 4)$. ¿Cuánto vale su similitud coseno?

RM1 P28

- A. 0,60 ✓
- B. 0,40
- C. 1,00
- D. 9,00

77 ¿Qué se gana con tener varias cabezas de atención en la misma capa?

RM1 P29

- A. Que el coste deje de crecer con el cuadrado de la longitud.
- B. Que cada cabeza se fije en un tipo de relación distinto de la frase. ✓
- C. Que el modelo pueda prescindir de la capa densa del bloque.
- D. Que la secuencia se reparta entre varias GPU a la vez.

78 En un modelo de churn, ¿qué se calcula en el paso hacia delante?

RM2 P1

- A. El reparto de los clientes entre train, validación y test.
- B. La culpa que tiene cada peso en el error ya cometido.
- C. La predicción del cliente a partir de la entrada y los pesos. ✓**
- D. El número de capas que la red necesita para el problema.

79 La neurona de salida de un modelo de churn da $z = 0$. ¿Qué probabilidad de baja sale de la sigmoide?

RM2 P2

- A. 0,00
- B. 0,50 ✓**
- C. 0,73
- D. 1,00

80 ¿Qué controla el learning rate durante el entrenamiento?

RM2 P3

- A. Cuántos clientes entran en cada batch del entrenamiento.
- B. Cuántas épocas se entrena la red antes de parar.
- C. Cuántas neuronas se apagan al azar en cada paso.
- D. Cuánto se mueve cada peso en cada paso de corrección. ✓**

81 Después de normalizar el batch, BatchNorm aplica gamma y beta. ¿Para qué sirven?

RM2 P4

- A. Para que la capa pueda reescalar y desplazar si le conviene. ✓**
- B. Para apagar al azar una parte de las neuronas de la capa.
- C. Para calcular la media y la varianza del batch que entra.
- D. Para fijar el learning rate con el que se entrena esa capa.

82 BatchNorm recibe el batch (4, 8, 10, 12, 16). ¿Cuánto vale el normalizado del 12, antes de gamma y beta?

RM2 P5

- A. 2,00
- B. 0,13
- C. 0,50 ✓**
- D. 0,45

83 ¿Qué es un mapa de activación en una CNN?

RM2 P6

- A. El conjunto de pesos que la capa aprende al entrenarse.
- B. La respuesta de un kernel en cada posición de la imagen. ✓**
- C. La foto de entrada después de pasarla a blanco y negro.
- D. La puntuación final que la red da a cada clase.

84 ¿Cuántos parámetros aprende una capa de max-pooling de 2x2?

RM2 P7

- A. Cuatro, los pesos del bloque de 2x2 que recorre el mapa.
- B. Uno por cada bloque de 2x2 en que se parte el mapa.
- C. Tantos como canales tenga el mapa que entra en la capa.
- D. Ninguno: su regla es fija y no se entrena. ✓**

85 Max-pooling 2x2 con paso 2 sobre (2 7 1 3 / 9 4 6 5 / 8 1 2 2 / 3 3 7 4). ¿Qué mapa sale?

RM2 P8

- A. (9 6 / 8 7) ✓**
- B. (5,5 3,75 / 3,75 3,75)
- C. (2 1 / 8 2)
- D. (9 7 / 9 7)

86 ¿Qué ahorra reutilizar un modelo preentrenado en vez de entrenar desde cero?

RM2 P9

- A. Tener que normalizar las fotos antes de meterlas en la red.
- B. El trabajo de elegir la métrica con la que juzgar el modelo.
- C. Datos etiquetados propios y muchísimas horas de GPU. ✓**
- D. La necesidad de reservar un conjunto de test para el juicio final.

87 ¿Qué quiere decir que una RNN se despliega en el tiempo?

RM2 P10

- A. Que la red añade una capa nueva por cada semana de la serie.
- B. Que se dibuja una copia de la red por paso, todas con los mismos pesos. ✓**
- C. Que el estado oculto se reinicia a cero en cada paso temporal.
- D. Que la serie se parte en trozos que se entrenan por separado.

88 En “el pedido llegó tarde”, ¿qué es el query de cada palabra?

RM2 P11

- A. El contenido que aporta cuando otra palabra decide mirarla.
- B. Su posición dentro de la frase, contada desde el principio.
- C. El peso que acaba recibiendo después del softmax.
- D. Lo que esa palabra busca en las demás para decidir a quién mirar. ✓**

89 ¿Para qué sirve la codificación posicional de un Transformer?

RM2 P12

- A. Para que el modelo sepa en qué orden venían las palabras. ✓**
- B. Para que los pesos de atención sumen uno en cada fila.
- C. Para partir el texto en tokens antes de vectorizarlo.
- D. Para impedir que un token mire a los que vienen detrás.

90 Dos fichas de producto tienen similitud coseno cercana a 0. ¿Qué significa?

RM2 P13

- A. Que una ficha es copia literal de la otra en el catálogo.
- B. Que las dos fichas tienen exactamente la misma longitud.
- C. Que hablan de cosas sin ninguna relación entre sí. ✓**
- D. Que ninguna de las dos se ha vendido durante el mes.

91 Dos embeddings valen $u = (1, 1)$ y $v = (0, 2)$. ¿Cuánto vale su similitud coseno?

RM2 P14

- A. 2,00
- B. 0,71 ✓**
- C. 0,50
- D. 1,00

92 ¿Qué aporta la conexión residual de un bloque Transformer?

RM2 P15

- A. Reparte los tokens entre las distintas cabezas de atención.
- B. Convierte los scores de atención en un reparto que suma uno.
- C. Normaliza la escala de los valores antes de la capa densa.
- D. Deja pasar la entrada tal cual y ayuda al gradiente a llegar al fondo. ✓**