

Día 03 · Tema 1 — Regularización, schedules y dashboards

1. Dropout

Dropout multiplica las activaciones por una máscara binaria $m \in \{0, 1\}^d$ cuyas componentes son Bernoulli independientes con probabilidad $1 - p$ de estar a 1. En entrenamiento se aplica

$$\tilde{a}_\ell = \frac{1}{1-p} m \odot a_\ell, \quad m_i \sim \text{Bernoulli}(1-p). \quad (1)$$

a_ℓ activación de la capa ℓ antes de dropout
 m máscara aleatoria, una nueva por minibatch
 p probabilidad de *apagar* cada neurona, típicamente 0,1–0,5
 $\tilde{a}_\ell$ activación regularizada, con escalado para preservar la media

En inferencia se desactiva ($p = 0$, $m \equiv 1$). El factor $1/(1-p)$ asegura que $\mathbb{E}[\tilde{a}_\ell] = a_\ell$, así que la red se calibra igual.

2. BatchNorm

BatchNorm normaliza cada *feature* por su estadística de minibatch y la deja libre de aprender una escala y un sesgo:

$$\hat{a} = \frac{a - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad y = \gamma \hat{a} + \beta. \quad (2)$$

μ_B, σ_B^2 media y varianza calculadas en el minibatch
 γ, β parámetros aprendibles, uno por canal/feature
 ϵ término de estabilidad (10^{-5})

Si el batch es muy pequeño (≤ 4), σ_B^2 es ruidoso; preferir **LayerNorm** (normalización sobre la dimensión de features, no el batch), que es estándar en Transformers.

3. Weight decay

Penalizar pesos grandes equivale a añadir un prior gaussiano:

$$\mathcal{L}_{\text{total}}(\theta) = \mathcal{L}_{\text{data}}(\theta) + \lambda \|\theta\|_2^2. \quad (3)$$

λ coeficiente, típicamente 10^{-5} – 10^{-3}
 $\|\theta\|_2^2$ suma de cuadrados de *todos* los pesos

En AdamW se aplica como decaimiento directo: $\theta \leftarrow \theta - \eta \lambda \theta$, sin pasar por el gradiente, lo que evita interacciones con las medias móviles (m_t, v_t) de Adam.

4. Early stopping

Sea $V(t)$ la pérdida de validación en la época t . El criterio de parada con *patience* P es

$$t^* = \min\{t : V(t) > \min_{t' \leq t} V(t') \text{ durante } P \text{ épocas}\}. \quad (4)$$

Se devuelve el checkpoint correspondiente a $\arg \min_{t' \leq t^*} V(t')$. Es la forma más simple y efectiva de regularización: el modelo deja de entrenar cuando empieza a memorizar.

5. Schedules de learning rate

La regla $\theta_{t+1} = \theta_t - \eta_t g_t$ admite η_t variable. Cuatro schedules clásicos:

- **Constante:** $\eta_t = \eta_0$.
- **Step decay:** $\eta_t = \eta_0 \gamma^{\lfloor t/T \rfloor}$, típicamente $\gamma = 0,1$, $T = 30$ épocas.
- **Cosine annealing** (defecto moderno):

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})\left(1 + \cos\left(\frac{\pi t}{T}\right)\right). \quad (5)$$

- **Warmup + cosine:** lineal de 0 a $\eta_{\max}$ en T_w pasos, luego cosine hasta $\eta_{\min}$ en $T - T_w$.

$\eta_{\max}, \eta_{\min}$ lr máximo y mínimo de la trayectoria
 T horizonte total (iteraciones o épocas)
 T_w duración del warmup

Cosine es la receta por defecto con AdamW; warmup es obligatorio para modelos grandes.

6. Diagnóstico con dashboards

Los cuatro paneles imprescindibles a vigilar en cada entrenamiento son:

1. **Pérdida train/val** — si val sube cuando train baja: overfitting.
2. **Gradient norm** $\|g_t\|_2$ — explosión $\Rightarrow$ bajar η o aplicar *gradient clipping* $g \leftarrow g \cdot \min(1, c/\|g\|_2)$.
3. **Métrica de negocio** (AUC, MAPE, F1) — el único panel que mira el cliente; debe correlar con la pérdida pero no coincide.
4. **Learning rate efectivo** η_t — verifica que el schedule realmente se ejecuta (los typos rompen schedules en silencio).

IDEA CLAVE. Si no se han registrado estos cuatro paneles, el experimento es *irreproducible*. Trackers (W&B, MLflow, Aim) los gestionan en disco con un coste nulo.

7. El primer prototipo correcto del curso

La receta defensiva, ordenada por prioridad: **(1)** AdamW con $\eta_{\text{máx}} = 10^{-3}$ y *warmup* de 5 % de los pasos; **(2)** cosine annealing; **(3)** weight decay 10^{-4} ; **(4)** dropout 0,2 en MLP, 0,1 en CNN; **(5)** early stopping con $P = 10$; **(6)** log en W&B o MLflow con los cuatro paneles.