

Simulacro del examen parcial · Bloque I — Solucionario

Deep Learning para Business Analytics · Universidad Pontificia Comillas (ICADE) · Curso 2026–2027

Días 02–09 (Temas 1–3) · clave, justificación y distractor de cada ítem

Cómo leer este documento. Debajo de cada pregunta va la letra correcta, por qué lo es y de qué error concreto nace el distractor más tentador. Ese segundo apartado es el que conviene leer aunque hayas acertado: el examen real usa exactamente el mismo tipo de distractor.

Qué no hay que deducir de aquí. Ninguna de estas quince preguntas aparece en el examen parcial. Lo que se repite es el formato, la dificultad y el estilo de las alternativas.

Parte I — Conceptos (12 preguntas, 1 punto cada una)

1. ¿Cuenta el sesgo b de una neurona como parámetro de la red?

- A. Sí: el entrenamiento lo ajusta igual que a los pesos.
- B. No: se fija a mano antes de empezar a entrenar.
- C. No: su valor queda anclado en cero para siempre.
- D. Sí, pero sólo en la última capa de la red.

A El sesgo se aprende de los datos como cualquier peso: el gradiente también pasa por él y el optimizador lo mueve en cada paso. Por eso una capa de n entradas y m salidas tiene $nm + m$ parámetros y no nm . *Distractor:* B, que lo confundiría con un hiperparámetro, esos sí fijados a mano desde fuera del entrenamiento.

2. Una red de diez capas sin ninguna activación, ¿a qué equivale?

- A. A una red igual con ReLU en sus capas ocultas.
- B. A un árbol de decisión de diez niveles de hondo.
- C. A una regresión lineal, por muchas capas que apile.
- D. A una red que sólo separa clases circulares.

C Componer transformaciones lineales da otra transformación lineal: $W_3W_2W_1\mathbf{x}$ es una sola matriz disfrazada de tres. Sin ReLU ni ninguna otra no linealidad, las diez capas colapsan en el modelo lineal de siempre y la profundidad no compra nada. *Distractor:* A, que es justamente la red que sí aprovecha la profundidad, porque la esquina de la ReLU rompe la linealidad.

3. ¿Qué hace un paso de descenso por gradiente sobre el error cuadrático medio?

- A. Mueve los pesos hacia donde ese error baja más deprisa.
- B. Descarta los ejemplos con el error más alto del batch.
- C. Recalcula la salida con los pesos que ya tenía antes.
- D. Elige la arquitectura que menos error comete al final.

A El gradiente del error cuadrático medio respecto a cada peso apunta hacia donde ese error sube; el paso avanza en sentido contrario, con una longitud que fija el learning rate. *Distractor:* C, el paso hacia delante, que calcula la predicción pero no cambia ningún peso.

4. ¿Qué es el dropout dentro de una red neuronal?

- A. Un optimizador que acelera la bajada del error.
- B. Un regularizador que combate el sobreajuste.
- C. Una métrica que mide el error en validación.
- D. Una capa que reduce el tamaño de la imagen.

B Apagar neuronas al azar mientras se entrena impide que la red se apoye siempre en las mismas y la obliga a repartir lo aprendido. El efecto es el de cualquier regularizador: empeora un poco el error de entrenamiento y cierra el hueco con el de validación. *Distractor:* D, que describe el pooling de una CNN.

5. ¿Para qué se reserva un conjunto de validación además del de entrenamiento?

- A. Para acortar el entrenamiento repartiendo los datos en dos mitades.
- B. Para equilibrar el número de ejemplos de cada una de las clases.
- C. Para etiquetar de nuevo los ejemplos que el modelo clasifica peor.
- D. Para medir el modelo sobre datos que no ha usado para aprender.

D Sobre los datos de entrenamiento cualquier red acaba luciendo bien, porque los ha visto; el juicio útil viene de datos que no ha tocado, y de ahí salen el early stopping y la elección de hiperparámetros. *Distractor:* A, que confunde partir los datos con paralelizar.

6. ¿Por qué una CNN conecta cada neurona sólo con píxeles vecinos?

- A. Porque la GPU no puede leer dos zonas distantes de la misma imagen.
- B. Porque así el mapa de salida conserva el tamaño de la imagen entera.
- C. Porque los píxeles lejanos de una foto casi no se informan entre sí.
- D. Porque los píxeles del borde no aportan información útil a la red.

C Un borde, una textura o una esquina se reconocen mirando un trozo pequeño; lo que pasa al otro lado de la foto no ayuda a decidirlo. Conectar sólo lo cercano ahorra casi todos los parámetros de un MLP denso. *Distractor:* A, una limitación de hardware inventada.

7. ¿Qué es un kernel de una capa convolucional?

- A. La lista de píxeles que la capa descarta en cada una de sus posiciones.
- B. Una matriz pequeña de pesos que la red aprende y desliza por la imagen.
- C. El número de mapas de activación que la capa deja a su salida.
- D. Una tabla fija de valores que el ingeniero escribe a mano antes.

B Son nueve números en el caso 3×3 , aprendidos como cualquier otro peso, que se aplican en todas las posiciones de la imagen. *Distractor:* D, que describe los kernels clásicos de visión anteriores al aprendizaje profundo, que sí se escribían a mano.

8. ¿Qué se descarga de un hub como Hugging Face al reutilizar un modelo?

- A. Los pesos ya entrenados sobre un conjunto de datos enorme.
- B. El conjunto de imágenes con el que se entrenó ese modelo.
- C. Las etiquetas del problema concreto que se quiere resolver.
- D. La máquina virtual con GPU sobre la que corre el entrenamiento.

A Lo que se reutiliza es el resultado del entrenamiento ajeno, es decir, unos pesos que costaron miles de horas de GPU y que traen hechos los rasgos visuales genéricos. *Distractor:* B, que sería el dato en crudo y no ahorraría nada del cómputo.

9. ¿Ante qué tipo de datos conviene una red recurrente?

- A. Ante tablas cuyas filas son independientes entre sí.
- B. Ante fotografías de alta resolución tomadas en color.
- C. Ante catálogos con muchas más columnas que ejemplos.
- D. Ante secuencias donde el orden de los valores importa.

D Una serie de ventas, una frase o un registro de sensores dicen algo distinto si se barajan sus elementos. La recurrente los lee uno tras otro y arrastra en su estado lo visto hasta ese punto, que es justo lo que unas filas independientes no necesitan. *Distractor:* A, el caso tabular de siempre, donde basta un MLP o un gradient boosting.

10. ¿Por qué los pesos de atención pasan por un softmax?

- A. Para que el coste deje de crecer con la longitud de la frase.
- B. Para que la salida sea una distribución de probabilidad.
- C. Para que los valores negativos se vuelvan positivos.
- D. Para que todas las cabezas compartan la dimensión.

B El softmax toma unos scores cualesquiera, los vuelve positivos y los normaliza para que sumen uno: lo que sale es una distribución de probabilidad sobre los tokens, y por eso cada peso se puede leer como la fracción de atención que recibe ese token. *Distractor:* A, que atribuye al softmax un efecto sobre el coste que no tiene: la atención sigue siendo cuadrática.

11. ¿De dónde saca word2vec el significado de una palabra?

- A. De un diccionario con las definiciones de cada uno de los términos.
- B. Del número de letras y de sílabas que tiene esa palabra concreta.
- C. De las palabras que aparecen a su alrededor a lo largo del texto.
- D. De la frecuencia con la que la palabra sale en el corpus entero.

C Dos palabras que aparecen rodeadas de las mismas vecinas acaban con vectores parecidos, sin que nadie le explique al modelo qué significan. *Distractor:* D, la frecuencia, que es justo lo que el coseno descarta al normalizar por la norma.

12. ¿Qué comparten por dentro ChatGPT, BERT y los traductores actuales?

- A. La red recurrente con memoria larga que llevan dentro.
- B. El mismo corpus de entrenamiento descargado de la web.
- C. El idioma inglés como única lengua que saben tratar.
- D. La arquitectura Transformer construida con atención.

D Desde 2017 casi todo lo que funciona en lenguaje es la misma pila de bloques de atención, y lo que los separa es el régimen de entrenamiento: con máscara causal sale un generador tipo GPT y sin ella un codificador tipo BERT. *Distractor*: A, la arquitectura recurrente anterior, que es justo la que el Transformer desplazó.

Parte II — Problemas (3 preguntas, 2 puntos cada una)

13. [Día 02] Un modelo de scoring de leads tiene una neurona de pesos $\mathbf{w} = (0,5, -0,5)$ y sesgo $b = -1$, con activación ReLU. Para el lead $\mathbf{x} = (6, 2)$, ¿cuánto vale $\text{ReLU}(z)$?

- A. $\text{ReLU}(1) = 1$
- B. $\text{ReLU}(2) = 2$
- C. $\text{ReLU}(3) = 3$
- D. $\text{ReLU}(-3) = 0$

A $z = (0,5)(6) + (-0,5)(2) - 1 = 3 - 1 - 1 = 1$, y la ReLU deja pasar los positivos tal cual, de modo que la neurona saca 1. *Distractores*: B olvida el sesgo; C toma w_2 en valor absoluto; D invierte el signo de los dos pesos, y entonces la ReLU apaga la salida.

14. [Día 04] Un control de calidad busca rayas horizontales en una pieza. La primera capa de su CNN coloca el kernel K sobre la ventana de 3×3 que ocupa la esquina inferior derecha de M . ¿Qué valor obtiene ahí?

$$K = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{pmatrix}, \quad M = \begin{pmatrix} 8 & 7 & 6 & 2 \\ 5 & 5 & 4 & 3 \\ 2 & 1 & 1 & 9 \\ 3 & 2 & 2 & 8 \end{pmatrix}.$$

- A. 12
- B. 24
- C. 0
- D. -12

C La ventana son las tres últimas filas y las tres últimas columnas. La fila central del kernel es cero, de modo que el valor es la suma de la fila de arriba menos la de abajo: $(5 + 4 + 3) - (2 + 2 + 8) = 12 - 12 = 0$. Ahí no hay raya horizontal porque arriba y abajo brillan lo mismo. *Distractores*: A suma sólo la fila de arriba; B suma las dos en vez de restarlas; D invierte el signo del kernel.

15. [Día 08] Un buscador interno guarda los embeddings $\varphi(\text{Madrid}) = (9, 5)$, $\varphi(\text{España}) = (8, 3)$ y $\varphi(\text{Francia}) = (7, 2)$. Según la analogía $\varphi(\text{París}) \approx \varphi(\text{Madrid}) - \varphi(\text{España}) + \varphi(\text{Francia})$, ¿qué vector predice para París?

- A. (24, 10)
- B. (8, 4)
- C. (10, 6)
- D. (-6, 0)

B Se opera coordenada a coordenada: $(9 - 8 + 7, 5 - 3 + 2) = (8, 4)$. La resta quita lo que Madrid tiene de capital española y la suma lo traslada a Francia. *Distractores*: A suma los tres vectores; C intercambia los papeles de España y Francia; D resta los dos en lugar de restar uno y sumar el otro.