

Deep Learning para Business Analytics

Día 08 · Tema 3 — Embeddings semánticos

 *Vectores que significan.*

Eduardo C. Garrido-Merchán

Profesor Propio Adjunto, Métodos Cuantitativos, ICADE

`ecgarrido@comillas.edu`



Madrid, Día 08

BBVA MERCADORA NETFLIX amazon Spotify Google

ejemplos del día

Lo que vamos a cubrir hoy.

1. Qué es un embedding
2. Cómo se entrenan
3. Medir el parecido
4. Casos de negocio


Al final del día: sabes qué hay dentro de un embedding , de dónde sale, qué es un token y cómo se compara por significado: la base de RAG  (Tema 6).

Parte 1 / 4

Qué es un embedding



🎵 🔍 Spotify agrupa 100 millones de canciones por similitud sin etiquetas manuales.



El problema. Spotify tiene > 100 millones de canciones. Etiquetarlas a mano es imposible.

La solución. Un embedding convierte cada canción en un vector. Canciones parecidas (por audio, letras y comportamiento de escucha) quedan como vectores cercanos.


El resultado. Discover Weekly y el autoplay funcionan comparando la distancia entre tu historial y canciones candidatas en el espacio de embeddings.

IDEA CLAVE. Un embedding convierte datos complejos en vectores donde la cercanía es similitud.



Un embedding es una dirección postal para cada palabra.

Un embedding es un mapa semántico: palabras cercanas = significados cercanos.



El mapa semántico. Cada palabra vive en un punto del espacio. Palabras con significado parecido (rey/reina, perro/gato) están cerca; palabras con sentido distinto (banco-dinero vs. banco-parque) están lejos.

La métrica. La distancia coseno mide el ángulo entre dos vectores. Ángulo pequeño → significado compartido. Ángulo grande → sentidos distintos.


Por qué importa. Esta geometría permite buscar por significado, no por coincidencia de caracteres.

IDEA CLAVE. Palabras con significado parecido viven cerca. La distancia coseno mide cuánto.

Cada número del vector mide algo, pero nadie le pone nombre.

Un embedding es una lista de números. ¿Qué mide cada número?

De juguete: “hipoteca” con 5 dimensiones



hipoteca = (0.95, 0.10, 0.80, 0.35, 0.90)

En un embedding real las dimensiones no tienen nombre.

Las elige el entrenamiento y por separado no dicen nada legible; lo que significa es la dirección del vector entero.

Cuántas dimensiones usan los modelos reales:

word2vec / GloVe (2013)		300
CLIP, imagen y texto (2021)		512
BERT base (2018)		768
E5 / BGE large (2023)		1024
OpenAI text-embedding-3-small		1536
OpenAI text-embedding-3-large		3072

de 300 a 3 000 números por trozo de texto

Más dimensiones, más matices caben, pero más memoria y búsquedas más lentas: un millón de frases a 1024 dim son 4 GB.

word2vec 🧠: la prueba de que los números guardan significado.

word2vec: la aritmética vectorial captura relaciones semánticas.



La analogía. 👑 rey – 🧑 hombre + 🧑 mujer $\approx$ 👑 reina.

Lectura. El salto de *rey* a *reina* es el mismo salto que de *hombre* a *mujer*: esa dirección del espacio codifica el género.

Por qué importa. Nadie programó esa dirección. Salió sola del entrenamiento, y eso es la prueba de que los números guardan relaciones de significado.

Parte 2 / 4

Cómo se entrenan






¿De dónde salen esos números? De jugar a adivinar la palabra que falta.


Los vectores empiezan al azar y se colocan solos jugando a adivinar el vecino.

1. Al principio: números al azar




ningún vector significa nada todavía

2. El juego, millones de veces



cada fallo empuja un poco los vectores

3. El resultado




quien comparte vecinos, acaba cerca

IDEA CLAVE. Los vectores arrancan al azar. Se tapa una palabra, la red intenta adivinarla por sus vecinas y cada fallo mueve un poco los vectores. Repetido sobre miles de millones de frases, las palabras que aparecen en contextos parecidos acaban en la misma zona: el significado lo define la compañía que cada palabra frecuente.

🤖 Un vector por palabra se queda corto; hoy el vector depende de la frase.

Un embedding es un mapa semántico: palabras cercanas = significados cercanos.



El problema de word2vec. “Banco” tiene un único vector que mezcla el banco del dinero y el del parque. Cualquier búsqueda hereda esa mezcla.

La solución es de ayer. Es exactamente la atención del Día 07: el vector de “banco” se recalcula mirando a las palabras de su frase. BERT y sus descendientes hacen eso en cada capa.

Cómo se entrenan. Mismo juego, más difícil: se tapa el 15 % de los tokens de un texto y la red los reconstruye viendo el contexto por los dos lados.

IDEA CLAVE. Estáticos (word2vec) para entender la idea; contextuales (BERT, E5) para todo lo que se usa hoy.


Parte 3 / 4

Medir el parecido



Comparar significados es comparar ángulos.

Buscar por significado es comparar ángulos: gana la frase que apunta más parecido.



La cuenta, con la frase A

consulta = (4.0, 0.5) frase A = (4.5, 0.8)

1. multiplico y sumo: $4.0 \cdot 4.5 + 0.5 \cdot 0.8 = 18.4$
2. longitud de cada flecha: 4.03 y 4.57
3. divido: $18.4 / (4.03 \cdot 4.57) = 1.00$

El ranking de la búsqueda

1.00 frase A: "el préstamo incluye comisión de apertura"

0.94 frase B: "abrimos una cuenta nómina sin comisiones"

0.36 frase C: "el banco del parque es de madera"

0 es nada que ver; 1 es exactamente la misma dirección.

Y eso, escrito, es la similitud coseno.

$$\cos(\vec{u}, \vec{v}) = \frac{\vec{u} \cdot \vec{v}}{\|\vec{u}\| \cdot \|\vec{v}\|} \in [-1, 1].$$

Cada trozo es un paso del dibujo anterior. Arriba, multiplicar coordenada a coordenada y sumar. Abajo, las longitudes de las dos flechas. Dividir quita el tamaño y deja solo la dirección.

 **Por qué el ángulo y no la distancia.** Un documento largo y uno corto sobre lo mismo apuntan igual aunque sus vectores midan distinto. Comparar direcciones ignora esa diferencia de tamaño.

 **En la práctica.** Se guardan los vectores ya normalizados a longitud 1; entonces el coseno es un simple producto escalar y la búsqueda es una multiplicación de matrices.

IDEA CLAVE.  Buscador semántico, recomendador y RAG (Día 15) son esta cuenta repetida un millón de veces.




Ejercicio resuelto: ¿qué texto devuelve el buscador?

Enunciado: la consulta es “¿cuánto cuesta una hipoteca a 30 años?”. ¿Qué texto devuelve el buscador?

Cada texto se describe con tres números: (cuánto habla de dinero, cuánto habla de plazo, cuánto habla de naturaleza).

consulta	(3, 4, 0)	<i>“¿cuánto cuesta una hipoteca a 30 años?”</i>	$\text{longitud} = \sqrt{3^2 + 4^2 + 0^2} = \sqrt{25} = 5$
texto A	(4, 3, 0)	<i>“préstamo hipotecario a largo plazo”</i>	$\text{longitud} = \sqrt{4^2 + 3^2 + 0^2} = \sqrt{25} = 5$
texto B	(0, 3, 4)	<i>“alquilamos la casa del bosque”</i>	$\text{longitud} = \sqrt{0^2 + 3^2 + 4^2} = \sqrt{25} = 5$
texto C	(0, 0, 5)	<i>“el banco del parque es de madera”</i>	$\text{longitud} = \sqrt{0^2 + 0^2 + 5^2} = \sqrt{25} = 5$

Qué es esa longitud



Lo que mide la flecha,
por Pitágoras:

$$\sqrt{3^2 + 4^2} = 5$$

Con tres números se
suman los tres cuadrados.

Desarrollo con el texto A

1. multiplico y sumo:

$$3 \cdot 4 + 4 \cdot 3 + 0 \cdot 0 = 24$$

2. longitudes: 5 y 5

3. divido: $24 / (5 \cdot 5) = 0.96$

Los tres resultados

texto A: $24/25 = 0.96$

gana la búsqueda

texto B: $12/25 = 0.48$

comparte el plazo

texto C: $0/25 = 0.00$

nada que ver

Respuesta: el buscador devuelve A (0.96), luego B (0.48) y descarta C (0.00).

⚙️ Una pieza más antes del Día 09: el modelo no ve palabras, ve tokens.

Token: el trozo de texto más pequeño que el modelo maneja, con su propio número en un vocabulario fijo.

"El banco aprueba la hipoteca del cliente." → 7 palabras, 10 tokens

El	banco	apr	ueba	la	hip	oteca	del	cliente	.
6719	53565	21726	43512	1208	18638	65490	1624	27727	13

debajo, el número de cada token en el vocabulario: eso es lo que entra de verdad en el modelo

"hipoteca"

hip

oteca

una palabra corriente en español
ya se parte en dos

"descatalogado"

desc

atalog

ado

cuanto más rara, más trozos

"BBVA2026"

BB

VA

202

6

marcas y cifras se parten aún más

Un vector por token

El embedding no va por palabra:
va por token. "hipoteca" son dos
vectores, no uno.

El vocabulario es fijo

El tokenizador de GPT-4 tiene
100 277 piezas. Todo texto del
mundo se escribe con ellas.

Todo se mide en tokens


El contexto y la factura de una API
se cuentan en tokens: la misma
frase cuesta más en español que
en inglés (10 frente a 7).

IDEA CLAVE. Lo veremos en serio más adelante, pero quedáos con esto: todo lo que entra y sale de un modelo se mide en tokens, y por tokens se paga. Cuando en el Día 13 montemos agentes, el presupuesto será en tokens.



Recapitulando: dónde encaja cada pieza del curso.

Dónde encaja cada pieza: del texto que escribe el usuario a la respuesta del modelo.




El Transformer del Día 07 vive en el paso 4; lo que mezcla son los embeddings del paso 3, y esos vienen de los tokens del paso 2.

IDEA CLAVE. Hoy hemos montado los pasos 2 y 3: trocear el texto en tokens y convertir cada token en un vector comparable por ángulo. El Transformer del Día 07 es el paso 4, y lo que mezcla son precisamente estos vectores. El Día 09 lo abre entero y el Día 11 llega al paso 5.

Parte 4 / 4

Casos de negocio



★ Cuatro casos que viven sobre embeddings.

Cuatro casos de negocio que viven sobre embeddings.

BBVA

Búsqueda interna

Encontrar circulares
por significado, no palabras.

MERCADONA

Recom. productos

Similitud entre productos
basada en descripción.

NETFLIX

Recom. contenidos

Embeddings de usuario
×
embeddings de serie.

amazon

Recom. compra

Vectores de ítem
entrenados con compras.



Buscador semántico. Encuentra documentos por significado, no por palabra exacta.



Recomendador. Productos similares en el espacio de embeddings.



Detección de fraude. Transacciones anómalas como vectores lejanos del clúster normal.



Triage clínico. Clasificar urgencias por similitud semántica con casos previos.



Lo que el alumno se lleva a casa de este día.



Concepto 1. Un embedding es una lista de entre 300 y 3 000 números por trozo de texto. Ninguno significa nada por separado; la dirección del conjunto sí.



Concepto 2. Esos números salen de jugar a adivinar la palabra que falta, millones de veces. Palabras con vecinos parecidos acaban cerca.



Concepto 3. Para comparar significados se mide el ángulo: similitud coseno, 1 es la misma dirección y 0 es nada que ver.



Concepto 4. El texto se trocea en tokens antes de nada, y en tokens se mide el contexto y se paga la factura.




Para la práctica. Embedder gratis (E5) + buscador semántico sobre 100 párrafos corporativos.



Próximo día. Día 09 (Tema 3.2): atención multi-head y bloque Transformer completo.

🗨️ Pausa para debatir: ¿Codifica un embedding también los prejuicios?



⚠️ **La pregunta.** Un embedding mide significado, pero ¿de quién? ¿Heredan los prejuicios del corpus de entrenamiento?

🔥 **Posición A.** Sí, y los amplifican: “médico” vs. “enfermera” en word2vec lo mostró.

🛡️ **Posición B.** No, son herramientas neutras; el problema es el uso, no el embedding.

🕒 **Reglas.** 5 minutos, dos turnos de palabra por bando, móviles boca abajo. Yo modero, no participo.

Hasta el Día 09.

⚡ *El Transformer entero, en pizarra.*

Eduardo C. Garrido-Merchán

ecgarrido@comillas.edu

