

Deep Learning para Business Analytics

Día 09 · Tema 3 — El Transformer entero

Atención multi-head, bloque encoder y por qué dominó la IA moderna.

Eduardo C. Garrido-Merchán

Profesor Propio Adjunto, Métodos Cuantitativos, ICADE

ecgarrido@comillas.edu



Madrid, Día 09



ejemplos del día

Lo que vamos a cubrir hoy.

1. Corolario de los dos días anteriores
2. Arquitecturas
3. Despedida de las matemáticas

Al final del día: sabes dibujar un Transformer de memoria y explicar de dónde sale cada pieza. Aquí se cierra la parte matemática del curso.


Parte 1 / 3

Corolario de los dos días anteriores



⚡🌐 ChatGPT, Claude, Gemini: todos son el mismo diseño de 2017.

Una sola idea (self-attention) unificó NLP, visión, audio y proteínas.



Una sola idea. La atención que visteis el Día 07, apilada en bloques, unificó texto, visión, audio y proteínas.


La línea temporal. 2017: *Attention Is All You Need*. 2018: BERT. 2020: GPT-3. 2022: ChatGPT. 2024–26: Claude, GPT-5 y los agentes que montaremos en el Tema 5.

Lo llamativo. La arquitectura no ha cambiado en lo esencial desde 2017. Lo que ha crecido es el tamaño, los datos y el dinero.

IDEA CLAVE. Hoy no aprendemos nada nuevo: montamos lo de los dos días anteriores y le ponemos nombre.

El corolario: un Transformer es vuestra atención apilada N veces.

El Transformer no es una pieza nueva: es el montaje de lo que ya sabéis.



Lo que puso cada día

Día 02

Una capa densa: multiplicar por una matriz y pasar una no linealidad.

Día 07

La atención: cada palabra pregunta al resto y se queda con una mezcla de lo que aportan.

Día 08

Tokens y embeddings: convertir texto en vectores con significado, comparables.

Hoy

El montaje: apilar N bloques iguales y elegir qué mira cada token (la máscara).

Eso es todo. GPT, Claude y Gemini son esta columna, con N muy grande.


Parte 2 / 3

Arquitecturas



⚡ Un bloque, por dentro: atención, residual, ⚙ MLP y residual.

Un bloque Transformer (encoder)



La atención mezcla tokens. Es la única parte del bloque donde un token ve a los demás; todo lo demás trabaja token a token. Se corren varias atenciones en paralelo (*multi-head*) y se concatena lo que sacan: con 768 números por token y 12 cabezas, cada una trabaja con 64.

La capa densa piensa sobre cada token. Es el MLP del Día 02, aplicado por separado a cada vector. Ahí es donde el modelo guarda la mayor parte de sus parámetros.



Residual y normalización. Cada sub-capas suma su salida a su entrada en vez de sustituirla, y se normaliza la escala entre bloques. Sin eso, apilar noventa bloques no entrenaría: el problema de gradientes del Día 03.

IDEA CLAVE. Cuatro piezas, todas conocidas. Lo nuevo es el orden en que se montan.



La máscara decide si el modelo entiende o genera.

BERT vs GPT: la máscara causal cambia el juego.



Sin máscara (BERT). Cada token ve toda la frase, antes y después. Sirve para clasificar, extraer entidades y buscar: comprender un texto que ya existe.

Con máscara causal (GPT). Cada token solo ve a los anteriores, porque los siguientes todavía no se han escrito. Sirve para generar.

Las dos cosas (T5, traducción). Un encoder que lee entero y un decoder que escribe palabra a palabra mirando al encoder.

IDEA CLAVE. Misma arquitectura, misma operación: tapar media tabla de atención es lo único que separa a BERT de ChatGPT.

⚡ Las tres familias, y por qué os vais a topar con las tres.

Forma	Modelo emblemático	Tarea típica	Dónde sale
Solo encoder	BERT, RoBERTa, E5.	Clasificar, buscar.	Día 08, Día 15.
Solo decoder	GPT, Claude, Llama.	Generar texto.	Días 11–17.
Encoder-decoder	T5, MarianMT.	Traducir, resumir.	Día 12.
Visión	ViT, Swin.	Clasificar imágenes.	Día 12.
Multimodal	CLIP, GPT-4V.	Imagen y texto juntos.	Día 12.

IDEA CLAVE. Cambiando la máscara y el entrenamiento, la misma arquitectura hace todo lo que veréis de aquí a junio.

El mismo diseño ganó en seis campos que no tenían nada que ver.

El Transformer ha sustituido a su predecesor en seis dominios distintos.

Ámbito	Antes	Modelo actual	Año salto
Traducción	RNN encoder-decoder	Transformer (Vaswani et al.)	2017
Lenguaje genérico	LSTM bidireccional	BERT, GPT-3 y descendientes	2018–2020
Visión	ResNet, EfficientNet	ViT y SAM	2020
Audio	RNN espectrogramas	Whisper, AudioLM	2022
Series temporales	ARIMA, LSTM	PatchTST, TimeGPT	2023
Robótica	Control clásico	RT-2 (vision-language-action)	2023

Parte 3 / 3

Despedida de las matemáticas



Aquí se acaban las matemáticas del curso.

Hasta aquí las matemáticas del curso. Lo que viene es construir con ellas.

Lo que ya habéis calculado a mano

- **Día 02** la neurona y el MLP
- **Día 03** entrenar sin romperlo
- **Día 04** convolución y pooling
- **Día 06** recurrencia y memoria
- **Día 07** atención
- **Día 08** tokens y embeddings
- **Día 09** el Transformer entero

Lo que viene, y ya no lleva derivadas

Día 11

LLMs y context engineering: qué cabe en el contexto de un modelo y cómo dárselo para que acierte.

Día 12

Generación multimodal: imagen, audio y vídeo con el mismo diseño de hoy.

Días 13-14

Agentes con Claude Code, subagentes y MCP: conectar el modelo a herramientas, ficheros y APIs de verdad.

Días 15-16

RAG corporativo sobre los embeddings de ayer, y adaptación con LoRA, SFT y DPO.

Días 17-18

Multi-agente en producción, AI Act, ética y auditoría.

Nadie os va a pedir derivar un Transformer. Se os va a pedir saber qué hay dentro cuando montéis uno.

★ Lo que os lleváis de este bloque.

Uno. ⚡ Un Transformer es una pila de bloques iguales, y cada bloque es atención (Día 07) más una capa densa (Día 02), con residuales y normalización.


Dos. 📖 Lo que entra son tokens convertidos en embeddings (Día 08); lo que sale depende de la cabeza que le pongas al final.

Tres. 🧠 Lo único que separa un modelo que comprende de uno que genera.

Cuatro. 🧠 Nada de esto se os va a pedir derivado ni calculado. Se os va a pedir reconocerlo cuando lo tengáis delante.

Lo próximo. 🚀 El examen parcial del Bloque I, y a la vuelta el Día 11: qué cabe en el contexto de un LLM y cómo hablarle para que haga lo que queréis.

Pausa para debatir: Si el Transformer sirve para todo, ¿qué papel queda a CNN y RNN?



La pregunta. ViT supera a ResNet y los Transformer hacen forecast mejor que una LSTM. ¿Es razonable seguir enseñando CNN y RNN en 2026?

Posición A. Sí: son la base conceptual del Transformer y siguen ganando en dispositivos pequeños y en latencia.

Posición B. No: son legado, y ese tiempo se aprovecha mejor montando agentes.

Reglas. 5 minutos, dos turnos de palabra por bando, móviles boca abajo. Yo modero, no participo.

Hasta el Día 11.

*Hablarle a un modelo: contexto, prompts
y herramientas.*

Eduardo C. Garrido-Merchán

ecgarrido@comillas.edu

