

IDIOMAS

Ficha del conjunto de datos de las pruebas de certificación de idiomas

Referencia EOI/CER/2026 • Ficha de conjunto de datos

Conjunto de datos. 6 400 registros • 17 campos • cada registro corresponde a una persona presentada a una prueba de certificación • documento de circulación interna.

Este documento recopila, sin análisis ni interpretación alguna, el material descriptivo de un conjunto de datos de las pruebas de certificación de idiomas de una escuela oficial. Se ofrece el diccionario de variables, las tablas de estadísticos descriptivos y una selección de representaciones gráficas, tal y como se obtendrían de una primera exploración del fichero. La lectura, el diagnóstico de la calidad del dato y cualquier conclusión quedan enteramente a cargo del analista. La puntuación global se obtiene promediando las cuatro destrezas sobre cien puntos y exige un mínimo del cincuenta por ciento en cada una.

1 Diccionario de variables

La tabla siguiente enumera los campos del fichero con su definición desde el punto de vista del negocio. No se indica su naturaleza estadística ni el papel que cada uno pueda desempeñar en un análisis posterior.

Campo	Definición de negocio
nivel_presentado	Nivel del Marco Común Europeo al que se presenta.
horas_curso_anuales	Horas de clase recibidas en la escuela durante el curso.
anios_estudio_idioma	Años acumulados de estudio formal del idioma.
estancia_pais_idioma	Indica si la persona ha residido al menos tres meses en un país del idioma. Procede de la última extracción del almacén de datos corporativo.
uso_laboral_idioma	Indica si la persona emplea el idioma habitualmente en su trabajo.
convocatorias_previas_idioma	Número de veces que la persona se presentó antes al mismo nivel. Idioma de la prueba de certificación. Se recoge en el momento del alta y no se actualiza después.
edad	Edad de la persona presentada.
sexo	Sexo registrado en la matrícula.
modalidad_matricula	Modalidad en que la persona cursó el idioma. Procede de la última extracción del almacén de datos corporativo.
sede	Sede en que se celebró la prueba.
fecha_prueba	Fecha de celebración de la prueba escrita. Procede de la última extracción del almacén de datos corporativo.
tasa_abonada_eur	Importe de la tasa de examen abonada.
becario	Indica si la persona está exenta del pago de la tasa.
puntuacion_global	Puntuación global de la prueba de certificación, sobre cien puntos, promediando las cuatro destrezas.
turno_oral	Turno asignado para la prueba oral.

Campo	Definición de negocio
numero_expediente	Número de orden del expediente en la sede.

2 Estadísticos descriptivos de las variables numéricas

Se recogen, para cada campo cuantitativo, el número de registros observados, el de ausencias, la media, la desviación típica, el mínimo, los cuartiles y el máximo.

Variable	<i>n</i>	Aus.	Media	D.T.	Mín.	Q1	Mediana	Q3	Máx.
Horas de curso en el año	6 400	0	130,01	58,41	12,00	87,00	122,00	163,00	490,00
Años de estudio del idioma	6 400	0	4,49	4,34	0,00	1,00	3,00	6,00	44,00
Convocatorias previas	6 400	0	0,51	1,00	0,00	0,00	0,00	1,00	8,00
Edad	6 400	0	24,18	31,43	-99,00	22,00	30,00	38,00	70,00
Puntuación global de la prueba	6 400	0	70,00	6,62	6,80	65,80	70,20	74,40	90,30
Número de expediente	6 400	0	692,60	403,99	1,00	338,00	684,00	1 038,25	1 400,00

3 Distribución de frecuencias de las variables categóricas

Para cada campo cualitativo se indica el número de categorías distintas, las ausencias, la categoría más frecuente y su peso relativo.

Variable	Categorías	Aus.	Categoría más frecuente	Frec.
Nivel presentado	4	0	B2	2 589 (40,5 %)
Estancia en país del idioma	2	0	no	4 970 (77,7 %)
Uso laboral del idioma	2	0	no	4 238 (66,2 %)
Idioma	6	0	inglés	3 813 (59,6 %)
Sexo	2	0	mujer	3 661 (57,2 %)
Modalidad de matrícula	9	0	presencial	3 136 (49,0 %)
Sede	3	0	sede central	2 854 (44,6 %)
Fecha de la prueba	20	0	18/05/2026	351 (5,5 %)
Tasa abonada	3	0	96,00	2 637 (41,2 %)
Exención de tasa	2	0	no	5 510 (86,1 %)
Turno de la prueba oral	2	0	mañana	3 610 (56,4 %)

El reparto completo de las dos variables cualitativas con mayor número de categorías se detalla a continuación.

Fecha de la prueba	<i>n</i>	%
18/05/2026	351	5,5
03/06/2026	345	5,4
04/06/2026	338	5,3
26/05/2026	337	5,3
27/05/2026	336	5,2
25/05/2026	331	5,2
30/05/2026	330	5,2
21/05/2026	329	5,1
24/05/2026	326	5,1
22/05/2026	325	5,1
01/06/2026	322	5,0
06/06/2026	319	5,0
19/05/2026	316	4,9
23/05/2026	310	4,8
02/06/2026	306	4,8
29/05/2026	306	4,8
05/06/2026	303	4,7
31/05/2026	300	4,7
28/05/2026	300	4,7
20/05/2026	270	4,2
Total	6 400	100,0

Modalidad de matrícula	<i>n</i>	%
presencial	3 136	49,0
semipresencial	1 113	17,4
libre	871	13,6
PRESENCIAL	419	6,5
presencial	379	5,9
SEMIPRESENCIAL	142	2,2
semipresencial	129	2,0
libre	126	2,0
LIBRE	85	1,3
Total	6 400	100,0

4 Representaciones gráficas

Las figuras que siguen se presentan sin comentario. Su pie se limita a identificar las variables representadas.




Figura 1. Matriz de correlación lineal entre las variables numéricas del conjunto.




Figura 2. Distribución de «Horas de curso en el año» (izquierda) y de «Años de estudio del idioma» (derecha).




Figura 3. Distribución de «Convocatorias previas» (izquierda) y de «Edad» (derecha).




Figura 4. Diagramas de caja de las variables numéricas tipificadas, es decir, expresadas en desviaciones respecto de su propia media.




Figura 5. Recuento de registros por «Fecha de la prueba» (izquierda) y por «Modalidad de matrícula» (derecha).




Figura 6. Reparto de registros por «Nivel presentado» (izquierda) y por «Estancia en país del idioma» (derecha).




Figura 7. «Convocatorias previas» frente a «Edad» (izquierda) y «Convocatorias previas» frente a «Número de expediente» (derecha).




Figura 8. «Edad» frente a «Número de expediente».




Figura 9. «Horas de curso en el año» desagregado por «Estancia en país del idioma».

5 Posibles enriquecimientos del conjunto

Reflexión abierta para el analista

Más allá de los campos disponibles, conviene preguntarse qué otras fuentes de información mejorarían el conjunto y qué se ganaría con cada una. Primero, ¿qué información de las destrezas por separado, como la puntuación de expresión oral frente a la de comprensión escrita, revelaría el perfil del candidato? Segundo, ¿qué datos del grupo de origen, como el profesor o el horario del curso, situarían el resultado en su contexto docente? Tercero, ¿qué variables del examen, como el modelo de prueba empleado en cada convocatoria, harían comparables las puntuaciones entre años? De todas ellas, ¿cuáles considera factibles de obtener respetando la normativa aplicable y cuáles meramente hipotéticas, y mediante qué identificador de expediente las uniría al fichero actual?